

Максимумът на точките, които можете да получите общо всички домашни през семестъра е 50, като това кореспондира с бонус от 0.5 към оценката за упражненията.

Това домашно е базирано на конкурсен изпит за френските университети под шапката Centrale-Supélec, и е наличен на <https://www.concours-centrale-supelec.fr/sujets-rapports> в секцията Mathématiques 1 за 2018 и съответно е под същия лиценз, CC BY-NC-SA 2.0 <https://creativecommons.org/licenses/by-nc-sa/2.0/>.

Бележки:

- В хода на задачата N , k и d са естествени числа по-големи или равни на 2, а t е реално число.
- За естествени числа m и n означаваме с $\mathcal{M}_{m,n}(\mathbb{R})$ множеството от $m \times n$ матрици с реални коефициенти.
- за $n \in \mathbb{N}$, за краткост под $[1, N]$, ще разбираме $\{1, \dots, N\}$.
- За всяка матрица A означаваме с A^T нейната транспонирана матрица.
- Всички случайни обекти са върху крайното вероятностно пространство $(\Omega, \mathcal{A}, \mathbb{P})$.
- Ако E е евклидово пространство (например $\mathbb{R}^n$), ще означаваме скаларното му произведение и породената норма съответно с $\langle \cdot, \cdot \rangle$ и $\| \cdot \|$.

Формулировка на задачата и цел

Колко най-много точки можем да изберем в $\mathbb{R}^n$, така че всички да са на равни разстояния помежду си? В равнината, т.е. $n = 2$, отговорът е 3 (равностранен триъгълник), а за $n = 3$, е 4 (правилен тетраедър); съответно може да проверим, че за $\mathbb{R}^n$ отговорът е $n + 1$.

Следователно е възможно да имаме например 50 вектора с размерност 100 (т.е. от $\mathbb{R}^{100}$) на равни разстояния помежду си. Ако искаме да визуализираме разположението им на двуизмерна картинка, предишният параграф ни показва, че това е невъзможно без да променим разстоянията между тях! Това е само едно (сравнително просто) проявление на т.нар. *проклятие на размерността* (*curse of dimensionality*), което е сборен термин за спецификите на пространства с висока размерност, които често се оказват контраинтуитивни.

В тази работа разглеждаме следния въпрос:

Могат ли N точки от евклидово пространство с висока размерност да бъдат линейно проектирани в пространство с по-ниска размерност, без съществена деформация на разстоянията между точките?

По-точно, нека $v_1, \dots, v_N \in \mathbb{R}^d$ са различни вектори. За реално $\varepsilon \in (0, 1)$, ще наричаме линейно преобразуване $f : \mathbb{R}^d \rightarrow \mathbb{R}^k$ ε -изометрия за $v_1, \dots, v_N$, ако

$$\forall (i, j) \in [1, N]^2 : (1 - \varepsilon) \|v_i - v_j\| \leq \|f(v_i) - f(v_j)\| \leq (1 + \varepsilon) \|v_i - v_j\|.$$

Цел: За кои стойности на k съществува линейно $f : \mathbb{R}^d \rightarrow \mathbb{R}^k$, което е ε -изометрия за $v_1, \dots, v_N$?

Ще докажем следната теорема, доказана първо от William B. Johnson и Joram Lindenstrauss през 1984:

Съществува абсолютна константа $c > 0$ такава, че за всички цели $N, d \geq 2$ и за всеки набор от N различни вектора в $\mathbb{R}^d$ е достатъчно

$$k \geq \frac{c \ln(N)}{\varepsilon^2},$$

за да съществува ε -изометрия $f : \mathbb{R}^d \rightarrow \mathbb{R}^k$ за $v_1, \dots, v_N$.

Единственият известен начин за доказване на тази теорема е чрез вероятностни методи. В част 1 разглеждаме нужни предварителни резултати за изпъкналост и вероятности. Част 2 е посветена на доказване на резултат на Талагранд за концентрация, а в Част 3 го използваме за доказване на теоремата на Johnson–Lindenstrauss.

1 Предварителни резултати

1.1 Проекция върху затворено изпъкнало множество

Нека E е евклидово пространство.

1. Нека $a, b \in E$. Докажете и дайте геометрична интерпретация на равенството

$$\|a + b\|^2 + \|a - b\|^2 = 2(\|a\|^2 + \|b\|^2).$$

2. Заключете, че ако $u, v, v' \in E$ са такива, че $v \neq v'$ и $\|u - v\| = \|u - v'\|$, то

$$\left\|u - \frac{v + v'}{2}\right\| < \|u - v\|.$$

3. Нека F е непразно затворено подмножество на E и $u \in E$. Докажете, че съществува $v \in F$ такава, че

$$\forall w \in F : \|u - v\| \leq \|u - w\|.$$

4. Заключете, че ако C е непразно затворено изпъкнало множество в E и $u \in E$, то съществува единствен $v \in C$ такъв, че

$$\forall w \in C : \|u - v\| \leq \|u - w\|.$$

Векторът v се нарича *проекция* на u върху C , като ще означаваме $d(u, C) := \|u - v\|$.

1.2 Неравенство на Hölder за очаквания

Нека p и q са положителни реални числа

$$\frac{1}{p} + \frac{1}{q} = 1.$$

1. Използвайки вдлъбнатостта на логаритъма, докажете, че за всички положителни a, b е изпълнено

$$ab \leq \frac{a^p}{p} + \frac{b^q}{q}.$$

2. Заключете, че за случайни величини X и Y над крайно вероятностно пространство е вярно, че

$$\mathbb{E}[|XY|] \leq (\mathbb{E}[|X|^p])^{1/p} (\mathbb{E}[|Y|^q])^{1/q}.$$

(Разгледайте първо случая $\mathbb{E}[|X|^p] = \mathbb{E}[|Y|^q] = 1$.)

1.3 Случайни величини със субгаусови опашки

Нека $X : \Omega \rightarrow \mathbb{R}$ е случайна величина и съществуват $a, b > 0$, такива че за всяко $t > 0$

$$\mathbb{P}(|X| \geq t) \leq a \exp(-bt^2).$$

1. Докажете, че

$$\mathbb{E}[X^2] = 2 \int_0^{+\infty} t \mathbb{P}(|X| \geq t) dt.$$

2. Покажете, че $\mathbb{E}[X^2] \leq a/b$.

3. За δ такава, че $\delta^2 \leq a/b$, докажете, че

$$\mathbb{P}(|X + \delta| \geq t) \leq \mathbb{P}(|X| \geq t - |\delta|).$$

4. Докажете, че

$$-b(t - |\delta|)^2 \leq a - \frac{1}{2}bt^2.$$

5. Заключете, че за $t \geq |\delta|$,

$$\mathbb{P}(|X + \delta| \geq t) \leq a \exp(a) \exp\left(-\frac{1}{2}bt^2\right).$$

6. Покажете, че последното неравенство остава вярно и за $0 \leq t < |\delta|$.

2 Неравенството на Талагранд

Нека E е евклидово пространство с размерност $n \geq 1$ и ортонормален базис $(e_1, \dots, e_n)$. Нека $\varepsilon_1, \dots, \varepsilon_n$ са независими Rademacher сл. вел., т.е. $\mathbb{P}(\varepsilon_1 = 1) = \mathbb{P}(\varepsilon_1 = -1) = 1/2$, и

$$X := \sum_{i=1}^n \varepsilon_i e_i.$$

Целта е да покажем, че за всяко непразно затворено изпъкнало множество $C \subset E$

$$\mathbb{P}(X \in C) \mathbb{E} \left[\exp \left(\frac{1}{8} d(X, C)^2 \right) \right] \leq 1, \quad (1)$$

с помощта на което ще докажем неравенството на Талагранд (2).

2.1 Два специални случая

1. Разгледайте случая, когато C не пресича

$$X(\Omega) := \{x \in E : X(\omega) = x \text{ за някое } \omega \in \Omega\},$$

т.е. $C \cap X(\Omega) = \emptyset$.

За останалите точки от тази подчасть предположете, че C пресича $X(\Omega)$ в точно един вектор u .

2. Покажете, че $\frac{1}{4} d(X, u)^2 \sim \text{Bin}(n, 1/2)$.
3. Намерете очакването на $\exp(\frac{1}{8} d(X, u)^2)$ и покажете, че то е най-много 2^n .
4. Докажете, че $d(X, C) \leq d(X, u)$ и докажете (1).

2.2 Индукция

Да предположим сега, че C е затворено изпъкнало подмножество на E , такова че $C \cap X(\Omega)$ съдържа поне два елемента. В такъв случай, без ограничение на общността, можем да приемем, че в $C \cap X(\Omega)$ има два вектора, които се различават по последната си координата. Ще докажем неравенството (1) чрез индукция по размерността n на E .

1. Разгледайте случая $n = 1$.

2.3 Свойства на C_{+1} и C_{-1}

Нека

$$E' := \text{span}(e_1, \dots, e_{n-1}), \quad \pi : E \rightarrow E' \text{ е ортогонална проекция,} \quad X' := \pi(X) = \sum_{i=1}^{n-1} \varepsilon_i e_i.$$

За $t \in \{-1, 1\}$, нека

$$H_t := E' + t e_n, \quad C_t := \pi(C \cap H_t).$$

1. Покажете, че за всеки $x' \in E'$ и $t \in \{-1, 1\}$

$$x' \in C_t \iff x' + t e_n \in C.$$

2. Докажете, че C_{+1} и C_{-1} са непразни затворени изпъкнали подмножества на E' .
3. За $t \in \{-1, 1\}$ нека Y_t е проекцията на X' върху C_t . Покажете, че

$$\mathbb{P}(X \in C) = \frac{1}{2} \mathbb{P}(X' \in C_{+1}) + \frac{1}{2} \mathbb{P}(X' \in C_{-1}).$$

2.4 Ключово неравенство

Нека $0 \leq \lambda \leq 1$.

1. Покажете, че

$$d(X, C) \leq \left\| (1 - \lambda)(Y_{\varepsilon_n} + \varepsilon_n e_n) + \lambda(Y_{-\varepsilon_n} - \varepsilon_n e_n) - X \right\|.$$

2. След това докажете, че

$$d(X, C)^2 \leq 4\lambda^2 + \left\| (1 - \lambda)(Y_{\varepsilon_n} - X') + \lambda(Y_{-\varepsilon_n} - X') \right\|^2$$

и

$$d(X, C)^2 \leq 4\lambda^2 + (1 - \lambda)\|Y_{\varepsilon_n} - X'\|^2 + \lambda\|Y_{-\varepsilon_n} - X'\|^2,$$

т.е.

$$d(X, C)^2 \leq 4\lambda^2 + (1 - \lambda)d(X', C_{\varepsilon_n})^2 + \lambda d(X', C_{-\varepsilon_n})^2.$$

2.5 Условни очаквания

Нека

$$p_+ := \mathbb{P}(X' \in C_{+1}), \quad p_- := \mathbb{P}(X' \in C_{-1}),$$

като БОО да приемем, че $p_+ \geq p_-$.

1. Покажете, че $p_- > 0$.
2. Докажете, че за всяко $\lambda \in [0, 1]$

$$\mathbb{E} \left[\exp \left(\frac{1}{8} d(X, C)^2 \right) \mid \varepsilon_n = -1 \right] \leq \exp \left(\frac{\lambda^2}{2} \right) \mathbb{E} \left[\left(\exp \left(\frac{1}{8} d(X', C_{-1})^2 \right) \right)^{1-\lambda} \left(\exp \left(\frac{1}{8} d(X', C_{+1})^2 \right) \right)^\lambda \right].$$

3. Заключете, че

$$\mathbb{E} \left[\exp \left(\frac{1}{8} d(X, C)^2 \right) \mid \varepsilon_n = -1 \right] \leq \exp \left(\frac{\lambda^2}{2} \right) \mathbb{E} \left[\exp \left(\frac{1}{8} d(X', C_{-1})^2 \right) \right]^{1-\lambda} \mathbb{E} \left[\exp \left(\frac{1}{8} d(X', C_{+1})^2 \right) \right]^\lambda.$$

4. Използвайки индукционното предположение, обосновайте, че

$$\mathbb{E} \left[\exp \left(\frac{1}{8} d(X, C)^2 \right) \mid \varepsilon_n = 1 \right] \leq \frac{1}{p_+}.$$

и след това, че за всяко $\lambda \in [0, 1]$

$$\mathbb{E} \left[\exp \left(\frac{1}{8} d(X, C)^2 \right) \right] \leq \frac{1}{2} \left(\frac{1}{p_+} + \exp \left(\frac{\lambda^2}{2} \right) \frac{1}{(p_-)^{1-\lambda}} \frac{1}{(p_+)^{\lambda}} \right).$$

2.6 Оптимизация

1. Нека $\lambda = 1 - \frac{p_-}{p_+}$. Покажете, че

$$\mathbb{E} \left[\exp \left(\frac{1}{8} d(X, C)^2 \right) \right] \leq \frac{1}{2p_+} \left(1 + \exp \left(\frac{\lambda^2}{2} \right) (1 - \lambda)^{\lambda-1} \right).$$

2. Докажете, че за всяко $x \in [0, 1]$

$$\frac{x^2}{2} + (x - 1) \ln(1 - x) \leq \ln(2 + x) - \ln(2 - x).$$

3. Изведете, че за всяко $x \in [0, 1]$

$$1 + \exp \left(\frac{x^2}{2} \right) (1 - x)^{x-1} \leq \frac{4}{2 - x}.$$

4. Заключете доказателството на неравенството (1).
5. Докажете неравенството на Талагранд:

за всяко непразно затворено изпъкнало $C \subset E$ и за всяко $t > 0$

$$\mathbb{P}(X \in C) \mathbb{P}(d(X, C) \geq t) \leq \exp \left(-\frac{t^2}{8} \right). \quad (2)$$

3 Теорема на Johnson–Lindenstrauss

В тази част разглеждаме

$$E = \mathcal{M}_{k,d}(\mathbb{R}),$$

снабдено със скаларното произведение $\langle A, B \rangle_F := \text{tr}(A^T B)$ и породената от него норма (позната и като Фробениусова) $\|\cdot\|_F$. За удобство ще идентифицираме $\mathbb{R}^d$ с $\mathcal{M}_{d,1}(\mathbb{R})$, така че всеки вектор $x \in \mathbb{R}^d$ да бъде разглеждан и като матрица от една колона. Нека $u \in \mathbb{R}^d$, $\|u\| = 1$, и дефинираме

$$g(M) := \|Mu\|, \quad M \in \mathcal{M}_{k,d}(\mathbb{R}).$$

Нека

$$X = (\varepsilon_{ij})_{1 \leq i \leq k, 1 \leq j \leq d}$$

е случайна величина със стойности в $\mathcal{M}_{k,d}(\mathbb{R})$, чиито елементи ε_{ij} са независими Rademacher величини.

3.1 Неравенение за концентрация

1. Покажете, че

$$C = \{M \mid g(M) \leq r\}$$

е изпъкнало и затворено подмножество на $\mathcal{M}_{k,d}(\mathbb{R})$.

2. Докажете, че за всяка матрица M е изпълнено, че

$$\|Mu\| \leq \|M\|_F.$$

3. Нека $r, t \in \mathbb{R}$ с $t > 0$. Покажете, че ако $d(M, C) < t$, то $g(M) < r + t$.

4. Заключете, че

$$\mathbb{P}(g(X) \leq r) \mathbb{P}(g(X) \geq r + t) \leq \exp\left(-\frac{t^2}{8}\right).$$

3.2 Медиани

1. Обосновете, че $g(X)$ има поне една медиана.

2. Докажете, че за всяко $t > 0$

$$\mathbb{P}(|g(X) - m| \geq t) \leq 4 \exp\left(-\frac{t^2}{8}\right),$$

както и че

$$\mathbb{E}[(g(X) - m)^2] \leq 32.$$

3. Покажете, че $\mathbb{E}[g(X)^2] = k$ и $\mathbb{E}[g(X)] \leq \sqrt{k}$.

4. Заключете, че

$$(\sqrt{k} - m)^2 \leq \mathbb{E}[(g(X) - m)^2].$$

3.3 Ключова лема

1. Покажете, че за всеки $t > 0$

$$\mathbb{P}(|g(X) - \sqrt{k}| \geq t) \leq 4 \exp(4) \exp\left(-\frac{t^2}{16}\right).$$

2. Да дефинираме $A_k = X/\sqrt{k}$ и нека $\varepsilon \in (0, 1)$, $\delta \in (0, \frac{1}{2})$, с

$$k \geq \frac{160 \ln(1/\delta)}{\varepsilon^2}.$$

Докажете, че за всеки вектор u с единична норма

$$\mathbb{P}(|\|A_k u\| - 1| > \varepsilon) < \delta.$$

3.4 Заключение

Нека $v_1, \dots, v_N$ са различни вектори в $\mathbb{R}^d$. За $(i, j) \in [1, N]^2$ и $i < j$, да дефинираме

$$E_{ij} := ((1 - \varepsilon) \|v_i - v_j\| \leq \|A_k v_i - A_k v_j\| \leq (1 + \varepsilon) \|v_i - v_j\|).$$

1. Покажете, че $\mathbb{P}(E_{ij}^c) < \delta$, където $E_{ij}^c := \Omega \setminus E_{ij}$.
2. Изведете, че

$$\mathbb{P} \left(\bigcap_{i < j} E_{ij} \right) \geq 1 - \frac{N(N-1)}{2} \delta.$$

3. Докажете теоремата на Johnson–Lindenstrauss.