Лекция 1

1) През 1827 г. Р. Браун наблюдава движението на частици от цветен прашец във вода в покой. Те извършват хаотично движение. Защо? Айнщайн (1905 г.) обяснява това движение чрез кинетичната теория на молекулите. То се нарича Брауново движение и служи като модел на редица физически процеси. Изследването му допринася и за експерименталното определяне на числото на Авогадро. За своите изследвания върху молекулната структура на материята Жан Перен получава Нобеловата награда за физика през 1926 г.↗

2) На 06.09.2009 г. в тираж на „6/49“ се падат същите числа като в предходния тираж. Разбира се, това моментално води до съмнения за честността на играта. Редки ли са такива повторения в действителност?

   Бел.: Този казус е дискутиран в книга на автори от Imperial College London.

3) През 1958 г. акад. Сендов формулира хипотезата на Сендов, която гласи, че ако всички нули на полином P от степен поне две са в диска $|z| \leq 1$, то за всяка негова нула a съществува нула b на P' с $|a-b| \leq 1$.

   Макар проблемът да е изцяло детерминистичен, Т. Тао доказва хипотезата за полиноми с достатъчно висока степен↗, използвайки идеи от теорията на потенциала, свързани с Брауновото движение! Това доказателство е много по-красиво и идейно от пълното решение на хипотезата↗, получено с помощта на ИИ през лятото на 2026 г.

Във всички тези разнородни примери основна роля играе теорията на вероятностите! За да навлезем в нея, ние трябва да я формализираме и поставим на математическа основа.

Дефиниция. *Случаен експеримент* наричаме опит, чийто резултат не може да бъде предопределен еднозначно. Резултатът от него наричаме *елементарно събитие* и бележим с ω.

Дефиниция. Множеството от всички елементарни събития наричаме Ω.

Примери за пространства от елементарни събития

⊕ $\Omega = \{\text{ези}, \text{тура}\}$ — хвърляне на монета.
$\Omega = \{0, 1\}$ — мъж/жена, клиент в магазин.

⊕ $\Omega = \{1, 2, 3, 4, 5, 6\}$ — зар; $\omega = 5$, ако се е паднало 5.

⊕ $\Omega = \{\omega : [0, \infty) \to \mathbb{R} : \ \omega \text{ е непрекъсната}, \ \omega(0) = 0\}$.



⊕ $N = 13\,983\,816 = \binom{49}{6}$ — брой шесторки в „6/49“.

$$\Omega = \{\omega_1, \ldots, \omega_N\}, \qquad \omega_1 = \{1, 2, 3, 4, 5, 6\}.$$

⊕ Пространство на историята от 10001 тиража на „6/49“:

$$\Omega_i = \{\omega_1, \ldots, \omega_N\}, \qquad N = 13\,983\,816,$$

$$\Omega = \prod_{i=1}^{10001} \Omega_i = \{\omega = (\omega^{(1)}, \ldots, \omega^{(10001)}) : \omega^{(i)} \in \Omega_i\}.$$

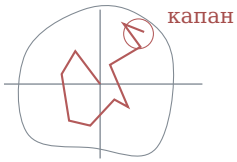
⊕ $\Omega = \mathbb{R}^+ = [0, \infty)$ — време на живот на CPU.

Дефиниция. За крайно множество A бележим с $|A|$ неговата кардиналност.

Дефиниция. На този етап наричаме *събитие* всяко $A \subseteq \Omega$. След като изберем σ-алгебра $\mathcal{A}$, ще разглеждаме като събития само множествата $A \in \mathcal{A}$.

Събитията обикновено са съвкупности от елементарни събития, отделени по някакъв признак.

Примери за събития

- $\Omega = \mathbb{R}_+$, $A = (a, b) \subseteq \mathbb{R}_+$ — елементарният изход е времето на живот, а събитието е това време да бъде между a и b.
- $A = \{1, 3, 5\} \subseteq \{1, 2, 3, 4, 5, 6\}$ — пада се нечетно число.
- Ако ω_i е определена шесторка, то $\{\omega_i\}$ е събитие.
- 

$A = \{$всички функции от Ω, които рано или късно попадат в капана$\}$.

Операции с множества

За $A, B \subseteq \Omega$ имаме

$$A \subseteq B \iff \forall \omega \in A : \ \omega \in B.$$

Освен това

$$A = B \iff A \subseteq B \text{ и } B \subseteq A.$$

Дефиниция. За $A, B \subseteq \Omega$ тяхното *обединение* (сума) е

$$A \cup B = \{\omega \in \Omega : \ \omega \in A \textbf{ или } \omega \in B\}.$$

Ако имаме две събития, различени по даден признак, то $A \cup B$ се състои от елементарните събития, които притежават поне един от тези признаци.

Дефиниция. За $A, B \subseteq \Omega$ тяхното *сечение* (произведение) е

$$A \cap B = \{\omega \in \Omega : \ \omega \in A \textbf{ и } \omega \in B\}.$$

$A \cap B$ са всички елементарни събития, които притежават и двата признака.

Дефиниция. *Допълнението* на $A \subseteq \Omega$ е

$$A^c = \Omega \setminus A = \{\omega \in \Omega : \ \omega \notin A\}.$$

A^c са всички елементарни събития, които *не* притежават признака на A.

Операции и тъждества

За $A, B, C \subseteq \Omega$:

а) **Комутативност:**

$$A \cup B = B \cup A, \qquad A \cap B = B \cap A.$$

б) **Асоциативност:**

$$A \cup (B \cup C) = (A \cup B) \cup C, \qquad A \cap (B \cap C) = (A \cap B) \cap C.$$

в) **Дистрибутивност:**

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C),$$
$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$

г) **Закони на Де Морган:**

$$\left(\bigcup_i A_i\right)^c = \bigcap_i A_i^c, \qquad \left(\bigcap_i A_i\right)^c = \bigcup_i A_i^c.$$

При изброима фамилия $(A_i)_{i\geq 1}$:

$$\bigcup_{i=1}^{\infty} A_i = \{\omega \in \Omega : \ \omega \in A_i \text{ за някое } i\},$$

$$\bigcap_{i=1}^{\infty} A_i = \{\omega \in \Omega : \ \omega \in A_i \text{ за всяко } i\}.$$

Бел.: Обединението и сечението се дефинират и за произволни фамилии множества. Изброимостта е съществена за дефиницията на σ-алгебра.

σ-алгебра

Дефиниция. Нека Ω е множество от елементарни събития и $\mathcal{A}$ е колекция от подмножества на Ω. Наричаме $\mathcal{A}$ *σ-алгебра*, ако

1) $\varnothing \in \mathcal{A}$;
2) ако $A \in \mathcal{A}$, то $A^c \in \mathcal{A}$;
3) ако $A_i \in \mathcal{A}$ за всяко $i \geq 1$, то $\bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$.

Бел.: От дефиницията следва и затвореността относно крайни обединения. Действително, за $A_1, \ldots, A_n \in \mathcal{A}$ е достатъчно да положим $A_i = \varnothing$ за $i > n$ и да приложим свойство 3.

Следствие. Ако $\mathcal{A}$ е σ-алгебра, то

$$\Omega \in \mathcal{A} \qquad \text{и} \qquad \bigcap_{i=1}^{\infty} A_i \in \mathcal{A} \quad \text{за } A_i \in \mathcal{A}.$$

Примери

⊕ За $\Omega = \{0, 1\}$ имаме две σ-алгебри

$$\mathcal{A}_1 = \{\Omega, \varnothing\}, \qquad \mathcal{A}_2 = \{\varnothing, \Omega, \{0\}, \{1\}\} = 2^{\Omega}.$$

⊕ За $\Omega = \{1, 2, \ldots, n\}$ фамилията $\mathcal{A} = 2^{\Omega}$ е множеството на всички подмножества на Ω.

$$|\Omega| = n, \qquad |2^{\Omega}| = 2^n.$$

Пример. Ако $\Omega = \{\omega_1, \ldots, \omega_N\}$, където $N = 13\,983\,816$, то

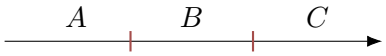
$$\mathcal{A} = 2^{\Omega}, \qquad |\mathcal{A}| = 2^N.$$

Дефиниция. Ако G е произволна съвкупност от подмножества на Ω, то $\sigma(G)$ е *най-малката σ-алгебра*, съдържаща G.

$$G \subseteq 2^{\Omega}.$$

Примери

⊕ За $\Omega = \mathbb{R}$:



$\mathcal{A}_1 = \mathcal{B}(\mathbb{R})$ — най-малката σ-алгебра, съдържаща всички интервали. Например

$$\{x\} = \bigcap_{i=1}^{\infty} \left(x - \frac{1}{i},\, x + \frac{1}{i}\right), \qquad (0,1] = \bigcup_{n=1}^{\infty} \left[\frac{1}{n}, 1\right] \in \mathcal{B}(\mathbb{R}).$$

Нека A, B, C са борелови множества, образуващи разбиване на реалната права:

$$\mathcal{A}_2 = \{\mathbb{R}, \varnothing, A, B, C, A \cup B, A \cup C, B \cup C\} \subseteq \mathcal{B}(\mathbb{R}) = \mathcal{A}_1.$$

⊕ 

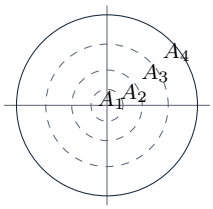
$\Omega = \{$всички непрекъснати функции ω с $\omega(0) = 0\}$.
$A = ?$ — не е съвсем ясно!

Атоми на σ-алгебра

Дефиниция. $A \in \mathcal{A}$ е *атом* на $\mathcal{A}$, ако $A \neq \varnothing$ и от $B \in \mathcal{A}$, $B \subseteq A$ следва $B \in \{\varnothing, A\}$.
Нека

$$\Omega = \{(x, y) \in \mathbb{R}^2 :\ x^2 + y^2 \leq 1\},$$

а $\mathcal{U} = \{A_1, A_2, A_3, A_4\}$ е разбиване на диска на четири части, както е показано на фигурата:



Породената σ-алгебра е

$$\mathcal{A} = \sigma(\mathcal{U}) = \left\{ \bigcup_{i \in I} A_i :\ I \subseteq \{1,2,3,4\} \right\}.$$

Последователни тиражи на „6/49“

Пример. Разглеждаме $10\,001$ тиража на „6/49“. Нека

$$\Omega_i = \{\omega_1, \ldots, \omega_N\}, \qquad \Omega = \prod_{i=1}^{10001} \Omega_i = \left\{\omega = (\omega^{(1)}, \ldots, \omega^{(10001)}) : \omega^{(i)} \in \Omega_i\right\}.$$

Събитието „два последователни тиража дават едни и същи числа“ е

$$A = \bigcup_{i=1}^{10000} A_i, \qquad A_i = \{\omega \in \Omega :\ \omega^{(i)} = \omega^{(i+1)}\}.$$

Лекция 2

Вероятност (вероятностна функция)

Дефиниция. Нека $\mathcal{A}$ е σ-алгебра над Ω. Функцията $\mathbb{P} : \mathcal{A} \to [0,1]$ се нарича *вероятност (вероятностна функция)*, ако:

1) $\mathbb{P}(\Omega) = 1$;
2) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ за всяко $A \in \mathcal{A}$;
3) за всяка редица $(A_i)_{i\geq 1}$ от взаимно непресичащи се събития, т.е. $A_i \cap A_j = \varnothing$ при $i \neq j$, е изпълнено
$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i).$$

Последното свойство се нарича *σ-адитивност*. Вероятността е мярка, подобно на теглото, дължината и обема.

За $A, B \subseteq \Omega$ използваме разликата на множества $A \setminus B = A \cap B^c$.

Основни свойства на вероятността

Теорема (следствие от аксиомите). Нека $\mathbb{P} : \mathcal{A} \to [0,1]$ е вероятност и $A, B \in \mathcal{A}$. Тогава:

а) $\mathbb{P}(\varnothing) = 0$;

б) *Разлагане по A:*
$$\mathbb{P}(B) = \mathbb{P}(A \cap B) + \mathbb{P}(A^c \cap B);$$

в) *Монотонност:* ако $A \subseteq B$, то $\mathbb{P}(A) \leq \mathbb{P}(B)$;

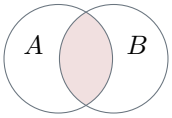
г) *Формула за обединение:*
$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B);$$

д) *Изброима субадитивност:* за произволни $A_i \in \mathcal{A}$,
$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} \mathbb{P}(A_i);$$

е) *Непрекъснатост:* ако $A_n \in \mathcal{A}, n \geq 1$, и $A_1 \supseteq A_2 \supseteq \cdots$, то
$$\mathbb{P}\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} \mathbb{P}(A_n).$$

Доказателство. За а) получаваме
$$\mathbb{P}(\varnothing) = 1 - \mathbb{P}(\varnothing^c) = 1 - \mathbb{P}(\Omega) = 0.$$

За б) разлагаме B на две непресичащи се части:
$$B = (A \cap B) \dot{\cup} (A^c \cap B).$$

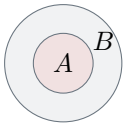


Следователно от адитивността

$$\mathbb{P}(B) = \mathbb{P}(A \cap B) + \mathbb{P}(A^c \cap B).$$

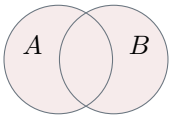
За в), ако $A \subseteq B$, то $B = A \dot\cup (B \cap A^c)$ и

$$\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \cap A^c) \geq \mathbb{P}(A).$$



За г) използваме разлагането на три непресичащи се части

$$A \cup B = (A \cap B^c) \dot\cup (A \cap B) \dot\cup (A^c \cap B).$$



Следователно

$$\begin{aligned}\mathbb{P}(A \cup B) &= \mathbb{P}(A \cap B^c) + \mathbb{P}(A \cap B) + \mathbb{P}(A^c \cap B) \\ &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).\end{aligned}$$

В частност $\mathbb{P}(A \cup B) \leq \mathbb{P}(A) + \mathbb{P}(B)$. За краен брой събития това дава по индукция

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) \leq \sum_{i=1}^{n} \mathbb{P}(A_i).$$

За д), когато множествата A_i не са непременно непресичащи се, ги заменяме с

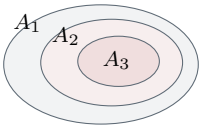
$$C_1 = A_1, \qquad C_i = A_i \setminus \bigcup_{j=1}^{i-1} A_j, \quad i \geq 2.$$

Тогава $C_i \subseteq A_i$, събитията $(C_i)_{i\geq 1}$ са взаимно непресичащи се и $\bigcup_{i\geq 1} C_i = \bigcup_{i\geq 1} A_i$. По σ-адитивност и монотонност получаваме

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(C_i) \leq \sum_{i=1}^{\infty} \mathbb{P}(A_i).$$

За е) полагаме $D_i = A_i \setminus A_{i+1}$. Тогава D_i са взаимно непресичащи се и

$$A_1 = \left(\bigcap_{n=1}^{\infty} A_n\right) \dot\cup \bigcup_{i=1}^{\infty} D_i.$$



Също така $\mathbb{P}(A_n) = \mathbb{P}(A_1) - \sum_{i=1}^{n-1} \mathbb{P}(D_i)$, откъдето след преминаване към границата следва твърдението. □

Примери

Дискретна вероятност

⊕ Нека $\Omega = \{0, 1\}$ и $\mathcal{A} = 2^\Omega$. За $p \in [0, 1]$ полагаме

$$\mathbb{P}(\{0\}) := p, \qquad \mathbb{P}(\{1\}) := 1 - p \text{ и } \mathbb{P}(\{\Omega\}) := 1.$$

Тогава $\mathcal{A} = \{\varnothing, \Omega, \{0\}, \{1\}\}$ и $\mathbb{P}$ е вероятност върху $\mathcal{A}$.

⊕ Нека $\Omega = \{\omega_1, \ldots, \omega_N\}$, $\mathcal{A} = 2^\Omega$ и $p_1, \ldots, p_N$ са числа, за които

$$p_i \geq 0, \qquad \sum_{i=1}^{N} p_i = 1.$$

Тогава

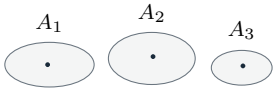
$$\mathbb{P}(A) := \sum_{\omega_i \in A} p_i, \qquad A \in \mathcal{A},$$

задава вероятност. Наистина:

$$\mathbb{P}(\Omega) = \sum_{i=1}^{N} p_i = 1,$$
$$\mathbb{P}(A^c) = \sum_{\omega_i \notin A} p_i = 1 - \sum_{\omega_i \in A} p_i = 1 - \mathbb{P}(A).$$

Ако $A_1, \ldots, A_k$ са взаимно непресичащи се, то

$$\mathbb{P}\left(\bigcup_{\ell=1}^{k} A_\ell\right) = \sum_{\omega_i \in \cup_{\ell=1}^{k} A_\ell} p_i = \sum_{\ell=1}^{k} \sum_{\omega_i \in A_\ell} p_i = \sum_{\ell=1}^{k} \mathbb{P}(A_\ell).$$



⊕ Ако $p_i = 1/N$, $1 \leq i \leq N$, то

$$\mathbb{P}(A) = \frac{|A|}{N}, \qquad A \subseteq \Omega.$$

Това се нарича *равномерна вероятност* върху Ω.

Пример. За играта „6/49“ броят на възможните шесторки е $N = \binom{49}{6} = 13\,983\,816$. Ако те са равновероятни, то

$$\mathbb{P}(\{\omega_i\}) = \frac{1}{13\,983\,816}, \qquad \mathbb{P}(A) = \frac{|A|}{13\,983\,816}, \quad A \subseteq \Omega.$$

Пример. Нека $\Omega = \{1, 2, \ldots, N\}$, но се интересуваме само дали резултатът е четен или нечетен. Разглеждаме

$$A = \{i \leq N : i \text{ е четно}\}, \qquad B = A^c = \{i \leq N : i \text{ е нечетно}\}.$$

Тогава може да използваме по-малката σ-алгебра

$$\mathcal{A} = \{\varnothing, \Omega, A, B\}, \quad \mathbb{P}(A) = \frac{|A|}{N}, \quad \mathbb{P}(B) = \frac{N - |A|}{N}.$$

Еквивалентен е на бинарен модел $\Omega = \{0, 1\}$.

⊕ Нека $\Omega = \{\omega_1, \omega_2, \ldots\}$ е изброимо безкрайно множество и $\mathcal{A} = 2^\Omega$. Ако

$$p_i \geq 0 \quad (i \geq 1), \qquad \sum_{i=1}^{\infty} p_i = 1,$$

то

$$\mathbb{P}(A) := \sum_{\omega_i \in A} p_i$$

задава(проверете) вероятност върху $\mathcal{A}$.

Примери за вероятности върху изброимо множество:

- За $p_i = \dfrac{6}{\pi^2 i^2}$, $i \geq 1$, получаваме ли вероятност?
- $p_i = qp^i$, $i \geq 0$, при $0 < p < 1$ и $q = 1 - p$ (геометрично разпределение върху $\{0, 1, 2, \ldots\}$).

Бел.: Върху изброимо безкрайно множество не съществува равномерна вероятност, при която всяка точка има една и съща вероятност.

Геометрична вероятност

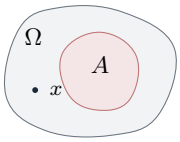
Нека $\Omega \subseteq \mathbb{R}^d$ е Борелово множество с $0 < \mathrm{Vol}_d(\Omega) < \infty$. С $|A|$ ще означаваме $\mathrm{Vol}_d(A)$, т.е.

$$|A| := \int_A \mathrm{d}x.$$

За $\mathcal{A} = \mathcal{B}(\Omega)$ поставяме

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|}, \qquad A \in \mathcal{A}.$$

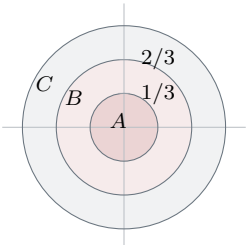
Тази вероятност е *равномерна* в смисъл, че $\mathbb{P}(A)$ зависи само от обема на A, а не от формата или положението му. Две събития A и B с еднакви обеми са равновероятни.



Тук Ω е неизброимо множество; за всяко $x \in \Omega$ имаме $\mathbb{P}(\{x\}) = 0$.

Пример. Нека $\Omega = \{(x, y) \in \mathbb{R}^2 : x^2 + y^2 \leq 1\}$ е единичният диск. Нека

$$A = \{(x, y) \in \Omega : x^2 + y^2 \leq 1/9\},$$
$$B = \{(x, y) \in \Omega : 1/9 < x^2 + y^2 < 4/9\},$$
$$C = \{(x, y) \in \Omega : x^2 + y^2 \geq 4/9\}.$$



Тогава

$$\mathbb{P}(A) = \frac{1}{9}, \qquad \mathbb{P}(B) = \frac{4}{9} - \frac{1}{9} = \frac{1}{3}, \qquad \mathbb{P}(C) = 1 - \frac{4}{9} = \frac{5}{9}.$$

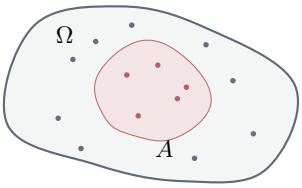
Вероятностно пространство

Дефиниция. Нека Ω е множество от елементарни събития, $\mathcal{A} \subseteq 2^{\Omega}$ е σ-алгебра и $\mathbb{P} : \mathcal{A} \to [0,1]$ е вероятност. Тройката $(\Omega, \mathcal{A}, \mathbb{P})$ се нарича *вероятностно пространство*.

Примери

- За $\Omega = \{1, 2, \ldots, N\}$, $\mathcal{A} = 2^{\Omega}$ и равномерната вероятност $\mathbb{P}(A) = |A|/N$, тройката $(\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство.
- В примера с единичния диск може да изберем и по-малката σ-алгебра, породена от A, B, C:
$$\mathcal{A} = \{\varnothing, \Omega, A, B, C, A \cup B, A \cup C, B \cup C\}.$$
Със същите вероятности за A, B, C, зададени чрез площите им, $(\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство.
- Нека $\Omega \subseteq \mathbb{R}^d$ е Борелово и $0 < |\Omega| < \infty$. Тогава
$$(\Omega, \mathcal{B}(\Omega), \mathbb{P}), \qquad \mathbb{P}(D) = \frac{|D|}{|\Omega|}, \quad D \in \mathcal{B}(\Omega),$$
е вероятностно пространство.

Метод Монте Карло за намиране на обем



Ако хвърлим независимо и равномерно n точки в Ω, като N_A е броят на попадналите в A, то относителната честота приближава вероятността на събитието:

$$\mathbb{P}(A) \approx \frac{N_A}{n} = \frac{\text{брой попадения в } A}{\text{брой хвърляния}}.$$

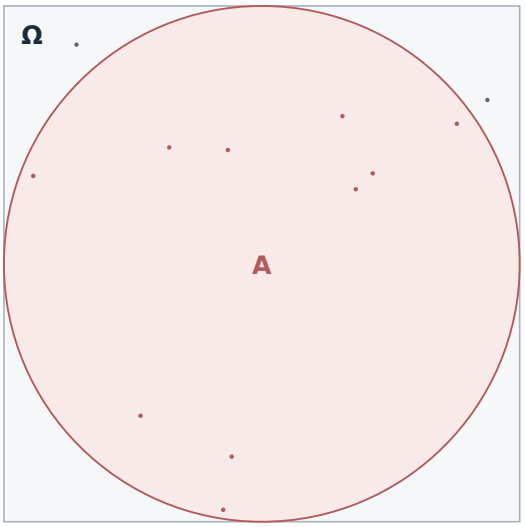
Следователно можем да приближим обема на A чрез

$$|A| \approx |\Omega| \, \frac{N_A}{n}.$$

Демонстрация: метод Монте Карло

В този пример точките са равномерно разпределени в квадрата $\Omega = [-1, 1]^2$. Нека $A = \{(x, y) \in \Omega : x^2 + y^2 \leq 1\}$ е единичният диск. Тогава $\mathbb{P}(A) = \pi/4$ и получаваме оценката

$$\widehat{\pi}_n = 4\,\frac{N_A}{n} \longrightarrow \pi \qquad \text{почти сигурно при } n \to \infty.$$



Метод Монте Карло

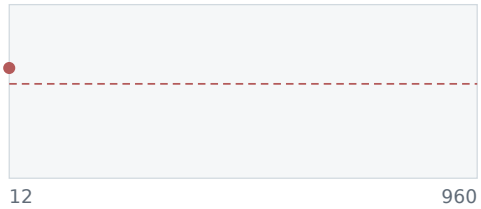
n = 12

N_A = 10

N_A/n = 0.8333

π ≈ 3.3333

Точна стойност: π = 3.14159...



Бел.: Бутоните под фигурата управляват анимацията. Тя показва 960 предварително генерирани независими точки за около 20 секунди. За възпроизвеждане в PDF е необходим съвместим PDF четец, например настолният Adobe Acrobat Reader с разрешен JavaScript.

Лекция 3

Условна вероятност

Нека $(\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство и $A \in \mathcal{A}$, $\mathbb{P}(A) > 0$. Ако знаем, че A се е сбъднало, как да пресметнем вероятността да се сбъдне и събитието B? С други думи, как новата информация променя вероятността на B?

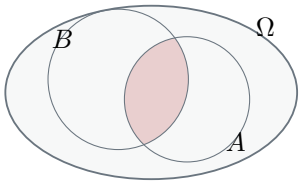
Дефиниция. Нека $(\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство и $A \in \mathcal{A}$, $\mathbb{P}(A) > 0$. *Условна вероятност* при условие A наричаме функцията

$$\mathbb{P}_A(B) = \mathbb{P}(B \mid A) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}, \qquad B \in \mathcal{A}.$$

След като приемем, че A е настъпило, можем да разглеждаме новото вероятностно пространство

$$\big(A, \mathcal{A}_A, \mathbb{P}_A\big), \qquad \mathcal{A}_A = \{A \cap B : B \in \mathcal{A}\}.$$

Тук $\mathbb{P}_A$ е ограничението на условната вероятност върху $\mathcal{A}_A$ (или същата функция, разглеждана върху $\mathcal{A}$).



⊕ **Играта „6/49“.** Нека Ω е множеството на всички шесторки от $\{1, \ldots, 49\}$. Приемаме, че те са равновероятни. Знаем, че числата 1 и 2 са се паднали. Каква е вероятността да е изтеглена точно шесторката $\omega_1 = \{1, 2, 3, 4, 5, 6\}$?

Полагаме $A = \{\omega \in \Omega : 1, 2 \in \omega\}$ и $B = \{\omega_1\}$. Тогава

$$\mathbb{P}(A) = \frac{\binom{47}{4}}{\binom{49}{6}}, \qquad \mathbb{P}(B) = \frac{1}{\binom{49}{6}}, \qquad B \subseteq A,$$

откъдето

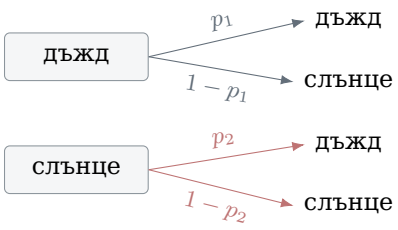
$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(B)}{\mathbb{P}(A)} = \frac{1}{\binom{47}{4}} = \frac{1}{178\,365}.$$

⊕ **Примитивен модел за прогноза на времето.** Разглеждаме два последователни дни, за всеки от които е възможно да вали дъжд или да бъде слънчево. Нека

$$\mathbb{P}(\text{дъжд утре} \mid \text{дъжд днес}) = p_1,$$
$$\mathbb{P}(\text{дъжд утре} \mid \text{слънце днес}) = p_2.$$

Вероятностите за слънце утре са съответно $1 - p_1$ и $1 - p_2$. За двата дни можем да вземем

$$\Omega = \Omega_1 \times \Omega_2, \qquad \Omega_1 = \Omega_2 = \{\text{дъжд}, \text{слънце}\}.$$



⊕ **Избори.**

Има две партии, с общо N_1 и N_2 гласоподаватели. Сред тях младите избиратели са съответно m_1 и m_2.

	общо	млади
1	N_1	m_1
2	N_2	m_2

Нека A означава „избирателят е млад“, а B — „гласувал е за партия 1“. При равномерно избран избирател

$$\mathbb{P}(B \mid A) = \frac{m_1/(N_1+N_2)}{(m_1+m_2)/(N_1+N_2)} = \frac{m_1}{m_1+m_2}.$$

Тази вероятност зависи само от младите хора и може да е много различна от $\mathbb{P}(B) = N_1/(N_1+N_2)$.

Независимост

Дефиниция. Две събития $A, B \in \mathcal{A}$ се наричат *независими* ($A \perp\!\!\!\perp B$), ако

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\,\mathbb{P}(B).$$

Ако $\mathbb{P}(A) > 0$, това е еквивалентно на $\mathbb{P}(B \mid A) = \mathbb{P}(B)$: информацията, че A е настъпило, не променя вероятността на B.

Пример. Ако $\mathbb{P}(A) = 0$, то $\mathbb{P}(A \cap B) = 0$ за всяко $B \in \mathcal{A}$. Следователно A е независимо от всяко събитие (въпреки че $\mathbb{P}(B \mid A)$ не е дефинирана).

Дефиниция. Събитията $A_1, \ldots, A_n \in \mathcal{A}$ са *взаимно независими*, ако за всяко непразно $I \subseteq \{1, \ldots, n\}$

$$\mathbb{P}\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} \mathbb{P}(A_i).$$

Теорема. (Формула за последователни условни вероятности.) Нека $A_1, \ldots, A_n \in \mathcal{A}$ и $\mathbb{P}\left(\bigcap_{i=1}^{n-1} A_i\right) > 0$. Тогава

$$\mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right) = \mathbb{P}(A_1)\,\mathbb{P}(A_2 \mid A_1)\,\mathbb{P}(A_3 \mid A_1 \cap A_2) \cdots \mathbb{P}\left(A_n \mid \bigcap_{i=1}^{n-1} A_i\right).$$

Доказателство. За $n = 2$ формулата следва непосредствено от дефиницията. При $n > 2$ полагаме $B_k = \bigcap_{i=1}^{k} A_i$ и записваме

$$\mathbb{P}(B_n) = \mathbb{P}(A_n \mid B_{n-1})\,\mathbb{P}(B_{n-1}).$$

Повтаряме същата стъпка за $B_{n-1}, \ldots, B_2$, докато стигнем до $\mathbb{P}(A_1)$. □

⊕ **Повторения в „6/49“.** Нека се проведат $10\,001$ независими тиража, всички с равномерно разпределени шесторки. Пишем

$$\Omega = \prod_{i=1}^{10001} \Omega_i, \qquad \Omega_i = \{\omega_1, \ldots, \omega_N\}, \quad N = \binom{49}{6} = 13\,983\,816.$$

Всяка точно зададена редица от тиражи има вероятност N^{-10001}. Нека

$$A_i = \{\omega \in \Omega : \omega^{(i)} = \omega^{(i+1)}\}, \quad 1 \le i \le 10000, \qquad A = \bigcup_{i=1}^{10000} A_i.$$

Събитието A означава, че поне два последователни тиража са дали една и съща шесторка. Проверете, че $A_1, \ldots, A_{10000}$ са взаимно независими и $\mathbb{P}(A_i) = 1/N$. Следователно

$$\begin{aligned}\mathbb{P}(A) &= 1 - \mathbb{P}\left(\bigcap_{i=1}^{10000} A_i^c\right) = 1 - \prod_{i=1}^{10000} \mathbb{P}(A_i^c) \\ &= 1 - \left(1 - \frac{1}{N}\right)^{10000} \approx \frac{10000}{13\,983\,816} \approx \frac{1}{1400}.\end{aligned}$$

Вероятността е малка, но не е от фрапиращо малък порядък, особено ако се имат предвид многото провеждани лотарийни игри.

Формула за пълната вероятност

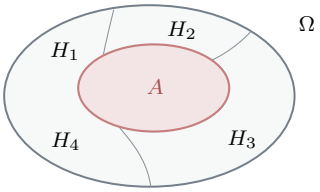
Често е удобно пространството Ω да бъде разбито на подмножества $H_1, H_2, \ldots$. Например може да знаем вероятностите $\mathbb{P}(H_j)$ и да пресмятаме $\mathbb{P}(A \mid H_j)$ за всяка от възможните хипотези.

Дефиниция. Събитията $H_1, H_2, \ldots \in \mathcal{A}$ образуват *пълна група от събития*, ако са две по две непресичащи се и

$$\bigcup_j H_j = \Omega, \qquad H_i \cap H_j = \varnothing \quad (i \neq j).$$

Теорема (формула за пълната вероятност). Нека (H_j) е крайна или изброима пълна група от събития. Тогава за всяко $A \in \mathcal{A}$

$$\mathbb{P}(A) = \sum_j \mathbb{P}(H_j)\,\mathbb{P}(A \mid H_j)\,.$$



При $\mathbb{P}(H_j) = 0$ съответният член на сумата е 0.

Доказателство. Поради пълнотата на групата

$$A = A \cap \Omega = A \cap \bigcup_j H_j = \dot{\bigcup_j}(A \cap H_j).$$

По σ-адитивност и по дефиницията на условната вероятност

$$\mathbb{P}(A) = \sum_j \mathbb{P}(A \cap H_j) = \sum_j \mathbb{P}(H_j)\,\mathbb{P}(A \mid H_j)\,. \qquad \square$$

Бел.: Информацията за вероятностите на хипотезите и за условните вероятности при всяка хипотеза позволява да се възстанови безусловната вероятност.

⊕ **Още един пример с тиражи.** Нека $N = 13\,983\,816$ и се проведат три независими тиража. За $j = 1, \ldots, N$ полагаме $H_j = \{\omega^{(1)} = \omega_j\}$; тогава $(H_j)_{j=1}^N$ е пълна група от събития.

Да означим с A събитието, че вторият и третият тираж са различни от първия (но не непременно един от друг):

$$A = \{\omega^{(2)} \neq \omega^{(1)},\ \omega^{(3)} \neq \omega^{(1)}\}.$$

По формулата за пълната вероятност

$$\begin{aligned}
\mathbb{P}(A) &= \sum_{j=1}^{N} \mathbb{P}(H_j)\,\mathbb{P}(A \mid H_j) \\
&= \sum_{j=1}^{N} \frac{1}{N} \mathbb{P}\left(\omega^{(2)} \neq \omega_j\right) \mathbb{P}\left(\omega^{(3)} \neq \omega_j\right) \\
&= \sum_{j=1}^{N} \frac{1}{N} \left(\frac{N-1}{N}\right)^2 = \left(\frac{N-1}{N}\right)^2.
\end{aligned}$$

Формула на Бейс

Теорема (Бейс). Нека (H_j) е крайна или изброима пълна група от събития и $A \in \mathcal{A}$ е такова, че $\mathbb{P}(A) > 0$. Тогава за всяко k с конвенцията $\mathbb{P}(A \mid H_j) = 0$ при $\mathbb{P}(H_j) = 0$

$$\mathbb{P}(H_k \mid A) = \frac{\mathbb{P}(H_k)\,\mathbb{P}(A \mid H_k)}{\sum_j \mathbb{P}(H_j)\,\mathbb{P}(A \mid H_j)}.$$

Доказателство. От определението за условна вероятност и формулата за пълната вероятност:

$$\mathbb{P}(H_k \mid A) = \frac{\mathbb{P}(A \cap H_k)}{\mathbb{P}(A)} = \frac{\mathbb{P}(H_k)\,\mathbb{P}(A \mid H_k)}{\sum_j \mathbb{P}(H_j)\,\mathbb{P}(A \mid H_j)}. \qquad \square$$

Бел.: $\mathbb{P}(H_k)$ е априорната, а $\mathbb{P}(H_k \mid A)$ — апостериорната вероятност на хипотезата H_k след наблюдаване на A. По-специално, при положителни вероятности $\mathbb{P}(H_i), \mathbb{P}(H_j)$ получаваме

$$\frac{\mathbb{P}(H_i \mid A)}{\mathbb{P}(H_j \mid A)} = \frac{\mathbb{P}(H_i)}{\mathbb{P}(H_j)} \frac{\mathbb{P}(A \mid H_i)}{\mathbb{P}(A \mid H_j)}.$$

⊕ **Два вида монети.** Нека H_1 означава, че монетата е честна, а H_2 — че вероятността за ези е $1/3$. Априорните вероятности са

$$\mathbb{P}(H_1) = 0.99, \qquad \mathbb{P}(H_2) = 0.01.$$

Наблюдаваме 30 ези от 100 независими хвърляния. Нека A е това събитие. Тогава

$$\mathbb{P}(A \mid H_1) = \binom{100}{30} 2^{-100}, \qquad \mathbb{P}(A \mid H_2) = \binom{100}{30} \left(\frac{1}{3}\right)^{30} \left(\frac{2}{3}\right)^{70}.$$

По формулата на Бейс за отношението на апостериорните вероятности

$$\begin{aligned} \frac{\mathbb{P}(H_1 \mid A)}{\mathbb{P}(H_2 \mid A)} &= \frac{\mathbb{P}(H_1)}{\mathbb{P}(H_2)} \frac{\mathbb{P}(A \mid H_1)}{\mathbb{P}(A \mid H_2)} \\ &= 99 \exp\bigl(100 \log 3 - 170 \log 2\bigr) \approx 0.0341. \end{aligned}$$

Понеже $\mathbb{P}(H_1 \mid A) + \mathbb{P}(H_2 \mid A) = 1$, следва

$$\mathbb{P}(H_1 \mid A) \approx 0.0330.$$

⊕ **Тест за инфекция.** Нека 1% от хората са заразени. Обозначаваме с I събитието „човекът е заразен“, с $H = I^c$ — „човекът е здрав“, а с B — „тестът дава положителен резултат“. Тестът разпознава заразен с вероятност 0.99 и отчита здрав като здрав с вероятност 0.8. Следователно

$$\mathbb{P}(I) = 0.01, \quad \mathbb{P}(H) = 0.99, \quad \mathbb{P}(B \mid I) = 0.99, \quad \mathbb{P}(B \mid H) = 0.2.$$

По формулата на Бейс

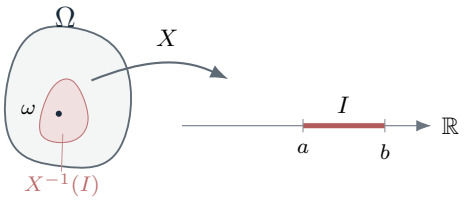
$$\mathbb{P}(I \mid B) = \frac{0.99 \cdot 0.01}{0.99 \cdot 0.01 + 0.2 \cdot 0.99} = \frac{1}{21}.$$

Следователно дори положителният резултат не прави вероятността за инфекция висока при малка разпространеност.

Лекция 4

Случайни величини и техните свойства

Нека $V = (\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство. Множеството Ω може да се състои от сложни обекти: хвърляния на зарове, траектории на процеси и др. Често не е необходимо да познаваме напълно всеки елементарен изход ω, а само определена негова числова характеристика $X(\omega)$.



За интервал $I \subseteq \mathbb{R}$ означаваме

$$X^{-1}(I) = \{\omega \in \Omega : X(\omega) \in I\}.$$

Дефиниция. Нека $(\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство. Функция $X : \Omega \to \mathbb{R}$ се нарича *случайна величина*, ако за всеки интервал $I = (a, b)$, $a < b$, е изпълнено $X^{-1}(I) \in \mathcal{A}$.

Бел.: Еквивалентно е да изискваме $X^{-1}(B) \in \mathcal{A}$ за всяко борелово множество $B \in \mathcal{B}(\mathbb{R})$. В частност същото важи за интервали $(-\infty, b)$, $[a, b]$, $(a, b]$ и за едноточкови множества.

Операции със случайни величини

Теорема. Нека X, Y са случайни величини върху $(\Omega, \mathcal{A}, \mathbb{P})$. Тогава:

а) $aX + bY$ е случайна величина за всички $a, b \in \mathbb{R}$;

б) XY е случайна величина;

в) ако $\mathbb{P}(Y = 0) = 0$, то X/Y, доопределено например с 0 върху $\{Y = 0\}$, е случайна величина.

Доказателство. Първо нека $Z = cX$. За $I = (-\infty, b)$ и $c > 0$ имаме

$$Z^{-1}(I) = \{X < b/c\} \in \mathcal{A}.$$

Ако $c < 0$, получаваме $\{X > b/c\} \in \mathcal{A}$, а при $c = 0$ множеството $Z^{-1}(I)$ е или $\varnothing$, или Ω. Остава да проверим сумата $Z_1 + Z_2$ на две случайни величини. Използвайки плътността на рационалните числа, получаваме

$$\{Z_1 + Z_2 < b\} = \bigcup_{q \in \mathbb{Q}} \big(\{Z_1 < q\} \cap \{Z_2 < b - q\}\big).$$

Наистина, ако $Z_1(\omega) + Z_2(\omega) < b$, съществува $q \in \mathbb{Q}$ с $Z_1(\omega) < q < b - Z_2(\omega)$; обратното включване е непосредствено. Дясната страна е изброимо обединение на събития и следователно принадлежи на $\mathcal{A}$. $\square$

Дискретни случайни величини

Дефиниция. За $H \subseteq \Omega$ функцията

$$1_H(\omega) = \begin{cases} 1, & \omega \in H, \\ 0, & \omega \notin H \end{cases}$$

се нарича *индикаторна функция* на H.

Лема. Ако $H \in \mathcal{A}$, то 1_H е случайна величина.

Доказателство. За $b \in \mathbb{R}$ имаме

$$\{1_H < b\} = \begin{cases} \varnothing, & b \leq 0, \\ H^c, & 0 < b \leq 1, \\ \Omega, & b > 1. \end{cases}$$

И трите множества принадлежат на $\mathcal{A}$. □

Пример. Нека $X = 1_H$, където H описва успех в случаен експеримент. Ако $\mathbb{P}(H) = p \in [0,1]$, то

$$\mathbb{P}(X = 1) = p, \qquad \mathbb{P}(X = 0) = 1 - p.$$

Това е *Бернулиева случайна величина* с параметър p. Разпределението не зависи от конкретното вероятностно пространство. Например за друго вероятностно пространство $(\Omega^*, \mathcal{A}^*, \mathbb{P}^*)$ можем да вземем $X^* = 1_{H^*}$, $H^* \in \mathcal{A}^*$ и $\mathbb{P}^*(H^*) = p$. Тогава X и X^* имат едно и също разпределение.

Пример. При хвърляне на две честни монети можем да използваме наредените изходи

$$\Omega = \{(0,0), (0,1), (1,0), (1,1)\},$$

като 1 означава „ези“. Ако X е броят на получените „ези“, то

$$\mathbb{P}(X = 0) = \frac{1}{4}, \qquad \mathbb{P}(X = 1) = \frac{1}{2}, \qquad \mathbb{P}(X = 2) = \frac{1}{4}.$$

Във всяко вероятностно пространство $(\Omega, \mathcal{A}, \mathbb{P})$ можем да разглеждаме крайно или изброимо *разбиване* $\{H_j : j \in J\} \subseteq \mathcal{A}$ на Ω, т.е.

$$H_j \cap H_k = \varnothing \quad (j \neq k), \qquad \bigcup_{j \in J} H_j = \Omega.$$

Дефиниция. Случайна величина X се нарича *дискретна*, ако приема краен или изброим брой стойности $x_j \in \mathbb{R}$. В такъв случай тя има представяне

$$X(\omega) = \sum_{j \in J} x_j 1_{H_j}(\omega), \qquad H_j = \{X = x_j\}.$$

Тук стойностите x_j се приемат различни, а множествата H_j образуват пълна група от събиятия в V.

Обратно, ако $\{H_j\}_{j \in J} \subseteq \mathcal{A}$ е крайно или изброимо разбиване и $x_j \in \mathbb{R}$, то функцията $X = \sum_{j \in J} x_j 1_{H_j}$ е случайна величина. Действително, за всяко $x \in \mathbb{R}$ имаме

$$\{X \leq x\} = \bigcup_{j \colon x_j \leq x} H_j \in \mathcal{A}.$$

Във всеки елементарен изход точно един индикатор в сумата е равен на 1.

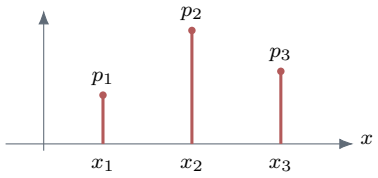
Дефиниция. Нека X е дискретна случайна величина, която приема различни стойности $x_1, x_2, \ldots$. Числата

$$p_j := \mathbb{P}(X = x_j) = \mathbb{P}(H_j), \qquad p_j \geq 0, \qquad \sum_j p_j = 1,$$

се наричат *разпределение* на X и се записват чрез таблицата

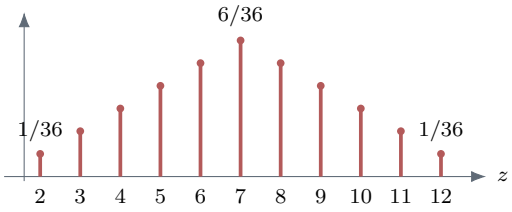
X	x_1	x_2	$\cdots$	x_j	$\cdots$
$\mathbb{P}$	p_1	p_2	$\cdots$	p_j	$\cdots$

Две случайни величини, дефинирани дори върху различни вероятностни пространства, могат да имат едно и също разпределение. Разпределението може да се изобрази и чрез стълбовидна диаграма:



Пример. Нека Z е сумата от резултатите при хвърляне на два честни зара. Тогава Z приема стойностите $2, 3, \ldots, 12$ с вероятности

$$\mathbb{P}(Z = k) = \frac{6 - |7 - k|}{36}, \qquad 2 \leq k \leq 12.$$



Смяна на променливите

Нека $g : \mathbb{R} \to \mathbb{R}$ е функция и X е дискретна случайна величина. Тогава $Y = g(X)$ също е дискретна случайна величина: ако $X = \sum_j x_j 1_{H_j}$, то

$$Y = \sum_j g(x_j) 1_{H_j}.$$

Различни стойности на X могат да се преобразуват в една и съща стойност на Y. В този случай съответните вероятности се сумират:

$$\mathbb{P}(Y = y) = \sum_{j:\, g(x_j) = y} p_j.$$

Пример. Нека $X : \Omega \to \{0, 1, 2, \ldots\}$ е броят дни работа на нов процесор, като $X = 0$ означава, че той е дефектен. Полагаме

$$g(u) = \begin{cases} 1, & u \geq 1, \\ 0, & u < 1. \end{cases} \qquad Y = g(X) = 1_{\{X \geq 1\}}.$$

Тогава Y показва дали процесорът е работил поне един ден и

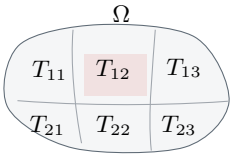
$$\mathbb{P}(Y = 0) = \mathbb{P}(X = 0) = p_0, \qquad \mathbb{P}(Y = 1) = 1 - p_0.$$

Дефиниция. Ако X и Y са две дискретни случайни величини и $g : \mathbb{R} \times \mathbb{R} \to \mathbb{R}$ е функция, то $Z = g(X, Y)$ също е дискретна случайна величина.
Наистина, ако

$$X = \sum_j x_j 1_{H_j}, \qquad Y = \sum_k y_k 1_{K_k}, \qquad T_{jk} = H_j \cap K_k,$$

тогава $(T_{jk})_{j,k}$ е изброимо разбиване на Ω (като празните множества могат да се пропуснат) и

$$Z = g(X, Y) = \sum_{j,k} g(x_j, y_k) 1_{T_{jk}}.$$



Независимост на дискретни случайни величини

Дефиниция. Дискретните случайни величини X и Y са *независими*, което означаваме $X \perp\!\!\!\perp Y$, ако за всички техни възможни стойности x_i и y_j е изпълнено

$$\mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i)\,\mathbb{P}(Y = y_j).$$

Пример. Нека $\Omega = \{0,1\}^2$, $\mathcal{A} = 2^\Omega$, като четирите изхода са равновероятни. Ако $X(\omega_1, \omega_2) = \omega_1$ и $Y(\omega_1, \omega_2) = \omega_2$, то

$$\mathbb{P}(X = i, Y = j) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(X = i)\,\mathbb{P}(Y = j), \quad i, j \in \{0,1\}.$$

Следователно X и Y са независими.

Съвместни и маргинални разпределения

За дискретни X, Y с възможни стойности x_i, y_j числата

$$p_{ij} = \mathbb{P}(X = x_i, Y = y_j)$$

образуват *съвместното разпределение*. От него получаваме *маргиналните разпределения*

$$p_i = \mathbb{P}(X = x_i) = \sum_j p_{ij}, \qquad q_j = \mathbb{P}(Y = y_j) = \sum_i p_{ij}.$$

Независимостта означава, че $p_{ij} = p_i q_j$ за всички i, j.

Функция на разпределение

Дефиниция. За произволна случайна величина X функцията

$$F_X(x) := \mathbb{P}(X \le x), \qquad x \in \mathbb{R},$$

се нарича *функция на разпределение* на X.
За дискретна случайна величина X, приемаща подредените стойности $x_1 < x_2 < \cdots$, с $p_i = \mathbb{P}(X = x_i)$ получаваме

$$F_X(x) = \sum_{i:\, x_i \le x} p_i.$$

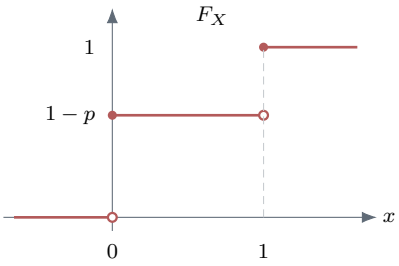
Например за първите три стойности имаме

$$F_X(x) = \begin{cases} 0, & x < x_1, \\ p_1, & x_1 \le x < x_2, \\ p_1 + p_2, & x_2 \le x < x_3, \end{cases}$$

като аналогично продължаваме за останалите стойности. Точката x_i принадлежи на стъпалото *след скока*.

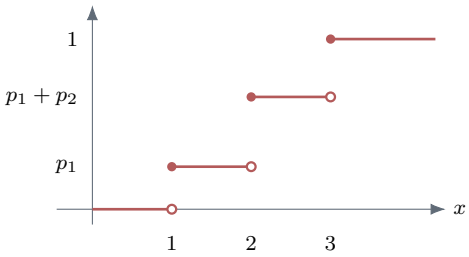
Пример. Ако $X = 1_H$ и $\mathbb{P}(H) = p$, то

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1-p, & 0 \le x < 1, \\ 1, & x \ge 1. \end{cases}$$



Пример. Ако X приема стойностите $1, 2, 3$ с вероятности p_1, p_2, p_3 ($p_1 + p_2 + p_3 = 1$), тогава

$$F_X(x) = \begin{cases} 0, & x < 1, \\ p_1, & 1 \le x < 2, \\ p_1 + p_2, & 2 \le x < 3, \\ 1, & x \ge 3. \end{cases}$$



Лекция 5

Математическо очакване

Дефиниция. Нека X е дискретна случайна величина със стойности $(x_j)_j \in \mathbb{R}$ и вероятности $p_j = \mathbb{P}(X = x_j), j \geq 1$. Числото

$$\mathbb{E}[X] := \sum_j x_j p_j$$

наричаме *математическо очакване* на X, ако редът е абсолютно сходящ, т.е. $\sum_j |x_j| p_j < \infty$.
Ако X приема краен брой стойности, то $\mathbb{E}[X]$ винаги е добре дефинирано.

⊕ Ако X приема стойностите $j \geq 1$ с вероятности

$$p_j = \mathbb{P}(X = j) = \frac{6}{\pi^2 j^2},$$

то $\sum_{j\geq 1} p_j = 1$, но

$$\sum_{j=1}^{\infty} j p_j = \frac{6}{\pi^2} \sum_{j=1}^{\infty} \frac{1}{j} = \infty.$$

Следователно X няма *крайно* математическо очакване.

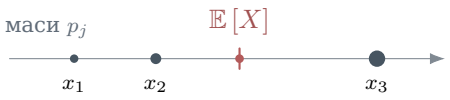
Идеи и интерпретации

⊕ Ако X приема стойностите $x_1, \ldots, x_n$ с еднакви вероятности $p_j = 1/n$, то

$$\mathbb{E}[X] = \frac{1}{n} \sum_{j=1}^{n} x_j,$$

тоест получаваме средното аритметично.

⊕ $\mathbb{E}[X] = \sum_j x_j p_j$ може да се разглежда като *център на тежестта* на маси p_j, разположени в точките x_j на реалната права.



⊕ Ако $\mathbb{E}[X^2] < \infty$, то математическото очакване минимизира квадратичната грешка:

$$\operatorname*{argmin}_{a\in\mathbb{R}} \sum_j (x_j - a)^2 p_j = \mathbb{E}[X].$$

Математическото очакване играе основна роля в закона за големите числа и централната гранична теорема.

Пример: европейска рулетка

Пример. В европейската рулетка има 37 равновероятни числа. Ако заложим 1 евро на точно едно число и X е чистата печалба, то разпределението е

X	-1	35
$\mathbb{P}$	$\frac{36}{37}$	$\frac{1}{37}$

$$\Longrightarrow \qquad \mathbb{E}[X] = -\frac{36}{37} + \frac{35}{37} = -\frac{1}{37}.$$

При 3700 игри очакваната обща загуба е 100 евро.

Ако заложим 1 евро на червено и Y е чистата печалба, получаваме

$$\begin{array}{c|cc} Y & -1 & 1 \\ \hline \mathbb{P} & \frac{19}{37} & \frac{18}{37} \end{array} \qquad \Longrightarrow \qquad \mathbb{E}[Y] = -\frac{19}{37} + \frac{18}{37} = -\frac{1}{37}.$$

Очакване на функции от случайни величини

Ако $Y = g(X)$ и $\mathbb{E}[|Y|] < \infty$, то

$$\mathbb{E}[Y] = \mathbb{E}[g(X)] = \sum_j g(x_j)\mathbb{P}(X = x_j).$$

Аналогично, ако $Z = g(X, Y)$ е интегрируема случайна величина, то

$$\mathbb{E}[Z] = \sum_{i,j} g(x_i, y_j)\mathbb{P}(X = x_i;\, Y = y_j).$$

Същата формула е валидна за функция на произволен краен брой дискретни случайни величини, като се сумира по съвместното им разпределение.

Основни свойства на математическото очакване

Лема. Нека X и Y са дискретни случайни величини с крайно математическо очакване, а $c \in \mathbb{R}$. Тогава:

а) ако $X = c$ почти сигурно, то $\mathbb{E}[X] = c$;

б) $\mathbb{E}[cX] = c\mathbb{E}[X]$;

в) $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$; в частност

$$\mathbb{E}\left[\sum_{j=1}^{n} X_j\right] = \sum_{j=1}^{n} \mathbb{E}[X_j];$$

г) ако $X \perp\!\!\!\perp Y$, то $\mathbb{E}[XY] = \mathbb{E}[X]\,\mathbb{E}[Y]$;

д) ако $X \geq 0$, то $\mathbb{E}[X] \geq 0$.

Доказателство. Свойства а), б) и д) следват непосредствено от дефиницията. За в) използваме съвместното разпределение:

$$\begin{aligned} \mathbb{E}[X + Y] &= \sum_{i,j} (x_i + y_j)\mathbb{P}(X = x_i;\, Y = y_j) \\ &= \sum_i x_i \mathbb{P}(X = x_i) + \sum_j y_j \mathbb{P}(Y = y_j) = \mathbb{E}[X] + \mathbb{E}[Y]. \end{aligned}$$

Тук независимост не е необходима. Ако X и Y са независими, то за г) имаме

$$\begin{aligned} \mathbb{E}[XY] &= \sum_{i,j} x_i y_j \mathbb{P}(X = x_i;\, Y = y_j) \\ &= \sum_i x_i \mathbb{P}(X = x_i) \sum_j y_j \mathbb{P}(Y = y_j) = \mathbb{E}[X]\,\mathbb{E}[Y]. \end{aligned} \qquad \square$$

Пример за математическо очакване

Пример. Нека имаме тестване за Ковид като целта е да минимизираме разходите при неговото провеждане (средният разход за потенциален пациент да е минимален). Събираме тестови материал от потенциални пациенти като половината от всеки материал се смесва в една обща проба, върху която се прилага един тест. Ако пробата е положителна всеки пациент се тества отново с отделен тест. Моделираме с X_n, определена с

$$\begin{array}{c|cc} X_n & 1 & n+1 \\ \hline \mathbb{P} & p^n & 1-p^n \end{array} \qquad (0<p<1).$$

Такава величина възниква например при n независими опита с вероятност p за успех, ако поставим $X_n = 1$, когато всички са успешни, и $X_n = n+1$ в противен случай. Тогава

$$\mathbb{E}[X_n] = p^n + (n+1)(1-p^n) = n+1-np^n, \quad \text{търсим } \min_{n\geq 1}\left(1+\frac{1}{n}-p^n\right).$$

При $p = 0.95$ и $n = 5$ намираме

$$\mathbb{E}[X_5] = 6 - 5(0.95)^5 \approx 2.13 \qquad \big(\approx 0.426\cdot 5\big).$$

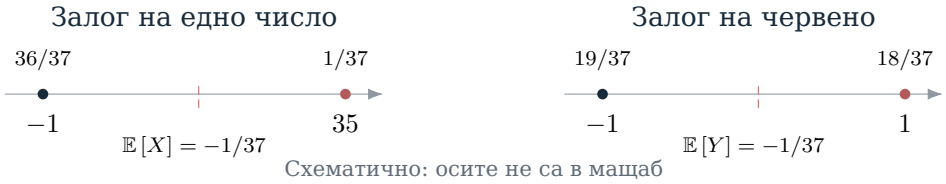
Ако $X_5^{(1)}, \ldots, X_5^{(k)}$ са независими копия на X_5, тоест тестваме $5k$ пациенти, то средното от наблюденията

$$\frac{X_5^{(1)} + \cdots + X_5^{(k)}}{k} \longrightarrow \mathbb{E}[X_5]$$

почти сигурно, когато $k \to \infty$, съгласно закона за големите числа.

Дисперсия и стандартно отклонение

Двете стратегии на рулетка имат едно и също математическо очакване, но различна степен на риск.



Дефиниция. Ако X има крайно второ моментно очакване $\mathbb{E}\left[X^2\right] < \infty$, то

$$\mathrm{D}X := \mathbb{E}\left[(X - \mathbb{E}[X])^2\right] = \sum_j (x_j - \mathbb{E}[X])^2 p_j$$

се нарича *дисперсия* на X, а $\sqrt{\mathrm{D}X}$ — *стандартно отклонение*.

Интерпретация. Дисперсията измерва разсейването около математическото очакване и е минималната средна квадратична грешка:

$$\mathrm{D}X = \min_{a\in\mathbb{R}} \mathbb{E}\left[(X-a)^2\right].$$

Пример. За двете стратегии на рулетка имаме

$$\mathrm{D}X = \frac{36}{37}\frac{1}{37}(35-(-1))^2 = \frac{46656}{1369} \approx 34.08,$$
$$\mathrm{D}Y = \frac{19}{37}\frac{18}{37}(1-(-1))^2 = \frac{1368}{1369} \approx 1.$$

Следователно еднаквото очакване не означава еднакъв риск, а еднаква тенденция.

Пример: независими избори

Пример. $2N$ души независимо избират с вероятност $1/2$ дали да застанат отляво или отдясно на въже. Нека $X_i = 1$ при избор на дясната страна и $X_i = -1$ при избор на лявата, и положим

$$Y = \sum_{i=1}^{2N} X_i.$$

Тогава $Y = 0$ означава, че от двете страни има равен брой хора. От симетрията и независимостта следва

$$\mathbb{E}[Y] = \sum_{i=1}^{2N} \mathbb{E}[X_i] = 0, \qquad \mathbb{P}(Y = 0) = \binom{2N}{N} \frac{1}{2^{2N}} \sim \frac{1}{\sqrt{\pi N}}.$$

Освен това $\mathrm{D}Y = 2N$, така че стандартното отклонение е $\sqrt{2N}$.

Тъждество за дисперсията

Твърдение. За всяка случайна величина X с $\mathbb{E}\left[X^2\right] < \infty$ е изпълнено

$$\mathrm{D}X = \mathbb{E}\left[X^2\right] - (\mathbb{E}[X])^2.$$

Доказателство. От линейността на математическото очакване

$$\begin{aligned} \mathrm{D}X &= \mathbb{E}\left[(X - \mathbb{E}[X])^2\right] = \mathbb{E}\left[X^2 - 2X\mathbb{E}[X] + (\mathbb{E}[X])^2\right] \\ &= \mathbb{E}\left[X^2\right] - 2\mathbb{E}[X]\,\mathbb{E}[X] + (\mathbb{E}[X])^2 = \mathbb{E}\left[X^2\right] - (\mathbb{E}[X])^2. \end{aligned}$$ □

Свойства на дисперсията

Ако X и Y имат крайни втори моменти, а $c \in \mathbb{R}$, то:

а) $\mathrm{D}X \geq 0$;

б) $\mathrm{D}c = 0$;

в) $\mathrm{D}(cX) = c^2 \mathrm{D}X$;

г) за произволни X и Y:

$$\mathrm{D}(X+Y) = \mathrm{D}X + \mathrm{D}Y + 2\big(\mathbb{E}[XY] - \mathbb{E}[X]\,\mathbb{E}[Y]\big).$$

По-специално, ако $X \perp\!\!\!\perp Y$, то

$$\mathrm{D}(X+Y) = \mathrm{D}X + \mathrm{D}Y.$$

Доказателство. Първото свойство следва от $(X - \mathbb{E}[X])^2 \geq 0$. За б) и в) имаме

$$\mathrm{D}c = \mathbb{E}\left[(c-c)^2\right] = 0, \qquad \mathrm{D}(cX) = \mathbb{E}\left[c^2(X - \mathbb{E}[X])^2\right] = c^2 \mathrm{D}X.$$

За г) разкриваме квадрата и използваме тъждеството за дисперсията:

$$\begin{aligned} \mathrm{D}(X+Y) &= \mathbb{E}\left[(X+Y)^2\right] - (\mathbb{E}[X] + \mathbb{E}[Y])^2 \\ &= \mathrm{D}X + \mathrm{D}Y + 2\mathbb{E}[XY] - 2\mathbb{E}[X]\,\mathbb{E}[Y]. \end{aligned}$$

При независимост $\mathbb{E}[XY] = \mathbb{E}[X]\,\mathbb{E}[Y]$ и последните два члена се унищожават. □

Следствие. За всяка случайна величина с краен втори момент

$$\mathbb{E}\left[X^2\right] \geq (\mathbb{E}[X])^2.$$

Лекция 6

Пораждаща функция

Пораждащата функция позволява да се изучава разпределението на неотрицателна целочислена случайна величина посредством една функция. *Бел.: Г. Поля (1954) дава аналогия за пораждащата функция като торбичка, в която слагаме всички обекти, и ги вадим при необходимост.*

Дефиниция. Нека $X : \Omega \to \{0, 1, 2, \ldots\}$ е дискретна случайна величина. Функцията

$$g_X(s) := \mathbb{E}\left[s^X\right] = \sum_{n=0}^{\infty} s^n \mathbb{P}(X = n), \qquad |s| \leq 1,$$

се нарича *пораждаща функция* на X. За $s = 0$ приемаме $0^0 = 1$.

Свойства. При съществуване на съответните моменти имаме

а) $g_X(1) = 1$;

б) $g'_X(1) = \mathbb{E}[X]$;

в) $\mathrm{D}(X) = g''_X(1) + g'_X(1) - \left(g'_X(1)\right)^2$;

г) $\mathbb{P}(X = n) = \dfrac{g_X^{(n)}(0)}{n!}$, $n = 0, 1, \ldots$.

Бел.: За производните при $s = 1$ се използват левите граници; равенствата за очакването и дисперсията изискват съответните моменти да са крайни.

Вярно е, че $X \overset{d}{=} Y \iff g_X = g_Y$, където под равенство по разпределение, разбираме, че $\mathbb{P}(X = n) = \mathbb{P}(Y = n), n \geq 0$.

Теорема. Нека $X_1, \ldots, X_n$ са независими неотрицателни целочислени случайни величини и $Y = X_1 + \cdots + X_n$. Тогава

$$g_Y(s) = \prod_{j=1}^{n} g_{X_j}(s).$$

Ако освен това $X_i \overset{d}{=} X_j$ за всички i, j, то

$$g_Y(s) = \left(g_{X_1}(s)\right)^n.$$

Доказателство. По независимост за $0 \leq s \leq 1$:

$$\begin{aligned} g_S(s) &= \mathbb{E}\left[s^{X_1 + \cdots + X_n}\right] \\ &= \sum_{i_1, \ldots, i_n \geq 0} s^{i_1 + \cdots + i_n} \mathbb{P}(X_1 = i_1, \ldots, X_n = i_n) \\ &= \sum_{i_1, \ldots, i_n \geq 0} \prod_{j=1}^{n} s^{i_j} \mathbb{P}(X_j = i_j) \\ &= \prod_{j=1}^{n} \sum_{i_j = 0}^{\infty} s^{i_j} \mathbb{P}(X_j = i_j) = \prod_{j=1}^{n} g_{X_j}(s). \end{aligned}$$

При еднакво разпределение на X_j всички множители са равни. □

Основни дискретни разпределения

Разглеждаме последователни независими опити, всеки от които има два възможни изхода: успех (с вероятност p) и неуспех (с вероятност $q = 1 - p$). Нека $X_j = 1$ при успех в j-ия опит и $X_j = 0$ при неуспех като съвкупността от изходите означаваме с $(X_j)_{j \geq 1}$. Това се нарича схема на Бернули.

А. Разпределение на Бернули

Дефиниция. Казваме, че X има разпределение на Бернули с параметър $p \in [0,1]$, и пишем $X \sim \mathrm{Ber}(p)$, ако

$$\mathbb{P}(X=1)=p, \qquad \mathbb{P}(X=0)=q=1-p.$$

X	0	1
$\mathbb{P}$	q	p

$$\mathbb{E}[X]=p, \qquad \mathrm{D}(X)=\mathbb{E}\left[X^2\right]-\mathbb{E}[X]^2=p-p^2=pq.$$

Пораждащата функция е

$$g_X(s)=q\,s^0+p\,s^1=q+ps.$$

Пример. Резултатът от единичен опит с два възможни изхода, например здрав/болен, може да бъде представен с разпределение на Бернули.

Б. Биномно разпределение

Броим успехите в n независими опита с вероятност p за успех. Нека $X_j \sim \mathrm{Ber}(p)$ са независими и

$$X=\sum_{j=1}^{n} X_j.$$

Тогава казваме, че X има *биномно разпределение* с параметри n и p и пишем $X \sim \mathrm{Bin}(n,p)$.

Твърдение. За $X \sim \mathrm{Bin}(n,p)$:

а) $g_X(s)=(q+ps)^n$;

б) $\mathbb{E}[X]=np$ и $\mathrm{D}(X)=npq$;

в) $\mathbb{P}(X=k)=\binom{n}{k}p^k q^{n-k}$, $k=0,1,\ldots,n$.

Доказателство. По теоремата за пораждащата функция на сума и свойствата на очакването и дисперсията:

$$g_X(s)=\prod_{j=1}^{n}(q+ps)=(q+ps)^n, \quad \mathbb{E}[X]=\sum_{j=1}^{n}\mathbb{E}[X_j]=np, \quad \mathrm{D}(X)=\sum_{j=1}^{n}\mathrm{D}(X_j)=npq.$$

Освен това за $0 \le k \le n$:

$$\begin{aligned}\mathbb{P}(X=k)&=\frac{g_X^{(k)}(0)}{k!}=\frac{n(n-1)\cdots(n-k+1)}{k!}p^k(q+ps)^{n-k}\Big|_{s=0}\\&=\binom{n}{k}p^k q^{n-k}.\square\end{aligned}$$

Пример. X може да е броят родени момичета сред n деца или броят заразени сред n тествани, при независими и еднакви по вероятност опити.

В. Геометрично разпределение

В схемата на Бернули $(X_j)_{j\ge 1}$ с параметър $p \in (0,1]$ разглеждаме броя на неуспехите преди първия успех.

Дефиниция. Ако $X = \min\{n \geq 1 : X_n = 1\} - 1$, то казваме, че X има *геометрично разпределение* с параметър p и пишем $X \sim \mathrm{Ge}(p)$.

Твърдение. Ако $X \sim \mathrm{Ge}(p)$, то

$$\mathbb{P}(X = k) = q^k p, \quad k = 0, 1, \ldots, \qquad g_X(s) = \frac{p}{1 - qs}.$$

Освен това

$$\mathbb{E}[X] = \frac{q}{p}, \qquad \mathrm{D}(X) = \frac{q}{p^2}.$$

Доказателство. Събитието $\{X = k\}$ означава, че първите k опита са неуспешни, а $(k+1)$-вият е успешен:

$$\mathbb{P}(X = k) = \mathbb{P}(X_1 = 0, \ldots, X_k = 0, X_{k+1} = 1) = q^k p,$$

$$g_X(s) = \sum_{k=0}^{\infty} p s^k q^k = \frac{p}{1 - qs}.$$

Оттук

$$g'_X(1) = \frac{pq}{(1-q)^2} = \frac{q}{p}, \qquad g''_X(1) = \frac{2pq^2}{(1-q)^3} = \frac{2q^2}{p^2},$$

и следователно

$$\mathrm{D}(X) = g''_X(1) + g'_X(1) - g'_X(1)^2 = \frac{q}{p^2}.\square$$

Пример. Хвърляме монета до първото „ези“; X е броят предхождащи „тура“. Друг пример е последователна стрелба с независими изстрели, когато X брои неуспехите до първото попадение. При рулетка може да се разглежда броят черни резултати до първото червено при независими завъртания.

Свойство (липса на памет). Ако $X \sim \mathrm{Ge}(p)$ и $0 < p < 1$, то за всички цели $m, k \geq 0$:

$$\mathbb{P}(X \geq m + k \mid X \geq k) = \mathbb{P}(X \geq m) = q^m.$$

Доказателство. От $\mathbb{P}(X \geq \ell) = \mathbb{P}(X_1 = 0, \ldots, X_\ell = 0) = q^\ell$ получаваме

$$\mathbb{P}(X \geq m + k \mid X \geq k) = \frac{\mathbb{P}(X \geq m + k)}{\mathbb{P}(X \geq k)} = \frac{q^{m+k}}{q^k} = q^m.\square$$

Пример. Ако X е броят неуспехи до първия успех, то

$$\mathbb{P}(X \geq 5 \mid X \geq 3) = \mathbb{P}(X \geq 2) = q^2, \qquad \mathbb{P}(X \geq 4 \mid X \geq 3) = \mathbb{P}(X \geq 1) = q.$$

Г. Отрицателно биномно разпределение

Разглеждаме независима схема на Бернули $(X_j)_{j \geq 1}$, $X_j \sim \mathrm{Ber}(p)$, и броя неуспехи преди r-ия успех.

Дефиниция. За цяло число $r \geq 1$ нека

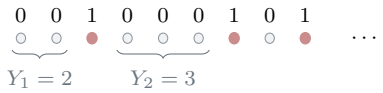
$$X = \min\left\{ n \geq r : \sum_{j=1}^{n} X_j = r \right\} - r.$$

Тогава X има *отрицателно биномно разпределение* с параметри r, p; пишем $X \sim \mathrm{NB}(r, p)$.

При $r = 1$ получаваме геометричното разпределение.

Твърдение. Нека $X \sim \mathrm{NB}(r, p)$. Тогава $X = Y_1 + \cdots + Y_r$, където $Y_i \sim \mathrm{Ge}(p)$ са независими случайни величини.

Доказателство. Y_i брои неуспехите между $(i-1)$-вия и i-ия успех. Поради независимостта на опитите блоковете Y_i са независими, а за всяко $k \geq 0$ имаме $\mathbb{P}(Y_i = k) = q^k p$. $\square$



Твърдение. За $X \sim \mathrm{NB}(r, p)$:

$$g_X(s) = \left(\frac{p}{1-qs}\right)^r, \qquad \mathbb{E}[X] = \frac{rq}{p}, \quad \mathrm{D}(X) = \frac{rq}{p^2}.$$

Още,

$$\mathbb{P}(X = k) = \binom{k+r-1}{k} q^k p^r, \qquad k = 0, 1, \ldots.$$

Доказателство. От представянето като сума на независими геометрични величини следват веднага формулите за пораждащата функция, математическото очакване и дисперсията.

За да бъде $X = k$, сред първите $k + r - 1$ опита трябва да има точно $r - 1$ успеха и k неуспеха, а последният, $(k + r)$-и опит, трябва да е успех. Следователно

$$\mathbb{P}(X = k) = \binom{k+r-1}{r-1} p^{r-1} q^k p = \binom{k+r-1}{k} q^k p^r. \square$$

Д. Поасоново разпределение

Дефиниция. Нека $\lambda > 0$. Казваме, че X има *Поасоново разпределение* с параметър λ, и пишем $X \sim \mathrm{Poi}(\lambda)$, ако

$$\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \qquad k = 0, 1, \ldots.$$

Действително $\sum_{k \geq 0} \mathbb{P}(X = k) = 1$.

Такова разпределение може да описва например броя пристигнали клиенти за единица време, броя телефонни повиквания за определен интервал, броя разпадания на частици за единица време или броя голове в даден времеви интервал.

Твърдение. Ако $X \sim \mathrm{Poi}(\lambda)$, то

$$g_X(s) = e^{\lambda(s-1)}, \qquad \mathbb{E}[X] = \mathrm{D}(X) = \lambda.$$

Доказателство. От определението:

$$g_X(s) = \sum_{k=0}^{\infty} s^k \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} e^{\lambda s} = e^{\lambda(s-1)}.$$

Следователно

$$g'_X(1) = \lambda, \qquad g''_X(1) = \lambda^2, \quad \mathrm{D}(X) = \lambda^2 + \lambda - \lambda^2 = \lambda. \square$$

Теорема (Поасон). Нека $X_n \sim \mathrm{Bi}(n, p_n)$, като $np_n \to \lambda > 0$ (еквивалентно $p_n = \lambda/n + u_n/n$, $u_n \to 0$). Тогава за всяко фиксирано $k = 0, 1, \ldots$:

$$\lim_{n \to \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

Доказателство. От формулата за биномното разпределение за $n \geq k$:

$$\begin{aligned} \mathbb{P}(X_n = k) &= \binom{n}{k} p_n^k (1-p_n)^{n-k} \\ &= \frac{(np_n)^k}{k!} \underbrace{\prod_{j=0}^{k-1} \left(1 - \frac{j}{n}\right)}_{\longrightarrow 1} (1-p_n)^{n-k} \longrightarrow \frac{\lambda^k}{k!} e^{-\lambda}, \end{aligned}$$

защото $p_n \to 0$ и $(1-p_n)^{n-k} \to e^{-\lambda}$. □

Пример. Обикновено приближаваме $\mathrm{Bi}(n,p)$ с $\mathrm{Poi}(\lambda)$, когато $\lambda = np$, n е голямо и p е малко. Например $\mathrm{Bi}(1000, 1/1000)$ се приближава добре с $\mathrm{Poi}(1)$. *Бел.: Практически ориентир: $\lambda = np \le 20$ и $n \ge 100$ често дават добро приближение, но това не е универсална гаранция. Точността зависи и от големината на p.*

Бел.: Пораждащите функции също позволяват да се изследва сходимостта на дискретни разпределения: при подходящи условия $g_{X_n}(s) \to g_X(s)$ води до $\mathbb{P}(X_n = k) \to \mathbb{P}(X = k)$ за всяко k.

Е. Хипергеометрично разпределение

В съвкупност от N елемента точно $M \le N$ са маркирани. Избираме $n \le N$ елемента *без връщане*. Нека X е броят на маркираните сред избраните.

Дефиниция. Казваме, че X има *хипергеометрично разпределение* с параметри N, M, n, и пишем $X \sim \mathrm{HG}(N, M, n)$.

Твърдение. Ако $X \sim \mathrm{HG}(N, M, n)$, то

$$\mathbb{P}(X = k) = \frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}},$$

където $\max(0, n+M-N) \le k \le \min(n, M)$, и

$$\mathbb{E}[X] = \frac{nM}{N}, \qquad \mathrm{D}(X) = \frac{nM}{N}\frac{N-M}{N}\frac{N-n}{N-1} \quad (N > 1).$$

Доказателство. Благоприятните извадки с точно k маркирани елемента се получават, като изберем k от M маркирани и $n-k$ от $N-M$ немаркирани; всички извадки са $\binom{N}{n}$. Това доказва формулата за вероятностите.

Нека I_j е индикаторът на събитието, че j-ият избран елемент е маркиран. Понеже $\mathbb{P}(I_j = 1) = M/N$,

$$X = \sum_{j=1}^{n} I_j, \qquad \mathbb{E}[X] = \sum_{j=1}^{n} \mathbb{E}[I_j] = \frac{nM}{N}.$$

Бел.: За разлика от биномното разпределение, индикаторите I_j не са независими: избирането е без връщане.

Пример. Клиенти пристигат последователно в магазин, като всеки прави покупка с вероятност p, независимо от останалите. Индикаторите за покупка образуват схема на Бернули. При отделен модел броят на пристиганията за единица време може да има разпределение на Поасон с параметър λ.

Лекция 7

Съвместни дискретни разпределения

Често разглеждаме повече от една случайна величина. Например ни интересува *съвместното разпределение* на двойката (X, Y).

Дефиниция. Нека X и Y са дискретни случайни величини, дефинирани върху едно вероятностно пространство $(\Omega, \mathcal{A}, \mathbb{P})$, с възможни стойности съответно $(x_i)_i$ и $(y_j)_j$. Числата

$$p_{ij} = \mathbb{P}(X = x_i,\, Y = y_j) = \mathbb{P}(\{X = x_i\} \cap \{Y = y_j\})$$

задават *съвместното разпределение* на (X, Y). Те удовлетворяват

$$p_{ij} \geq 0, \qquad \sum_i \sum_j p_{ij} = 1.$$

Често представяме съвместното разпределение в таблица:

$Y \backslash X$	x_1	x_2	$\cdots$	x_m
y_1	p_{11}	p_{21}	$\cdots$	p_{m1}
y_2	p_{12}	p_{22}	$\cdots$	p_{m2}
$\vdots$	$\vdots$	$\vdots$		$\vdots$

Разпределенията на X и Y се получават чрез сумиране по другия индекс:

$$\mathbb{P}(X = x_i) = \sum_j p_{ij}, \qquad \mathbb{P}(Y = y_j) = \sum_i p_{ij}.$$

Наричаме ги *маргинални разпределения*.

Пример. Хвърляме два независими честни зара. Нека X е броят на падналите се шестици, а Y — броят на падналите се единици. Тогава

$Y \backslash X$	0	1	2	$\mathbb{P}(Y = j)$
0	$\frac{16}{36}$	$\frac{8}{36}$	$\frac{1}{36}$	$\frac{25}{36}$
1	$\frac{8}{36}$	$\frac{2}{36}$	0	$\frac{10}{36}$
2	$\frac{1}{36}$	0	0	$\frac{1}{36}$
$\mathbb{P}(X = i)$	$\frac{25}{36}$	$\frac{10}{36}$	$\frac{1}{36}$	1

Например $\mathbb{P}(X = 0, Y = 0) = (4/6)^2 = 16/36$, защото никой от заровете не трябва да показва нито единица, нито шестица.

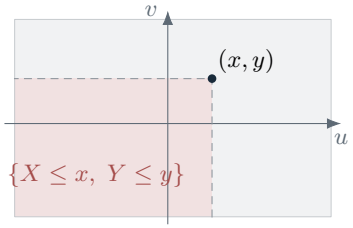
Съвместна функция на разпределение

Дефиниция. За произволни случайни величини X и Y функцията

$$F_{X,Y}(x, y) = \mathbb{P}(X \leq x,\, Y \leq y), \qquad (x, y) \in \mathbb{R}^2,$$

се нарича *съвместна функция на разпределение*.

Събитието съответства на долния ляв квадрант в равнината:



За дискретни X, Y имаме

$$F_{X,Y}(x,y) = \sum_{\substack{i:\, x_i \le x \\ j:\, y_j \le y}} p_{ij}.$$

Пример. За двата зара по-горе

$$F_{X,Y}\left(\frac{1}{2}, \frac{1}{2}\right) = \mathbb{P}\left(X = 0,\, Y = 0\right) = \frac{16}{36}.$$

Също така $F_{X,Y}(x,y) = 0$ за $x < 0$ или $y < 0$. Маргиналните функции на разпределение се получават от съвместната:

$$\lim_{y \to \infty} F_{X,Y}(x,y) = F_X(x), \qquad \lim_{x \to \infty} F_{X,Y}(x,y) = F_Y(y).$$

Независимост

Дефиниция. Две случайни величини X и Y са *независими*, $X \perp\!\!\!\perp Y$, точно когато

$$F_{X,Y}(x,y) = F_X(x) F_Y(y) \qquad \text{за всички } x, y \in \mathbb{R}.$$

За дискретни случайни величини това е еквивалентно на

$$\mathbb{P}\left(X = x_i,\, Y = y_j\right) = \mathbb{P}\left(X = x_i\right) \mathbb{P}\left(Y = y_j\right), \qquad \text{за всички } i, j.$$

Ковариация

Случайните величини могат да са зависими, без една от тях да е линейна функция на другата. За да характеризираме *линейната* връзка между тях, въвеждаме ковариацията.

Дефиниция. Нека X, Y имат крайни втори моменти. Тогава

$$\operatorname{cov}(X,Y) := \mathbb{E}\left[(X - \mathbb{E}\left[X\right])(Y - \mathbb{E}\left[Y\right])\right]$$

се нарича *ковариация* на X и Y.

При дискретни X, Y това е

$$\operatorname{cov}(X,Y) = \sum_{i,j} (x_i - \mathbb{E}\left[X\right])(y_j - \mathbb{E}\left[Y\right]) p_{ij}.$$

Твърдение. При същите условия

$$\operatorname{cov}(X,Y) = \mathbb{E}\left[XY\right] - \mathbb{E}\left[X\right]\mathbb{E}\left[Y\right].$$

Ако $X \perp\!\!\!\perp Y$, то $\operatorname{cov}(X,Y) = 0$.

Доказателство. Разкриваме скобите и използваме линейността на математическото очакване:

$$\begin{aligned}\mathbb{E}\left[(X - \mathbb{E}\left[X\right])(Y - \mathbb{E}\left[Y\right])\right] &= \mathbb{E}\left[XY\right] - \mathbb{E}\left[X\right]\mathbb{E}\left[Y\right] - \mathbb{E}\left[Y\right]\mathbb{E}\left[X\right] + \mathbb{E}\left[X\right]\mathbb{E}\left[Y\right] \\ &= \mathbb{E}\left[XY\right] - \mathbb{E}\left[X\right]\mathbb{E}\left[Y\right].\end{aligned}$$

Ако $X \perp\!\!\!\perp Y$, то $\mathbb{E}\left[XY\right] = \mathbb{E}\left[X\right]\mathbb{E}\left[Y\right]$, откъдето следва последното твърдение. □

Бел.: Ковариацията зависи от мащаба на двете величини. Например $\operatorname{cov}(10X, 10Y) = 100 \operatorname{cov}(X,Y)$.

Коефициент на корелация

Дефиниция. Ако $0 < DX, DY < \infty$, то *коефициентът на корелация* е

$$\rho(X,Y) := \frac{\operatorname{cov}(X,Y)}{\sqrt{DX}\sqrt{DY}}.$$

Тук $DX = \mathbb{E}\left[(X - \mathbb{E}[X])^2\right]$, а аналогично се определя DY. Въвеждаме центрираните и нормализирани величини

$$\overline{X} = \frac{X - \mathbb{E}[X]}{\sqrt{DX}}, \qquad \overline{Y} = \frac{Y - \mathbb{E}[Y]}{\sqrt{DY}}.$$

Тогава

$$\mathbb{E}\left[\overline{X}\right] = \mathbb{E}\left[\overline{Y}\right] = 0, \qquad D\overline{X} = D\overline{Y} = 1, \qquad \rho(X,Y) = \mathbb{E}\left[\overline{X}\overline{Y}\right].$$

Последното се получава непосредствено от дефиницията.

Теорема. За всяка двойка случайни величини с крайни и строго положителни дисперсии е изпълнено

$$|\rho(X,Y)| \le 1.$$

Освен това $|\rho(X,Y)| = 1$ точно когато $Y = aX + b$ почти сигурно за някои $a \neq 0$ и $b \in \mathbb{R}$.

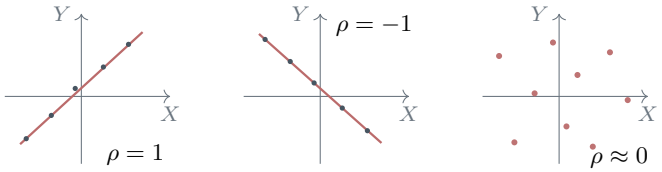
Доказателство. Понеже

$$0 \le \mathbb{E}\left[(\overline{X} \pm \overline{Y})^2\right] = 2 \pm 2\mathbb{E}\left[\overline{X}\overline{Y}\right] = 2 \pm 2\rho(X,Y),$$

то $-1 \le \rho(X,Y) \le 1$. Ако $\rho = 1$, то $\mathbb{E}\left[(\overline{X} - \overline{Y})^2\right] = 0$, откъдето $\overline{X} = \overline{Y}$ почти сигурно. Ако $\rho = -1$, аналогично $\overline{X} = -\overline{Y}$. Следователно

$$Y = \mathbb{E}[Y] \pm \sqrt{\frac{DY}{DX}}\,(X - \mathbb{E}[X]).$$

Обратно, от $Y = aX + b$ с $a \neq 0$ непосредствено получаваме $\rho(X,Y) = \operatorname{sgn}(a)$. □



Бел.: Независимостта влече $\rho(X,Y) = 0$, но обратното не е вярно: нулевата корелация означава липса на линейна зависимост, а не непременно независимост. Например, ако X е равномерна върху $\{-1, 0, 1\}$ и $Y = X^2$, то $\rho(X,Y) = 0$, но Y е функция на X.

Условно математическо очакване

Припомняне. За X с краен втори момент най-добрата константа, приближаваща X в средноквадратичен смисъл, е $\mathbb{E}[X]$, защото

$$\mathbb{E}\left[(X - a)^2\right] = DX + (a - \mathbb{E}[X])^2, \qquad \min_{a \in \mathbb{R}} \mathbb{E}\left[(X - a)^2\right] = DX.$$

Какво се случва, ако освен X наблюдаваме и друга случайна величина Y? Търсим функция G^*, за която решава задачата

$$\mathbb{E}\left[(X - G^*(Y))^2\right] = \inf_G \mathbb{E}\left[(X - G(Y))^2\right].$$

Така използваме оптимално информацията, съдържаща се в Y.

Случай на две възможни стойности. Нека $Y = 1_A$, където $A \in \mathcal{A}$ и $p = \mathbb{P}(A) \in (0,1)$. Всяка функция на Y е от вида

$$G(Y) = a1_A + b1_{A^c}, \qquad a, b \in \mathbb{R}.$$

Следователно минимизираме по a, b функцията

$$\begin{aligned} f(a,b) &= \mathbb{E}\left[(X - a1_A - b1_{A^c})^2\right] \\ &= \mathbb{E}\left[X^2\right] + a^2 p + b^2(1-p) - 2a\mathbb{E}\left[X1_A\right] - 2b\mathbb{E}\left[X1_{A^c}\right]. \end{aligned}$$

От уравненията за частните производни

$$\frac{\partial f}{\partial a} = 2ap - 2\mathbb{E}\left[X1_A\right] = 0, \qquad \frac{\partial f}{\partial b} = 2b(1-p) - 2\mathbb{E}\left[X1_{A^c}\right] = 0$$

получаваме

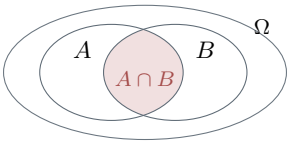
$$a = \frac{\mathbb{E}\left[X1_A\right]}{\mathbb{P}(A)}, \qquad b = \frac{\mathbb{E}\left[X1_{A^c}\right]}{\mathbb{P}(A^c)}.$$

Значи най-доброто приближение е

$$G(Y) = \frac{\mathbb{E}\left[X1_A\right]}{\mathbb{P}(A)}1_A + \frac{\mathbb{E}\left[X1_{A^c}\right]}{\mathbb{P}(A^c)}1_{A^c}.$$

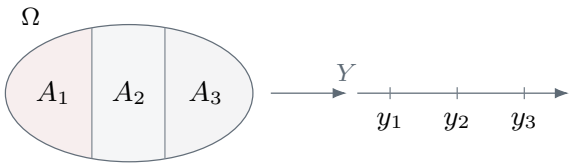
Пример. Ако $X = 1_B$ и $Y = 1_A$ за събития $A, B \in \mathcal{A}$, то

$$G(Y) = \mathbb{P}(B \mid A)\, 1_A + \mathbb{P}(B \mid A^c)\, 1_{A^c}.$$



Общ дискретен случай. Нека Y приема изброимо много стойности $(y_j)_j$. Полагаме $A_j = \{Y = y_j\}$ и $p_j = \mathbb{P}(A_j) > 0$. Тогава $(A_j)_j$ е разбиение на Ω, а всяка функция на Y е от вида

$$G(Y) = \sum_j a_j 1_{A_j}.$$



По същия начин минимизацията на $\mathbb{E}\left[(X - G(Y))^2\right]$ води до

$$a_j = \frac{\mathbb{E}\left[X1_{A_j}\right]}{\mathbb{P}(A_j)}, \qquad G(Y) = \sum_j \frac{\mathbb{E}\left[X1_{A_j}\right]}{\mathbb{P}(A_j)}1_{A_j}.$$

В частност, ако X също е дискретна със стойности $(x_i)_i$, то

$$\mathbb{E}\left[X1_{A_j}\right] = \sum_i x_i \mathbb{P}(X = x_i,\, Y = y_j) = \sum_i x_i p_{ij}.$$

Дефиниция. За интегруема дискретна случайна величина X и дискретна случайна величина Y *условното математическо очакване на* X *при* $Y = y_j$ е

$$\mathbb{E}[X \mid Y = y_j] := \sum_i x_i \mathbb{P}(X = x_i \mid Y = y_j) = \frac{\sum_i x_i p_{ij}}{\mathbb{P}(Y = y_j)},$$

когато $\mathbb{P}(Y = y_j) > 0$.

Дефиниция. *Условното математическо очакване на* X *при условие* Y е случайната величина

$$\mathbb{E}[X \mid Y] = \sum_j \mathbb{E}[X \mid Y = y_j]\ 1_{\{Y = y_j\}}.$$

По този начин $\mathbb{E}[X \mid Y]$ е функция на Y и съответно е дискретна случайна величина (с не повече от изброимо много стойности). Нейното разпределение се получава от стойностите $\mathbb{E}[X \mid Y = y_j]$ с вероятности $\mathbb{P}(Y = y_j)$, като еднаквите стойности се обединяват.

Пример. За двата зара, ако X е броят шестици, а Y — броят единици, получаваме

$$\mathbb{E}[X \mid Y = 0] = \frac{8+2}{25} = \frac{2}{5}, \qquad \mathbb{E}[X \mid Y = 1] = \frac{2}{10} = \frac{1}{5}, \qquad \mathbb{E}[X \mid Y = 2] = 0.$$

Следователно стойностите на $\mathbb{E}[X \mid Y]$ са $2/5, 1/5, 0$ (с вероятности $25/36, 10/36, 1/36$).

Свойства на условното математическо очакване

За интегруеми X, Z и константи a, b имаме:

а) *Линейност:*

$$\mathbb{E}[aX + bZ \mid Y] = a\mathbb{E}[X \mid Y] + b\mathbb{E}[Z \mid Y].$$

б) *Независимост:* ако $X \perp\!\!\!\perp Y$, то $\mathbb{E}[X \mid Y] = \mathbb{E}[X]$ почти сигурно.

в) *Известна функция на* Y*:* ако $X = f(Y)$, то $\mathbb{E}[X \mid Y] = f(Y) = X$ почти сигурно.

г) *Закон за пълното математическо очакване:*

$$\mathbb{E}[\mathbb{E}[X \mid Y]] = \mathbb{E}[X].$$

Доказателство на последното свойство. В дискретния случай

$$\begin{aligned}\mathbb{E}[\mathbb{E}[X \mid Y]] &= \sum_j \mathbb{E}[X \mid Y = y_j]\,\mathbb{P}(Y = y_j) \\ &= \sum_j \sum_i x_i p_{ij} = \sum_i x_i \mathbb{P}(X = x_i) = \mathbb{E}[X].\end{aligned}$$

Ако $X \perp\!\!\!\perp Y$, то при подходящи условия за интегруемост имаме и

$$\mathbb{E}[f(X, Y) \mid Y = y_j] = \mathbb{E}[f(X, y_j)].$$

Условни разпределения

Нека X, Y са дискретни случайни величини със съвместно разпределение (p_{ij}) и $\mathbb{P}(Y = y_j) > 0$. Тогава

$$\mathbb{P}(X = x_i \mid Y = y_j) = \frac{\mathbb{P}(X = x_i,\, Y = y_j)}{\mathbb{P}(Y = y_j)}$$

За всяко такова j тази фамилия от числа е вероятностно разпределение, тъй като

$$\sum_i \mathbb{P}(X = x_i \mid Y = y_j) = \frac{\sum_i p_{ij}}{\mathbb{P}(Y = y_j)} = 1.$$

Наричаме го *условно разпределение на X при $Y = y_j$*.

Пример. В примера с двата зара условното разпределение на X при $Y = 0$ е

$X \mid (Y = 0)$	0	1	2	сума
$\mathbb{P}$	$\frac{16}{25}$	$\frac{8}{25}$	$\frac{1}{25}$	1

Лекция 8

Непрекъснати случайни величини

Вече разгледахме дискретните случайни величини, за които вероятността е разпределена между краен или изброим брой стойности. В много задачи обаче е по-удобно да описваме разпределението чрез плътност. Такива разпределения наричаме *абсолютно непрекъснати*, или, за краткост, *непрекъснати*.

Защо е необходим този модел? Например:

а) При голямо n величина със стойности $1/n, 2/n, \ldots, n/n$ може да се приближава с модел върху интервал (например при температура/енергия, измерена с много малка точност).

б) Времето T до настъпване на събитие може да се измерва само с точност до интервал, например $T \in (0, 3)$.

в) Разпределенията с плътност позволяват вероятности да се пресмятат посредством интеграли, а не чрез суми.

г) Фундаментални гранични закони са непрекъснати случайни величини.

Дефиниция. Нека $V = (\Omega, \mathcal{A}, \mathbb{P})$ е вероятностно пространство и $X : \Omega \to \mathbb{R}$ е случайна величина. Казваме, че X има *вероятностна плътност* $f_X : \mathbb{R} \to [0, \infty)$, ако f_X е измерима и

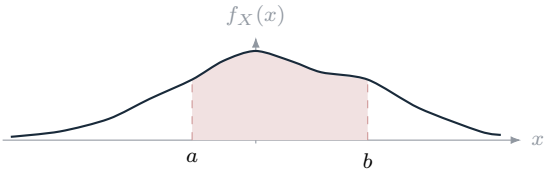
а) $f_X(x) \geq 0$ за всяко $x \in \mathbb{R}$;

б) $\displaystyle\int_{-\infty}^{\infty} f_X(x)\,dx = 1$;

в) за всички $a < b$,

$$\mathbb{P}\left(X \in (a, b)\right) = \int_a^b f_X(x)\,dx.$$

Такава случайна величина наричаме *непрекъсната*.



Пример. Нека размерът на загуба, покривана от застрахователна полица, е $R = 100\,000X$ лв., където X има плътност

$$f_X(x) = \begin{cases} 5(1-x)^4, & 0 < x < 1, \\ 0, & \text{иначе.} \end{cases}$$

Вероятността загубата да надхвърли $10\,000$ лв. е

$$\mathbb{P}\left(R > 10\,000\right) = \mathbb{P}\left(X > \tfrac{1}{10}\right) = 5\int_{1/10}^{1} (1-x)^4\,dx = \left(\frac{9}{10}\right)^5$$
$$= 0.59049 \approx 0.59.$$

Основни свойства на плътността

Теорема. Ако X е непрекъсната, то за всяко $c \in \mathbb{R}$ е изпълнено

$$\mathbb{P}(X = c) = 0.$$

Доказателство. От

$$\{X = c\} = \bigcap_{n \geq 1} \{c - 1/n < X < c + 1/n\}$$

и непрекъснатостта на вероятността отгоре следва

$$\mathbb{P}(X = c) = \lim_{n \to \infty} \int_{c-1/n}^{c+1/n} f_X(x)\, dx = 0.$$

Последното равенство следва от свойствата на интеграла. □

Функция на разпределение

Дефиниция. Функцията на разпределение на X е

$$F_X(x) = \mathbb{P}(X \leq x), \qquad x \in \mathbb{R}.$$

Ако X има плътност f_X, то

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\, dt.$$

Ако f_X е непрекъсната в x_0, то F_X е диференцируема в тази точка и

$$F_X'(x_0) = f_X(x_0).$$

В общия случай равенството $F_X' = f_X$ е вярно почти навсякъде.

Бел.: Използваме конвенцията $F_X(x) = \mathbb{P}(X \leq x)$. За случайна величина с плътност $\mathbb{P}(X < x) = \mathbb{P}(X \leq x)$, тъй като $\mathbb{P}(X = x) = 0$. Самото наличие на неизброимо много стойности не е достатъчно, за да има величината плътност, но в този курс няма да дискутираме такива случаи.

Смяна на променливата

Нека X има плътност f_X и $Y = g(X)$. Как да определим плътността f_Y, ако тя съществува?

Пример. Ако $g(x) = 1_{x \geq 0}$, то $Y = g(X)$ приема само стойности 0 и 1; следователно Y е дискретна случайна величина, независимо че X има плътност.

Теорема (преобразуване на плътност). Нека X има плътност f_X върху интервал I, а $g : I \to g(I)$ е строго монотонна, непрекъснато диференцируема функция с $g'(x) \neq 0, x \in I$. Тогава $Y = g(X)$ има плътност

$$f_Y(y) = f_X\big(g^{-1}(y)\big)\,\big|(g^{-1})'(y)\big|, \quad y \in g(I),$$

и $g(y) = 0, y \notin g(I)$.

Доказателство. Ако g е растяща, то за $(a, b) \subseteq g(I)$:

$$\begin{aligned}
\mathbb{P}(a < Y < b) &= \mathbb{P}\big(g^{-1}(a) < X < g^{-1}(b)\big) \\
&= \int_{g^{-1}(a)}^{g^{-1}(b)} f_X(x)\, dx \\
&= \int_a^b f_X\big(g^{-1}(y)\big)(g^{-1})'(y)\, dy.
\end{aligned}$$

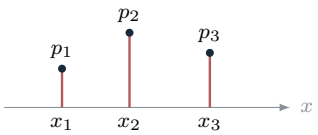
Ако g е намаляваща, границите на интегриране разменят местата си и се получава модулът на производната. □

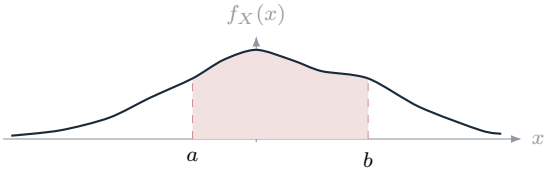
Математическо очакване и дисперсия

За дискретна случайна величина с разпределение $\mathbb{P}(X = x_i) = p_i$ математическото очакване е $\sum_i x_i p_i$. При величина с плътност сумата се заменя с интеграл:

Дефиниция. Ако X има плътност f_X и $\int_{\mathbb{R}} |x| f_X(x)\,dx < \infty$, дефинираме

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f_X(x)\,dx.$$





Ако $Y = g(X)$ и $\int_{\mathbb{R}} |g(x)| f_X(x)\,dx < \infty$, то

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x)\,dx.$$

Това следва от формулата за преобразуване на плътността, когато g е монотонна и диференцируема; общото твърдение важи за всяка измерима g, за която съществува посоченият интеграл.

Дефиниция. Ако $\mathbb{E}\left[X^2\right] < \infty$, *дисперсията* на X е

$$\mathrm{D}X = \mathbb{E}\left[(X - \mathbb{E}[X])^2\right] = \int_{-\infty}^{\infty} (x - \mathbb{E}[X])^2 f_X(x)\,dx.$$

Числото $\sqrt{\mathrm{D}X}$ се нарича *стандартно отклонение*.

Като следствие от свойствата на математическото очакване и дисперсията имаме:

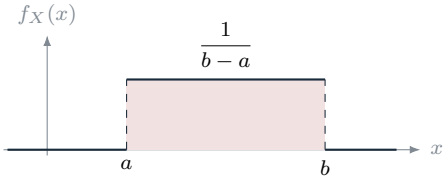
$$\mathbb{E}[c] = c, \qquad \mathbb{E}[aX + b] = a\mathbb{E}[X] + b,$$
$$\mathrm{D}c = 0, \qquad \mathrm{D}(aX + b) = a^2 \mathrm{D}X.$$

За интегрируеми X и Y е изпълнено $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$, а при независими X и Y с крайни втори моменти $\mathrm{D}(X + Y) = \mathrm{D}X + \mathrm{D}Y$.

Видове непрекъснати разпределения

А) Равномерно разпределение. Означаваме с $X \sim U(a, b)$, $a < b$, когато

$$f_X(x) = \begin{cases} \dfrac{1}{b-a}, & a < x < b, \\ 0, & \text{иначе.} \end{cases}$$



След пресмятане на съответните интеграли получаваме

$$\mathbb{E}[X] = \frac{a+b}{2}, \qquad \mathbb{E}\left[X^2\right] = \frac{a^2 + ab + b^2}{3}, \qquad \mathrm{D}X = \frac{(b-a)^2}{12}.$$

Функцията на разпределение е

$$F_X(x) = \begin{cases} 0, & x < a, \\ \dfrac{x-a}{b-a}, & a \le x < b, \\ 1, & x \ge b. \end{cases}$$

Ако $X \sim U(a,b)$, то

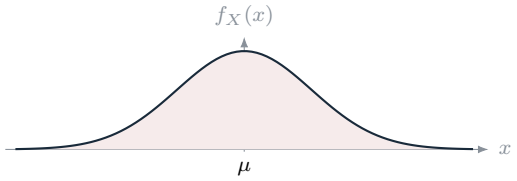
$$Y = \frac{X-a}{b-a} \sim U(0,1), \qquad \text{тоест} \qquad X = a + (b-a)Y.$$

Действително, за $y \in (0,1)$ преобразуването има $g^{-1}(y) = a + (b-a)y$ и

$$f_Y(y) = f_X\big(a + (b-a)y\big)(b-a) = 1.$$

Б) Нормално (Гаусово) разпределение. Пишем $X \sim N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma > 0$, когато

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \qquad x \in \mathbb{R}.$$



Стандартното нормално разпределение е $N(0,1)$, с плътност

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \ x \in \mathbb{R}.$$

За $X \sim N(\mu, \sigma^2)$ полагаме

$$Z = \frac{X-\mu}{\sigma}.$$

Използваме преобразуването $g(x) = \frac{x-\mu}{\sigma}$, за което производната на обратната функция е σ. Тогава

$$f_Z(z) = f_X(\sigma z + \mu)\sigma = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}, \qquad Z \sim N(0,1).$$

За стандартна нормална величина Z от симетрията следва $\mathbb{E}[Z] = 0$. Освен това, интегриране по части дава

$$\mathbb{E}\left[Z^2\right] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z^2 e^{-z^2/2}\, dz = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-z^2/2}\, dz = 1.$$

Следователно

$$\mathbb{E}[X] = \mu, \qquad \mathrm{D}X = \sigma^2.$$

Функцията на разпределение на стандартното нормално разпределение се означава с Φ:

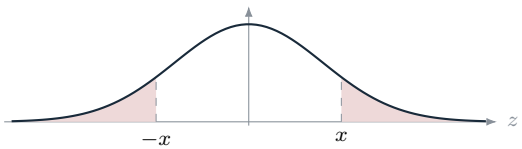
$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-t^2/2}\, dt.$$

За $X \sim N(\mu, \sigma^2)$ имаме

$$F_X(x) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

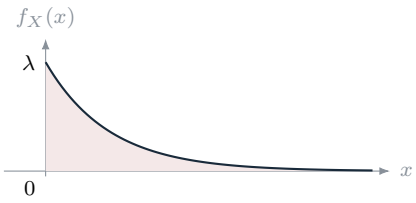
По симетрия на нормалната плътност

$$\Phi(-x) = 1 - \Phi(x), \qquad \mathbb{P}(Z > x) = 1 - \Phi(x) = \Phi(-x).$$



В) Експоненциално разпределение. Пишем $X \sim \mathrm{Exp}(\lambda)$, $\lambda > 0$, ако

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$



Наистина, $\int_0^\infty \lambda e^{-\lambda x}\,dx = 1$. Получаваме

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1 - e^{-\lambda x}, & x \geq 0, \end{cases} \qquad \mathbb{P}\left(X > x\right) = e^{-\lambda x} \quad (x \geq 0).$$

Съответно

$$\mathbb{E}\left[X\right] = \frac{1}{\lambda}, \qquad \mathrm{D}X = \frac{1}{\lambda^2}.$$

Липса на памет. За всички $x, y \geq 0$,

$$\begin{aligned} \mathbb{P}\left(X > x + y \mid X > y\right) &= \frac{\mathbb{P}\left(X > x + y\right)}{\mathbb{P}\left(X > y\right)} \\ &= \frac{e^{-\lambda(x+y)}}{e^{-\lambda y}} = e^{-\lambda x} = \mathbb{P}\left(X > x\right). \end{aligned}$$

Бел.: Това е непрекъснатият аналог на свойството за липса на памет при геометричното разпределение.

Всяка плътност задава разпределение

Нека $f : \mathbb{R} \to [0, \infty)$ е измерима и $\int_{\mathbb{R}} f(x)\,dx = 1$. Тогава можем да дефинираме вероятностна мярка върху бореловите множества с

$$\mathbb{P}(A) = \int_A f(x)\,dx, \qquad A \in \mathcal{B}(\mathbb{R}).$$

В каноничното пространство $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P})$ тъждествената функция $X(\omega) = \omega$ е случайна величина с плътност f. По-специално

$$\mathbb{P}\left(X \in \mathbb{R}\right) = \int_{-\infty}^{\infty} f(x)\,dx = 1 \qquad \text{и} \qquad \mathbb{P}\left(X = c\right) = 0 \quad (c \in \mathbb{R}),$$

като последното равенство следва например от

$$0 \leq \mathbb{P}\left(X = c\right) \leq \int_{c-\varepsilon}^{c+\varepsilon} f(x)\,dx \underset{\varepsilon \downarrow 0}{\longrightarrow} 0.$$

Лекция 9

Непрекъснати съвместни разпределения

Дефиниция. Нека $X = (X_1, \ldots, X_n)$ е вектор от случайни величини върху вероятностното пространство $(\Omega, \mathcal{A}, \mathbb{P})$. Казваме, че X има *съвместна плътност* $f_X = f_{X_1,\ldots,X_n} : \mathbb{R}^n \to [0, \infty)$, ако

1) $f_X(x_1, \ldots, x_n) \geq 0$ за всички $(x_1, \ldots, x_n) \in \mathbb{R}^n$;

2) $\displaystyle\int_{\mathbb{R}^n} f_X(x_1, \ldots, x_n)\, dx_1 \cdots dx_n = 1$;

3) за всяко борелово множество $D \subseteq \mathbb{R}^n$,

$$\mathbb{P}(X \in D) = \int_D f_X(x_1, \ldots, x_n)\, dx_1 \cdots dx_n.$$

Дефиниция. Ако $f : \mathbb{R}^n \to [0, \infty)$ е съвместна плътност, то множеството

$$D_f = \{x \in \mathbb{R}^n : f(x) > 0\}$$

наричаме *област на положителност* на плътността.

Бел.: Понятието „носител“ често се използва и в топологичния смисъл $\operatorname{supp}(f) = \overline{\{f > 0\}}$ *(с подходящата уговорка за версии на плътността).*

Дефиниция. Нека $X = (X_1, \ldots, X_n)$ има съвместна плътност f_X. Плътността на X_i се нарича *маргинална плътност* и се получава чрез интегриране по всички останали координати:

$$f_{X_i}(x_i) = \int_{\mathbb{R}^{n-1}} f_X(x_1, \ldots, x_n)\, dx_1 \cdots dx_{i-1}\, dx_{i+1} \cdots dx_n.$$

Съвместна функция на разпределение

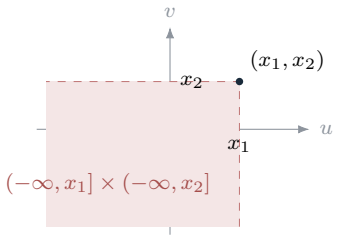
Дефиниция. За $X = (X_1, \ldots, X_n)$ функцията

$$F_X(x_1, \ldots, x_n) = \mathbb{P}(X_1 \leq x_1, \ldots, X_n \leq x_n)$$

се нарича *съвместна функция на разпределение*.

За $n = 2$ и при наличие на съвместна плътност,

$$F_{X_1,X_2}(x_1, x_2) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} f_{X_1,X_2}(u, v)\, dv\, du.$$



При непрекъсната плътност f_{X_1,X_2} имаме

$$\frac{\partial^2 F_{X_1,X_2}}{\partial x_1 \partial x_2}(x_1, x_2) = f_{X_1,X_2}(x_1, x_2).$$

Обратно, подходящата смесена производна възстановява съвместната плътност, когато такава съществува.

Дефиниция. Случайните величини X_1 и X_2 са *независими* тогава и само тогава, когато за всички $x_1, x_2 \in \mathbb{R}$

$$F_{X_1,X_2}(x_1,x_2) = F_{X_1}(x_1)F_{X_2}(x_2).$$

Ако имат съвместна плътност, това е еквивалентно на

$$f_{X_1,X_2}(x_1,x_2) = f_{X_1}(x_1)f_{X_2}(x_2) \quad \forall x_1,x_2 \in \mathbb{R}.$$

Маргинални плътности и математическо очакване

Дефиниция. Нека $X = (X_1,\ldots,X_n)$ има съвместна плътност. За подсемейството $(X_{i_1},\ldots,X_{i_k})$ маргиналната плътност се намира, като интегрираме съвместната плътност по останалите $n-k$ координати.
По-специално при $n=2$,

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1,X_2}(x_1,x_2)\,dx_2, \qquad f_{X_2}(x_2) = \int_{-\infty}^{\infty} f_{X_1,X_2}(x_1,x_2)\,dx_1.$$

Нека $g:\mathbb{R}^n \to \mathbb{R}$ е измерима функция и $\mathbb{E}\left[|g(X)|\right] < \infty$. Тогава

$$\mathbb{E}\left[g(X)\right] = \int_{\mathbb{R}^n} g(x_1,\ldots,x_n) f_X(x_1,\ldots,x_n)\,dx_1\cdots dx_n.$$

Следствие (линейност на математическото очакване). Нека X_1, X_2 са съвместно абсолютно непрекъснати и имат крайни математически очаквания. Тогава

$$\mathbb{E}\left[X_1+X_2\right] = \mathbb{E}\left[X_1\right] + \mathbb{E}\left[X_2\right].$$

Доказателство. За $g(x_1,x_2) = x_1+x_2$ получаваме

$$\begin{aligned}\mathbb{E}\left[X_1+X_2\right] &= \int_{\mathbb{R}^2} (x_1+x_2) f_{X_1,X_2}(x_1,x_2)\,dx_1\,dx_2 \\ &= \int_{\mathbb{R}} x_1 f_{X_1}(x_1)\,dx_1 + \int_{\mathbb{R}} x_2 f_{X_2}(x_2)\,dx_2 \\ &= \mathbb{E}\left[X_1\right] + \mathbb{E}\left[X_2\right]. \qquad \square\end{aligned}$$

При независими X_1, X_2 и съществуващи математически очаквания на съответните произведения имаме също

$$\mathbb{E}\left[X_1X_2\right] = \mathbb{E}\left[X_1\right]\mathbb{E}\left[X_2\right].$$

Следствие. Ако X_1 и X_2 са независими и имат крайни дисперсии, то

$$\mathrm{D}(X_1+X_2) = \mathrm{D}X_1 + \mathrm{D}X_2.$$

Доказателство. С $\mu_i = \mathbb{E}\left[X_i\right]$ и $u = x_1-\mu_1$, $v = x_2-\mu_2$, използвайки независимостта, намираме

$$\begin{aligned}\mathrm{D}(X_1+X_2) &= \int_{\mathbb{R}^2} \big((x_1-\mu_1)+(x_2-\mu_2)\big)^2 f_{X_1}(x_1)f_{X_2}(x_2)\,dx_1\,dx_2 \\ &= \mathbb{E}\left[(X_1-\mu_1)^2\right] + \mathbb{E}\left[(X_2-\mu_2)^2\right] + 2\mathbb{E}\left[X_1-\mu_1\right]\mathbb{E}\left[X_2-\mu_2\right] \\ &= \mathrm{D}X_1 + \mathrm{D}X_2. \qquad \square\end{aligned}$$

Смяна на променливите

Теорема. Нека $X = (X_1, X_2)$ има съвместна плътност f_X и

$$g : D \longrightarrow g(D) \subseteq \mathbb{R}^2, \qquad \begin{pmatrix} Y_1 \\ Y_2 \end{pmatrix} = g\begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$$

е диференцируемо, еднозначно обратимо преобразуване на областта D, в която X попада с вероятност едно. Нека обратното преобразуване $h = g^{-1}$ е непрекъснато диференцируемо, а якобианът

$$J_h(y_1, y_2) = \det \begin{pmatrix} \dfrac{\partial h_1}{\partial y_1} & \dfrac{\partial h_1}{\partial y_2} \\ \dfrac{\partial h_2}{\partial y_1} & \dfrac{\partial h_2}{\partial y_2} \end{pmatrix}$$

е ненулев за $(y_1, y_2) \in g(D)$. Тогава $Y = g(X)$ има съвместна плътност

$$f_Y(y_1, y_2) = f_X\big(h_1(y_1, y_2), h_2(y_1, y_2)\big)\,|J_h(y_1, y_2)|\,, \quad y \in g(D),$$

и $f_Y(y) = 0$ извън $g(D)$.

Доказателство. За борелово $A \subseteq g(D)$,

$$\begin{aligned} \mathbb{P}\,(Y \in A) = \mathbb{P}\left(X \in g^{-1}(A)\right) &= \int_{g^{-1}(A)} f_X(x)\,dx \\ &= \int_A f_X\big(h(y)\big)|J_h(y)|\,dy. \end{aligned}$$

Това дава търсената плътност. □

Пример. Нека $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, \ldots, n$, са независими. Тогава

$$\sum_{i=1}^{n} X_i \sim N\left(\sum_{i=1}^{n} \mu_i, \sum_{i=1}^{n} \sigma_i^2\right).$$

Доказателство за $n = 2$**.** Полагаме $X_i = \mu_i + V_i$, където $V_i \sim N(0, \sigma_i^2)$ са независими. Нека

$$W = V_1, \qquad Z = V_1 + V_2.$$

Това е обратимо преобразуване с

$$V_1 = W, \qquad V_2 = Z - W, \qquad \left|\det \frac{\partial(V_1, V_2)}{\partial(W, Z)}\right| = 1.$$

Следователно

$$f_{W,Z}(w, z) = \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{w^2}{2\sigma_1^2} - \frac{(z-w)^2}{2\sigma_2^2}\right).$$

За маргиналната плътност на Z получаваме

$$f_Z(z) = \frac{1}{2\pi\sigma_1\sigma_2} \int_{-\infty}^{\infty} \exp\left(-\frac{1}{2}\left[\frac{w^2}{\sigma_1^2} + \frac{(z-w)^2}{\sigma_2^2}\right]\right) dw.$$

Тъй като

$$\frac{w^2}{\sigma_1^2} + \frac{(z-w)^2}{\sigma_2^2} = \frac{\sigma_1^2 + \sigma_2^2}{\sigma_1^2\sigma_2^2}\left(w - \frac{\sigma_1^2 z}{\sigma_1^2 + \sigma_2^2}\right)^2 + \frac{z^2}{\sigma_1^2 + \sigma_2^2},$$

интегралът се свежда до гаусов и

$$f_Z(z) = \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} \exp\left(-\frac{z^2}{2(\sigma_1^2 + \sigma_2^2)}\right).$$

Следователно $Z \sim N(0, \sigma_1^2 + \sigma_2^2)$ и твърдението за $X_1 + X_2$ следва чрез добавяне на $\mu_1 + \mu_2$. Общият случай се получава по индукция. □

Гама-разпределение

Дефиниция. Казваме, че $X \sim \Gamma(\alpha, \beta)$, $\alpha, \beta > 0$, ако има плътност

$$f_X(x) = \begin{cases} \dfrac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0, \\ 0, & x \le 0. \end{cases}$$

Тук $\Gamma(\alpha) = \displaystyle\int_0^\infty t^{\alpha-1} e^{-t}\, dt$ е гама-функцията на Ойлер.

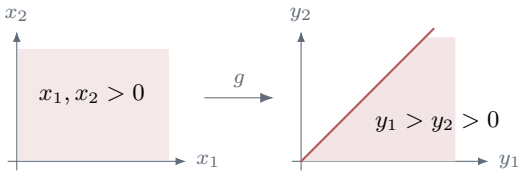
Пример. За $\alpha = \beta = 1$ получаваме експоненциалното разпределение с параметър 1. При $\alpha = 1$ и произволно $\beta > 0$ получаваме експоненциално разпределение с параметър β.

Теорема. Нека $X_1, \ldots, X_n$ са независими, $X_i \sim \Gamma(\alpha_i, \beta)$ и $\alpha_i, \beta > 0$. Тогава

$$Y = \sum_{i=1}^n X_i \sim \Gamma\left(\sum_{i=1}^n \alpha_i, \beta\right).$$

Доказателство за $n = 2$. Нека $Y_1 = X_1 + X_2$, $Y_2 = X_2$. Обратното преобразуване е

$$X_1 = Y_1 - Y_2, \quad X_2 = Y_2, \quad \left|\det \frac{\partial(X_1, X_2)}{\partial(Y_1, Y_2)}\right| = 1.$$



Тъй като $X_1, X_2 > 0$, новата област е $y_1 > y_2 > 0$. По теоремата за смяна на променливите

$$f_{Y_1,Y_2}(y_1, y_2) = \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} (y_1 - y_2)^{\alpha_1-1} y_2^{\alpha_2-1} e^{-\beta y_1}, \quad y_1 > y_2 > 0.$$

Интегрираме по y_2 и полагаме $u = y_2/y_1$:

$$\begin{aligned} f_{Y_1}(y_1) &= \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} e^{-\beta y_1} \int_0^{y_1} (y_1 - v)^{\alpha_1-1} v^{\alpha_2-1}\, dv \\ &= \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} y_1^{\alpha_1+\alpha_2-1} e^{-\beta y_1} \int_0^1 (1-u)^{\alpha_1-1} u^{\alpha_2-1}\, du \\ &= \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1+\alpha_2)} y_1^{\alpha_1+\alpha_2-1} e^{-\beta y_1}, \qquad y_1 > 0, \end{aligned}$$

като използвахме формулата за бета-функцията

$$B(a, b) = \int_0^1 u^{a-1}(1-u)^{b-1}\, du = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}.$$

Твърдението следва. □

Теорема. Ако $Y \sim \Gamma(\alpha, \beta)$, то

$$\mathbb{E}[Y] = \frac{\alpha}{\beta}, \qquad \mathrm{D}Y = \frac{\alpha}{\beta^2}.$$

Доказателство. С $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$ намираме

$$\mathbb{E}[Y] = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty x^\alpha e^{-\beta x}\, dx = \frac{\Gamma(\alpha+1)}{\beta\Gamma(\alpha)} = \frac{\alpha}{\beta},$$
$$\mathbb{E}\left[Y^2\right] = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty x^{\alpha+1} e^{-\beta x}\, dx = \frac{\alpha(\alpha+1)}{\beta^2}.$$

Следователно

$$\mathrm{D}Y = \mathbb{E}\left[Y^2\right] - \mathbb{E}[Y]^2 = \frac{\alpha}{\beta^2}. \qquad \square$$

Хи-квадрат разпределение

Дефиниция. Казваме, че X има *χ^2-разпределение с n степени на свобода*, ако

$$X \sim \Gamma\left(\frac{n}{2}, \frac{1}{2}\right), \qquad n \in \mathbb{N},\ n \geq 1.$$

Означаваме $X \sim \chi^2(n)$.

Следствие. Ако $X \sim \chi^2(n)$, то

$$\mathbb{E}[X] = n, \qquad \mathrm{D}X = 2n.$$

Теорема. Нека $Z_1, \ldots, Z_n$ са независими стандартни нормални случайни величини. Тогава

$$\sum_{i=1}^n Z_i^2 \sim \chi^2(n).$$

Доказателство. По теоремата за гама-разпределенията е достатъчно да покажем, че $Z_1^2 \sim \Gamma(\frac{1}{2}, \frac{1}{2})$. Нека $Z \sim N(0,1)$. За $x > 0$,

$$\mathbb{P}\left(Z^2 \leq x\right) = \mathbb{P}\left(-\sqrt{x} \leq Z \leq \sqrt{x}\right) = \frac{2}{\sqrt{2\pi}} \int_0^{\sqrt{x}} e^{-u^2/2}\, du.$$

След диференциране получаваме

$$f_{Z^2}(x) = \frac{1}{\sqrt{2\pi}} x^{-1/2} e^{-x/2} = \frac{(1/2)^{1/2}}{\Gamma(1/2)} x^{1/2-1} e^{-x/2}, \quad x > 0,$$

понеже $\Gamma(1/2) = \sqrt{\pi}$. Това е плътността на $\Gamma(\frac{1}{2}, \frac{1}{2})$. $\square$

Разпределение на Стюдент

Дефиниция. Нека $Z \sim N(0,1)$, $X \sim \chi^2(n)$ и $Z \perp\!\!\!\perp X$. Тогава случайна величина

$$T_n = \frac{Z}{\sqrt{X/n}}$$

има *t-разпределение на Стюдент с n степени на свобода*. Означаваме $T_n \sim t(n)$.

Лекция 10

Закони за големите числа. Видове сходимост

А. Видове сходимост

Нека $X_n : \Omega \to \mathbb{R}$, $n \geq 1$, е редица от случайни величини, дефинирани върху едно и също вероятностно пространство $V = (\Omega, \mathcal{A}, \mathbb{P})$, и X е случайна величина.

Дефиниция. Казваме, че X_n *сходжа почти сигурно* към X, и пишем $X_n \xrightarrow{\text{п.с.}} X$, ако

$$\mathbb{P}\left(\{\omega \in \Omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\}\right) = \mathbb{P}\left(\lim_{n\to\infty} X_n = X\right) = 1.$$

С други думи, ако $C = \{\omega \in \Omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\}$, то $\mathbb{P}(C) = 1$.

Дефиниция. Казваме, че X_n *сходжа по вероятност* към X, и пишем $X_n \xrightarrow{\mathbb{P}} X$, ако за всяко $\varepsilon > 0$

$$\lim_{n\to\infty} \mathbb{P}(\{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon)\} = \lim_{n\to\infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0.$$

Ако $A_{n,\varepsilon} = \{|X_n - X| > \varepsilon\}$, това условие е $\mathbb{P}(A_{n,\varepsilon}) \to 0$.
Нека $F_X(x) = \mathbb{P}(X \leq x)$ е функцията на разпределение на X, а

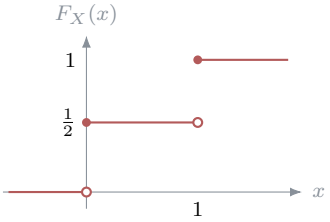
$$C_{F_X} = \{x \in \mathbb{R} : \ F_X \text{ е непрекъсната в } x\}.$$

Дефиниция. Казваме, че X_n *сходжа по разпределение* към X, и пишем $X_n \xrightarrow{d} X$, ако

$$F_{X_n}(x) \longrightarrow F_X(x) \qquad \text{за всяко } x \in C_{F_X}.$$

Пример. Сходимостта по разпределение, за разлика от предишните два вида, се определя само чрез функциите на разпределение. Не е необходимо случайните величини X_n и X да са дефинирани върху едно и също вероятностно пространство.
Пример. Ако $\mathbb{P}(X = 0) = \mathbb{P}(X = 1) = \frac{1}{2}$, то

$$F_X(x) = \begin{cases} 0, & x < 0, \\ \frac{1}{2}, & 0 \leq x < 1, \\ 1, & x \geq 1, \end{cases} \qquad C_{F_X} = \mathbb{R} \setminus \{0, 1\}.$$



В точките на скоковете функцията на разпределение не е непрекъсната. В частност, ако $x \in C_{F_X}$, то $\mathbb{P}(X = x) = 0$.
Теорема. За случайни величини $(X_n)_{n\geq 1}, X$, дефинирани върху едно вероятностно пространство,

$$X_n \xrightarrow{\text{п.с.}} X \quad \Longrightarrow \quad X_n \xrightarrow{\mathbb{P}} X \quad \Longrightarrow \quad X_n \xrightarrow{d} X.$$

Доказателство. Нека първо $X_n \xrightarrow{\text{п.с.}} X$ и да означим с

$$C = \{\omega : \ X_n(\omega) \to X(\omega)\}, \qquad \mathbb{P}(C) = 1.$$

За $r, m \in \mathbb{N}$ полагаме

$$A_{n,r^{-1}} = \{|X_n - X| \geq r^{-1}\}, \qquad B_{m,r} = \bigcup_{n=m}^{\infty} A_{n,r^{-1}}.$$

Тогава

$$C^c = \bigcup_{r\geq 1} \bigcap_{m\geq 1} \bigcup_{n=m}^{\infty} A_{n,r^{-1}} = \bigcup_{r\geq 1} \bigcap_{m\geq 1} B_{m,r}.$$

Множествата $B_{m,r}$ намаляват по m. Следователно, по непрекъснатостта на вероятността отгоре,

$$\lim_{m\to\infty} \mathbb{P}\left(B_{m,r}\right) = \mathbb{P}\left(\bigcap_{m=1}^{\infty} B_{m,r}\right).$$

Но понеже $\mathbb{P}\left(C^c\right) = 0$, то границата е 0 за всяко $r \geq 1$. За дадено $\varepsilon > 0$ избираме r с $1/r < \varepsilon$. Тогава

$$\mathbb{P}\left(|X_n - X| > \varepsilon\right) \leq \mathbb{P}\left(A_{n,r}\right) \leq \mathbb{P}\left(B_{n,r}\right) \longrightarrow 0.$$

Така е доказана първата импликация.

Нека сега $X_n \xrightarrow{\mathbb{P}} X$ и $x \in C_{F_X}$. За $\varepsilon > 0$, използвайки включването на събитията,

$$\begin{aligned}
\{X_n \leq x\} &\subseteq \left(\{X \leq x + \varepsilon\} \cap A_{n,\varepsilon}^c\right) \cup A_{n,\epsilon} \\
\{X_n \leq x\} &\supseteq \{X_n \leq x\} \cap A_{n,\varepsilon}^c \supseteq \{X \leq x - \varepsilon\} \cap A_{n,\varepsilon}^c
\end{aligned}$$

получаваме

$$\begin{aligned}
F_{X_n}(x) &\leq F_X(x + \varepsilon) + \mathbb{P}\left(|X_n - X| > \varepsilon\right), \\
F_{X_n}(x) &\geq F_X(x - \varepsilon) - \mathbb{P}\left(|X_n - X| > \varepsilon\right).
\end{aligned}$$

След преминаване към долна и горна граница:

$$F_X(x - \varepsilon) \leq \liminf_{n\to\infty} F_{X_n}(x) \leq \limsup_{n\to\infty} F_{X_n}(x) \leq F_X(x + \varepsilon).$$

Непрекъснатостта на F_X в x позволява $\varepsilon \downarrow 0$, откъдето $F_{X_n}(x) \to F_X(x)$. □

Теорема. Ако $X_n \xrightarrow{d} c$ за някаква константа $c \in \mathbb{R}$, то $X_n \xrightarrow{\mathbb{P}} c$.

Доказателство. Разпределението на константата е

$$F_c(x) = \begin{cases} 0, & x < c, \\ 1, & x \geq c, \end{cases} \qquad C_{F_c} = \mathbb{R} \setminus \{c\}.$$

За всяко $\varepsilon > 0$ точките $c - \varepsilon$ и $c + \varepsilon$ са точки на непрекъснатост и

$$\begin{aligned}
\mathbb{P}\left(|X_n - c| > \varepsilon\right) &= \mathbb{P}\left(X_n < c - \varepsilon\right) + \mathbb{P}\left(X_n > c + \varepsilon\right) \\
&\leq F_{X_n}(c - \varepsilon) + 1 - F_{X_n}(c + \varepsilon) \longrightarrow 0 + 1 - 1 = 0.
\end{aligned}$$

Следователно $X_n \xrightarrow{\mathbb{P}} c$. □

Б. Неравенства на Марков и Чебишов

Как да оценяваме вероятността от голямо отклонение на случайна величина от нейното математическо очакване?

Неравенство на Марков. Ако $Z \geq 0$ и $\mathbb{E}\left[Z\right] < \infty$, то за всяко $a > 0$

$$\mathbb{P}\left(Z > a\right) \leq \frac{\mathbb{E}\left[Z\right]}{a}.$$

Неравенство на Чебишов. Ако $\mathbb{E}\left[X^2\right] < \infty$, то за всяко $a > 0$

$$\mathbb{P}\left(|X - \mathbb{E}\left[X\right]| > a\right) \leq \frac{\mathrm{D}X}{a^2}.$$

Доказателство. За $Y = (X - \mathbb{E}\left[X\right])^2 \geq 0$ имаме

$$\begin{aligned}
\mathrm{D}X &= \mathbb{E}\left[(X - \mathbb{E}\left[X\right])^2\right] \\
&\geq \mathbb{E}\left[(X - \mathbb{E}\left[X\right])^2 1_{\{|X - \mathbb{E}[X]| > a\}}\right] \\
&\geq a^2 \mathbb{P}\left(|X - \mathbb{E}\left[X\right]| > a\right).
\end{aligned}$$

Това доказва неравенството. □

Обобщение. Ако $p > 0$ и $\mathbb{E}\left[|X - \mathbb{E}[X]|^p\right] < \infty$, то

$$\mathbb{P}\left(|X - \mathbb{E}[X]| > a\right) \leq \frac{\mathbb{E}\left[|X - \mathbb{E}[X]|^p\right]}{a^p}.$$

Ако $\mathbb{E}[X] = 0$, получаваме

$$\mathbb{P}\left(|X| > a\right) \leq \frac{\mathbb{E}\left[|X|^p\right]}{a^p}.$$

Пример. При $a = b\sqrt{\mathrm{D}X}$ ($\mathrm{D}X > 0$) неравенството на Чебишов дава

$$\mathbb{P}\left(|X - \mathbb{E}[X]| > b\sqrt{\mathrm{D}X}\right) \leq \frac{1}{b^2}, \qquad b > 0.$$

В частност при $b = 10$ вероятността за отклонение с повече от десет стандартни отклонения е не по-голяма от $1/100$.

В. Закони за големите числа

Дефиниция. Нека $(X_i)_{i\geq 1}$ е редица от случайни величини с крайно математическо очакване. Казваме, че за нея е в сила *слабият закон за големите числа (СЗГЧ)*, ако

$$\frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}[X_i]) \xrightarrow{\mathbb{P}} 0.$$

Ако $\mathbb{E}[X_i] = \mu$ за всяко i, то условието е еквивалентно на

$$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{\mathbb{P}} \mu.$$

Теорема (слаб закон за големите числа). Нека $(X_i)_{i\geq 1}$ са независими, еднакво разпределени случайни величини с $\mathrm{D}X_1 < \infty$. Тогава

$$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{\mathbb{P}} \mathbb{E}[X_1].$$

Доказателство. Нека $S_n = \sum_{i=1}^{n} X_i$ и $\mu = \mathbb{E}[X_1]$. По независимост

$$\mathrm{D}\left(\frac{S_n}{n}\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{D}X_i = \frac{\mathrm{D}X_1}{n}.$$

От неравенството на Чебишов за всяко $\varepsilon > 0$

$$\mathbb{P}\left(\left|\frac{S_n}{n} - \mu\right| > \varepsilon\right) \leq \frac{\mathrm{D}X_1}{n\varepsilon^2} \longrightarrow 0.$$

Следователно $S_n/n \xrightarrow{\mathbb{P}} \mu$. □

Дефиниция. Нека $(X_i)_{i\geq 1}$ е редица от случайни величини с крайно математическо очакване. Казваме, че за нея е в сила *силният закон за големите числа (УЗГЧ)*, ако

$$\frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}[X_i]) \xrightarrow{\text{п.с.}} 0.$$

Теорема (силен закон за големите числа). Нека $(X_i)_{i\geq 1}$ са независими и еднакво разпределени случайни величини с $\mathbb{E}[|X_1|] < \infty$. Тогава

$$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{\text{п.с.}} \mathbb{E}[X_1].$$

Бел.: Това е общата формулировка на силния закон. Доказателството по-долу разглежда специалния случай $\mathbb{E}\left[|X_1|^4\right] < \infty$. То не доказва само по себе си общия случай $\mathbb{E}\left[|X_1|\right] < \infty$.

Доказателство при краен четвърти момент. Полагаме $Y_i = X_i - \mathbb{E}\left[X_i\right]$ и $S_n = \sum_{i=1}^n Y_i$. Тогава Y_i са независими, еднакво разпределени и $\mathbb{E}\left[Y_i\right] = 0$. За всяко $\varepsilon > 0$,

$$\begin{aligned}&\mathbb{P}\left(\bigcup_{k=n}^{\infty}\left\{\left|\frac{S_k}{k}\right| > \varepsilon\right\}\right)\\ &\quad\leq \sum_{k=n}^{\infty}\mathbb{P}\left(\left|\frac{S_k}{k}\right| > \varepsilon\right) \leq \sum_{k=n}^{\infty}\frac{\mathbb{E}\left[S_k^4\right]}{k^4\varepsilon^4}.\end{aligned}$$

При разкриване на четвъртата степен и от независимост всички членове, съдържащи първа степен на някое Y_i, имат нулево математическо очакване. Следователно

$$\begin{aligned}\mathbb{E}\left[S_k^4\right] &= \sum_{i=1}^{k}\mathbb{E}\left[Y_i^4\right] + 6\sum_{1\leq i<j\leq k}\mathbb{E}\left[Y_i^2\right]\mathbb{E}\left[Y_j^2\right]\\ &= k\mathbb{E}\left[Y_1^4\right] + 3k(k-1)(\mathbb{E}\left[Y_1^2\right])^2.\end{aligned}$$

Така

$$\begin{aligned}&\mathbb{P}\left(\bigcup_{k=n}^{\infty}\left\{\left|\frac{S_k}{k}\right| > \varepsilon\right\}\right)\\ &\quad\leq \frac{1}{\varepsilon^4}\sum_{k=n}^{\infty}\left(\frac{\mathbb{E}\left[Y_1^4\right]}{k^3} + \frac{3(\mathbb{E}\left[Y_1^2\right])^2}{k^2}\right) \xrightarrow[n\to\infty]{} 0.\end{aligned}$$

Както преди с

$$C = \{\lim_{k\to\infty}\left|\frac{S_k}{k}\right| = 0\}$$

имаме

$$C^c = \bigcup_{r\geq 1}\bigcap_{m\geq 1}\bigcup_{n=m}^{\infty} A_{n,r^{-1}}$$

където $A_{n,r^{-1}} = \{\left|\frac{S_n}{n}\right| > r^{-1}\}$. Горната сходимост влече $\mathbb{P}\left(C^c\right) = 0$. □

Примери и приложения

1) **Хвърляне на монета.** Ако $X_i \sim \mathrm{Ber}(1/2)$ са независими, то

$$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{\text{п.с.}} \frac{1}{2}.$$

Тоест относителната честота наези се приближава към $1/2$.

2) **Независими опити.** Ако $X_i \sim \mathrm{Ber}(p)$ са независими, то

$$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{\text{п.с.}} p.$$

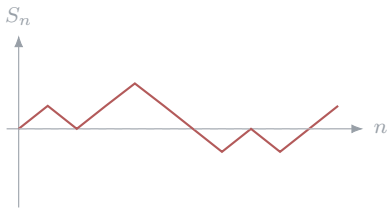
Честотата на успехите се приближава към вероятността за успех. Например приходът на казиното на единица залог се стабилизира около своята средна стойност.

3) **Рулетка.** Ако X_i е нетната печалба на играча при залог на един от двата цвята в европейска рулетка (18 печеливши срещу 19 губещи числа), то

$$\mathbb{E}\left[X_i\right] = \frac{18}{37} - \frac{19}{37} = -\frac{1}{37}, \qquad \frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{\text{п.с.}} -\frac{1}{37}.$$

4) **Случайна разходка.** Нека (X_i) са независими и $\mathbb{P}(X_i = 1) = \mathbb{P}(X_i = -1) = \frac{1}{2}$. Тогава

$$S_n = \sum_{i=1}^{n} X_i, \qquad \frac{S_n}{n} \xrightarrow{\text{п.с.}} 0.$$



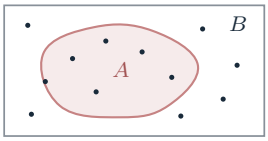
Това не означава, че $S_n \to 0$; то показва само, че S_n расте по-бавно n.

5) **Геометрична вероятност и честоти.** Нека $A \subseteq B \subseteq \mathbb{R}^2$ са измерими множества с $0 < |B| < \infty$, а X_i са независими и равномерно разпределени върху B. Полагаме

$$Y_i = 1_{\{X_i \in A\}}.$$

Тогава $\mathbb{E}[Y_i] = \mathbb{P}(X_i \in A) = |A|/|B|$ и

$$\frac{1}{n}\sum_{i=1}^{n} Y_i \xrightarrow{\text{п.с.}} \frac{|A|}{|B|}.$$



Това е математическата основа на оценяването на вероятности и площи чрез относителни честоти (метод Монте Карло).

Лекция 11

Централна гранична теорема

Теорема (ЦГТ). Нека $(X_i)_{i\geq 1}$ е редица от независими, еднакво разпределени случайни величини с

$$\mathbb{E}[X_1] = \mu, \qquad \mathrm{D}X_1 = \sigma^2 \in (0,\infty), \qquad S_n = \sum_{i=1}^{n} X_i.$$

Тогава за

$$Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}}$$

е в сила

$$Z_n \xrightarrow{d} Z, \qquad Z \sim N(0,1).$$

Коментари и приложения.

1) Припомняме, че функцията на разпределение на стандартната нормална случайна величина е

$$\Phi(x) = \mathbb{P}(Z \leq x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-y^2/2}\, dy.$$

От ЦГТ следва, че за всяко $a < b$,

$$\lim_{n\to\infty} \mathbb{P}\left(a < \frac{S_n - n\mu}{\sigma\sqrt{n}} < b\right) = \Phi(b) - \Phi(a) = \frac{1}{\sqrt{2\pi}} \int_{a}^{b} e^{-y^2/2}\, dy.$$

2) Ако $\overline{X}_n = S_n/n$, то

$$\frac{\overline{X}_n - \mu}{\sigma/\sqrt{n}} = Z_n \xrightarrow{d} Z.$$

Следователно за големи n можем да използваме нормалното приближение

$$\overline{X}_n \overset{\text{прибл.}}{\sim} N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{или формално} \quad \overline{X}_n \approx \mu + \frac{\sigma}{\sqrt{n}} Z.$$

Например за $a > 0$ се получава приближението

$$\mathbb{P}\left(|\overline{X}_n - \mu| > a\right) \approx \mathbb{P}\left(|Z| > a\sqrt{n}/\sigma\right) = \frac{1}{\sqrt{2\pi}} \int_{|y|>a\sqrt{n}/\sigma} e^{-y^2/2}\, dy.$$

Бел.: Последната формула е практическо нормално приближение. Самата ЦГТ не дава относителна асимптотика на вероятностите в опашките при прагове, растящи с n.

3) Ако $\mu = 0$, то от непрекъснатостта на нормалната функция на разпределение следва

$$\mathbb{P}(S_n > 0) = \mathbb{P}(Z_n > 0) \longrightarrow \mathbb{P}(Z > 0) = \frac{1}{2}.$$

Пример. Случайна величина с плътност

$$f_X(x) = \begin{cases} \frac{1}{2}e^{-x}, & x > 0, \\ \frac{1}{4}, & -2 \leq x \leq 0, \\ 0, & \text{иначе}, \end{cases}$$

има

$$\int_{\mathbb{R}} f_X(x)\,dx = 1, \qquad \mathbb{E}[X] = \frac{1}{2}\int_0^\infty xe^{-x}\,dx + \frac{1}{4}\int_{-2}^0 x\,dx = 0,$$

а $\mathbb{E}\left[X^2\right] = 5/3$. Следователно и за независими копия на тази величина можем да приложим ЦГТ.

Пример. Дърпане на въже. Нека X_i е 1 с вероятност $1/2$ и -1 с вероятност $1/2$, независимо за различните i. Ако $S_n = \sum_{i=1}^n X_i$ е резултатната сила, то

$$\mathbb{P}(\text{отбора отдясно побеждава}) = \mathbb{P}(S_n > 0) \longrightarrow \frac{1}{2}.$$

Функции на моментите

Дефиниция. Нека X е случайна величина и $\mathbb{E}\left[e^{tX}\right] < \infty$ за всяко $t \in (-a, a)$, където $a > 0$. Тогава

$$M_X(t) = \mathbb{E}\left[e^{tX}\right], \qquad |t| < a,$$

се нарича *функция на моментите* на X.

За дискретна и за абсолютно непрекъсната случайна величина, съответно,

$$M_X(t) = \sum_i e^{tx_i}\mathbb{P}(X = x_i), \qquad M_X(t) = \int_{-\infty}^\infty e^{tx} f_X(x)\,dx.$$

Дефиниция. Ако $k \geq 1$ е цяло число и съответното математическо очакване е крайно, $\mathbb{E}\left[X^k\right]$ се нарича *момент от ред* k. Величините

$$\mathbb{E}\left[|X|^k\right], \qquad \mathbb{E}\left[|X - \mathbb{E}[X]|^k\right]$$

са съответно *абсолютен* и *централен абсолютен момент* от ред k.

Пример. За дискретна величина с възможни стойности x_i и за величина с плътност f_X имаме

$$\mathbb{E}\left[|X|^k\right] = \sum_i |x_i|^k \mathbb{P}(X = x_i), \qquad \mathbb{E}\left[|X|^k\right] = \int_{\mathbb{R}} |x|^k f_X(x)\,dx.$$

Свойства на функцията на моментите.

а) $M_X(0) = \mathbb{E}[1] = 1$.

б) Ако M_X съществува в околност на нулата, то

$$M_X(t) = \sum_{k=0}^\infty \frac{t^k}{k!}\mathbb{E}\left[X^k\right] \quad \text{за достатъчно малки } |t|.$$

в) За $k \geq 1$,

$$M_X^{(k)}(0) = \mathbb{E}\left[X^k\right].$$

В частност $M_X'(0) = \mathbb{E}[X]$ и $\mathrm{D}X = M_X''(0) - \left(M_X'(0)\right)^2$.

г) Ако $X \perp\!\!\!\perp Y$, то при обща област на съществуване

$$M_{X+Y}(t) = \mathbb{E}\left[e^{t(X+Y)}\right] = \mathbb{E}\left[e^{tX}\right]\mathbb{E}\left[e^{tY}\right] = M_X(t)M_Y(t).$$

д) Ако $M_{X_n}(t) \to M_X(t)$ за всяко t от една и съща околност на 0, в която тези функции са крайни, то

$$X_n \xrightarrow{d} X.$$

Освен това, ако $M_X(t) = M_Y(t)$ в околност на нулата, то $X \stackrel{d}{=} Y$.

е) Ако $Y = aX + b$, то

$$M_Y(t) = \mathbb{E}\left[e^{t(aX+b)}\right] = e^{bt} M_X(at)$$

навсякъде, където двете страни са дефинирани.

Пример. Ако $X \sim N(\mu, \sigma^2)$, то

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right), \qquad t \in \mathbb{R}.$$

Доказателство. За $Z \sim N(0,1)$ чрез допълване до квадрат получаваме

$$\begin{aligned} M_Z(s) &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left(sx - \frac{x^2}{2}\right) dx \\ &= \frac{e^{s^2/2}}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-(x-s)^2/2}\, dx = e^{s^2/2}. \end{aligned}$$

Тъй като $X \stackrel{d}{=} \mu + \sigma Z$, от последното свойство следва формулата. □

Доказателство на ЦГТ чрез функции на моментите

Бел.: Доказателството по-долу изисква допълнителното условие $M_{X_1}(t) < \infty$ за $|t| < a$, $a > 0$. Общата ЦГТ е вярна само при крайна дисперсия и може да се докаже, например, чрез характеристични функции.

Нека $Y_i = (X_i - \mu)/\sigma$. Тогава Y_i са независими, еднакво разпределени и

$$\mathbb{E}[Y_i] = 0, \qquad \mathbb{E}\left[Y_i^2\right] = 1, \qquad Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} Y_i.$$

От съществуването на M_{Y_1} в околност на нулата получаваме

$$M_{Y_1}(u) = 1 + u\mathbb{E}[Y_1] + \frac{u^2}{2}\mathbb{E}\left[Y_1^2\right] + o(u^2) = 1 + \frac{u^2}{2} + o(u^2), \qquad u \to 0.$$

Следователно за всяко фиксирано $t \in \mathbb{R}$ и за достатъчно голямо n

$$\begin{aligned} M_{Z_n}(t) &= \left(M_{Y_1}\left(\frac{t}{\sqrt{n}}\right)\right)^n \\ &= \left(1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)^n \longrightarrow e^{t^2/2} = M_Z(t). \end{aligned}$$

По теоремата за сходимост на функциите на моментите,

$$Z_n \xrightarrow{d} Z \sim N(0,1). \qquad \square$$

Приложение: оценки на дял и нормално приближение

Пример. Нека от N независимо избрани избиратели $X_i = 1$, ако i-тият подкрепя даден кандидат, и $X_i = 0$ в противен случай. Ако вероятността за подкрепа е $p \in (0,1)$, то

$$X_i \sim \mathrm{Be}(p), \qquad \mathbb{E}[X_i] = p, \qquad \mathrm{D}X_i = p(1-p).$$

Относителният дял на подкрепящите в извадката е

$$\widehat{p}_N = \frac{1}{N} \sum_{i=1}^{N} X_i, \qquad \frac{\widehat{p}_N - p}{\sqrt{p(1-p)/N}} \xrightarrow{d} N(0,1).$$

За големи N това дава приближението

$$\mathbb{P}\left(|\widehat{p}_N - p| \le \varepsilon\right) \approx 2\Phi\left(\frac{\varepsilon\sqrt{N}}{\sqrt{p(1-p)}}\right) - 1.$$

Тъй като $p(1-p) \le 1/4$, можем да използваме и по-консервативното нормално приближение

$$\mathbb{P}\left(|\widehat{p}_N - p| \le \varepsilon\right) \gtrsim 2\Phi(2\varepsilon\sqrt{N}) - 1 = 1 - \frac{2}{\sqrt{2\pi}} \int_{2\varepsilon\sqrt{N}}^{\infty} e^{-y^2/2}\, dy.$$

Теорема (неравенство на Бери–Есен). Ако $X_1, X_2, \ldots$ са независими, еднакво разпределени случайни величини с $\mathbb{E}\,[X]_1 = \mu$, $\mathrm{D}X_1 = \sigma^2 \in (0, \infty)$ и $\mathbb{E}\left[|X_1 - \mu|^3\right] < \infty$, то за $Z_n = (\sum_{i=1}^n X_i - n\mu)/(\sigma\sqrt{n})$ е в сила оценката

$$\sup_{x \in \mathbb{R}} \left|\mathbb{P}\left(Z_n \le x\right) - \Phi(x)\right| \le \frac{0.4748\, \mathbb{E}\left[|X_1 - \mu|^3\right]}{\sigma^3\sqrt{n}}.$$

Пример. За $X_1 \sim \mathrm{Be}(p)$, $q = 1 - p$, получаваме

$$\mathbb{E}\left[|X_1 - p|^3\right] = pq\,(p^2 + q^2) \le \frac{1}{8}, \qquad \sigma^2 = pq,$$

и следователно

$$\sup_{x \in \mathbb{R}} \left|\mathbb{P}\left(Z_n \le x\right) - \Phi(x)\right| \le \frac{0.4748\,(p^2 + q^2)}{\sqrt{npq}}.$$

Бел.: Правилото „$n \ge 30$“ е само ориентировъчно: качеството на нормалното приближение зависи и от p, особено когато p е близко до 0 или 1.

Следствие (нормално приближение на биномното разпределение). Нека $X_n \sim \mathrm{Bi}(n, p)$, където $0 < p < 1$ е фиксирано, и $q = 1 - p$. Тогава

$$\frac{X_n - np}{\sqrt{npq}} \xrightarrow{d} Z \sim N(0, 1).$$

В частност за $a < b$

$$\lim_{n \to \infty} \mathbb{P}\left(a < \frac{X_n - np}{\sqrt{npq}} < b\right) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-y^2/2}\, dy.$$

Доказателство. Ако $Y_1, \ldots, Y_n$ са независими и $Y_i \sim \mathrm{Be}(p)$, то $X_n \overset{d}{=} \sum_{i=1}^n Y_i$. Прилагаме ЦГТ с $\mu = p$ и $\sigma^2 = pq$. □

Пример: функция на моментите на гама-разпределение

Нека $X \sim \Gamma(\alpha, \beta)$ с параметри $\alpha > 0$ и $\beta > 0$, като β е *интензитет*. Плътността е

$$f_X(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} 1_{\{x>0\}}.$$

Тогава при $t < \beta$

$$\begin{aligned} M_X(t) &= \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty x^{\alpha-1} e^{-(\beta-t)x}\, dx \\ &= \frac{\beta^\alpha}{(\beta-t)^\alpha \Gamma(\alpha)} \int_0^\infty y^{\alpha-1} e^{-y}\, dy = \left(\frac{\beta}{\beta-t}\right)^\alpha. \end{aligned}$$

Понеже M_X съществува в околност на нулата, всички моменти са крайни, а

$$M_X'(0) = \frac{\alpha}{\beta}, \qquad M_X''(0) = \frac{\alpha(\alpha+1)}{\beta^2}.$$

Следователно

$$\mathbb{E}[X] = \frac{\alpha}{\beta}, \qquad \mathrm{D}X = \frac{\alpha}{\beta^2}.$$

По същия начин за всяко цяло $k \geq 1$ може да се пресметне

$$\mathbb{E}\left[X^k\right] = \frac{\Gamma(\alpha+k)}{\Gamma(\alpha)\,\beta^k}.$$

Лекция 12

Статистика. Точкови оценки

Разглеждаме *генерална съвкупност* от обекти: например всички жители на България, всички студенти или всички избиратели. Интересуваме се от определено свойство на тази съвкупност, но обикновено не можем да изследваме всички обекти. Един подход е да подберем случайно няколко от тях — *извадка* — и въз основа на получените наблюдения да направим изводи за цялата съвкупност.

Пример. При президентските избори в САЩ през 1936 г. прогнозите показват колко важно е извадката да бъде *представителна*: голям, но неправилно подбран набор от отговори може да е по-малко информативен от по-малка, добре подбрана извадка.

Пример. Можем да изследваме средния ръст на студенти от даден випуск или да направим изследване сред избиратели за техните предпочитания.

Постановка на задачата. Нека X е случайна величина, която описва интересуващото ни свойство на генералната съвкупност (например ръст на случайно избран човек). Правим n независими наблюдения, т.е. разглеждаме независими копия $X_1, \dots, X_n$ на X, и полагаме

$$\vec{X} = (X_1, \dots, X_n).$$

Искаме да получим информация за разпределението F_X (а при съществуване на плътност — и за f_X).

Допускаме, че разпределението на X принадлежи на известен параметричен клас. Тогава

$$F_X(x;\theta), \qquad f_X(x;\theta), \qquad \theta \in \Theta \subseteq \mathbb{R}^s,$$

зависят от един или няколко неизвестни параметъра, които искаме да оценим.

Пример. За $X \sim N(\mu, \sigma^2)$, $\sigma^2 > 0$, можем да положим $\theta = (\mu, \sigma^2)$, като

$$f_X(x;\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

Друг пример е разпределението на Бернули $\mathrm{Be}(p)$ с параметър $p \in (0,1)$.

Дефиниция. *Точкова оценка* на параметъра θ се нарича величина от вида

$$\widehat{\theta} = \widehat{\theta}(\vec{X}),$$

т.е. функция на извадката, чиято стойност служи за оценяване на неизвестния параметър. Така $\widehat{\theta}$ е случайна величина (или случаен вектор), а при конкретни наблюдавани стойности $\vec{X} = \vec{x}$ получаваме числова оценка $\widehat{\theta}(\vec{x})$. Функциите на извадката се наричат още *статистики*.

Нашата цел е да построяваме точкови оценки на неизвестните параметри.

А. Метод на максималното правдоподобие

Методът на максималното правдоподобие (МПО, Fisher) използва съвместната плътност (съответно вероятностна функция) на наблюденията. Поради независимостта им тя има вида

$$f_{X_1,\dots,X_n}(x_1, \dots, x_n; \theta) = \prod_{j=1}^{n} f_X(x_j;\theta).$$

За фиксирани наблюдения $\vec{x} = (x_1, \dots, x_n)$ разглеждаме дясната страна като функция на параметъра:

$$L(\vec{x};\theta) = \prod_{j=1}^{n} f_X(x_j;\theta), \qquad \theta \in \Theta.$$

Това е *функцията на правдоподобие*. За $n = 1$ тя съвпада с $f_X(x_1;\theta)$ като функция на θ.

Дефиниция. *Оценка по метода на максималното правдоподобие* е статистика $\widehat{\theta} = \widehat{\theta}(\vec{X})$, за която при наблюденията $\vec{x}$ е в сила

$$L(\vec{x};\widehat{\theta}(\vec{x})) = \sup_{\theta\in\Theta} L(\vec{x};\theta),$$

ако максимумът се достига.

Ако L е гладка функция и максимумът се достига във вътрешна точка на Θ, можем да търсим решението на

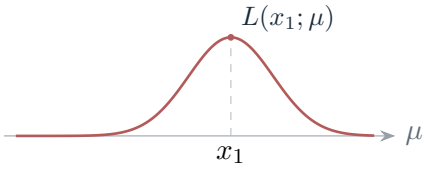
$$\frac{\partial L}{\partial \theta_j} = 0, \quad \text{или, когато } L > 0, \quad \frac{\partial \log L}{\partial \theta_j} = 0, \qquad j = 1,\dots,s.$$

Това са *уравненията на правдоподобието*; след намиране на кандидатите трябва да проверим и границата на параметричното пространство.

Пример. Ако $X_1 \sim N(\mu,\sigma^2)$, а $\sigma^2 > 0$ е известно, то за дадено наблюдение x_1 функцията

$$L(x_1;\mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_1-\mu)^2}{2\sigma^2}\right)$$

е максимална при $\widehat{\mu} = x_1$.



Пример. Нека $X_1,\dots,X_n$ са независими и $X_i \sim U(0,\theta)$, $\theta > 0$. Полагаме $x^* = \max\{x_1,\dots,x_n\}$ и избираме версия на плътността

$$f_X(x;\theta) = \frac{1}{\theta}\, 1_{\{0<x\le\theta\}}.$$

Тогава при положителни наблюдения

$$L(\vec{x};\theta) = \frac{1}{\theta^n}\, 1_{\{\theta\ge x^*\}} = \begin{cases} 0, & 0 < \theta < x^*, \\ \theta^{-n}, & \theta \ge x^*. \end{cases}$$

Понеже θ^{-n} намалява, получаваме

$$\widehat{\theta}_{\text{МПО}} = \max\{X_1,\dots,X_n\}.$$

Бел.: Изборът дали крайната точка се включва в плътността не променя разпределението, но е съществен за това дали правдоподобието достига своя максимум. При версията $1_{\{0<x<\theta\}}/\theta$ се достига само супремум при $\theta \downarrow x^*$.

Пример. Нормално разпределение. Нека $X_1,\dots,X_n$ са независими с разпределение $N(\mu,\sigma^2)$, където и двата параметъра са неизвестни. Поставяме $v = \sigma^2 > 0$. Имаме

$$L(\vec{x};\mu,v) = (2\pi v)^{-n/2} \exp\left(-\frac{1}{2v}\sum_{j=1}^{n}(x_j-\mu)^2\right),$$

следователно

$$\ell(\mu,v) := \log L(\vec{x};\mu,v) = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log v - \frac{1}{2v}\sum_{j=1}^{n}(x_j-\mu)^2.$$

Уравненията на правдоподобието са

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{v}\sum_{j=1}^{n}(x_j - \mu) = 0, \qquad \frac{\partial \ell}{\partial v} = -\frac{n}{2v} + \frac{1}{2v^2}\sum_{j=1}^{n}(x_j - \mu)^2 = 0.$$

От първото уравнение получаваме

$$\widehat{\mu} = \overline{X}_n = \frac{1}{n}\sum_{j=1}^{n} X_j.$$

Ако μ е известно, МПО-оценката за дисперсията е

$$\widehat{\sigma^2} = \frac{1}{n}\sum_{j=1}^{n}(X_j - \mu)^2.$$

Ако μ е неизвестно, заместваме го с $\widehat{\mu}$ и получаваме

$$\widehat{\sigma^2}_{\text{МПО}} = \frac{1}{n}\sum_{j=1}^{n}(X_j - \overline{X}_n)^2.$$

Б. Метод на моментите

Нека разпределението зависи от параметър θ, а първият му теоретичен момент е

$$m_1(\theta) = \mathbb{E}\left[X_1\right].$$

От закона за големите числа при $\mathbb{E}\left[|X_1|\right] < \infty$ знаем, че

$$\overline{X}_n = \frac{1}{n}\sum_{j=1}^{n} X_j \xrightarrow{\mathbb{P}} m_1(\theta).$$

Методът на моментите при един неизвестен параметър се състои в решаването на уравнението

$$m_1(\widehat{\theta}) = \overline{X}_n,$$

когато то има подходящо решение.
При s неизвестни параметъра $\theta = (\theta_1, \ldots, \theta_s)$ използваме първите s момента, ако съществуват:

$$m_k(\theta) = \mathbb{E}\left[X_1^k\right], \qquad \overline{X_n^{(k)}} = \frac{1}{n}\sum_{j=1}^{n} X_j^k, \quad k = 1, \ldots, s,$$

и определяме оценката от системата

$$m_k(\widehat{\theta}) = \overline{X_n^{(k)}}, \qquad k = 1, \ldots, s.$$

Пример. Ако $X \sim U(0, \theta)$, то $\mathbb{E}\left[X\right] = \theta/2$ и методът на моментите дава

$$\widehat{\theta}_{\text{ММО}} = 2\overline{X}_n, \qquad \text{докато} \qquad \widehat{\theta}_{\text{МПО}} = \max_{1 \le j \le n} X_j.$$

Пример. Ако $X \sim N(\mu, \sigma^2)$, то

$$m_1(\theta) = \mu, \qquad m_2(\theta) = \sigma^2 + \mu^2.$$

От уравненията на моментите получаваме

$$\widehat{\mu}_{\text{ММО}} = \overline{X}_n, \qquad \widehat{\sigma^2}_{\text{ММО}} = \frac{1}{n}\sum_{j=1}^{n} X_j^2 - (\overline{X}_n)^2 = \frac{1}{n}\sum_{j=1}^{n}(X_j - \overline{X}_n)^2.$$

Тези оценки съвпадат с оценките по МПО.

Свойства на оценките

Имаме различни начини за оценяване на един параметър. За да сравняваме получените оценки, въвеждаме два основни критерия: *неизместеност* и *състоятелност*.

а) Неизместеност.

Дефиниция. Оценката $\widehat{\theta} = \widehat{\theta}(\vec{X})$ се нарича *неизместена*, ако

$$\mathbb{E}\left[\widehat{\theta}\right] = \theta$$

за всяка стойност на параметъра θ, за която е дефиниран моделът. Разликата $\left|\mathbb{E}\left[\widehat{\theta}\right] - \theta\right|$ се нарича *систематична грешка* (изместване).

Пример. Нека $X_1, \ldots, X_n$ са независими с $\mathbb{E}[X_i] = \mu$. Тогава

$$\mathbb{E}[\widehat{\mu}] = \mathbb{E}\left[\overline{X}_n\right] = \frac{1}{n}\sum_{j=1}^{n}\mathbb{E}[X_j] = \mu,$$

т.е. извадковото средно е неизместена оценка на μ.

При $X_i \sim N(\mu, \sigma^2)$, ако μ е известно, оценката $\widehat{\sigma^2} = n^{-1}\sum_{j=1}^{n}(X_j - \mu)^2$ е неизместена. Ако μ е неизвестно, МПО-оценката има изместване:

$$\begin{aligned}\mathbb{E}\left[\widehat{\sigma^2}_{\text{МПО}}\right] &= \mathbb{E}\left[\frac{1}{n}\sum_{j=1}^{n}X_j^2 - (\overline{X}_n)^2\right] \\ &= (\sigma^2 + \mu^2) - \left(\mu^2 + \frac{\sigma^2}{n}\right) = \left(1 - \frac{1}{n}\right)\sigma^2.\end{aligned}$$

Следователно при $n \geq 2$ коригираната извадкова дисперсия

$$S_n^2 = \frac{1}{n-1}\sum_{j=1}^{n}(X_j - \overline{X}_n)^2 = \frac{n}{n-1}\widehat{\sigma^2}_{\text{МПО}}$$

е неизместена: $\mathbb{E}\left[S_n^2\right] = \sigma^2$.

Пример. Ако $X_i \sim U(0, \theta)$ и $Y = \max_{1\leq i\leq n} X_i$, то

$$F_Y(y) = \left(\frac{y}{\theta}\right)^n, \quad 0 \leq y \leq \theta, \qquad f_Y(y) = \frac{ny^{n-1}}{\theta^n}\,1_{\{0<y<\theta\}}.$$

Ето защо

$$\mathbb{E}[Y] = \int_0^\theta y\frac{ny^{n-1}}{\theta^n}\,dy = \frac{n}{n+1}\,\theta \neq \theta.$$

Така МП-оценката Y е изместена, а оценката

$$\widetilde{\theta} = \frac{n+1}{n}\max_{1\leq i\leq n} X_i$$

е неизместена.



б) Състоятелност.

Дефиниция. Редицата от оценки $\widehat{\theta}_n = \widehat{\theta}_n(X_1, \ldots, X_n)$ е *състоятелна* за параметъра θ, ако

$$\widehat{\theta}_n \xrightarrow[n\to\infty]{\mathbb{P}} \theta, \qquad \text{т.е.} \qquad \lim_{n\to\infty} \mathbb{P}\left(|\widehat{\theta}_n - \theta| > \varepsilon\right) = 0 \quad \text{за всяко } \varepsilon > 0.$$

Ако сходимостта е почти сигурна, оценката се нарича *силно състоятелна*.

Пример. Ако $X_1, X_2, \ldots$ са независими и еднакво разпределени с $\mathbb{E}\left[|X_1|\right] < \infty$ и $\mathbb{E}\left[X_1\right] = \mu$, то по закона за големите числа

$$\overline{X}_n \xrightarrow{\mathbb{P}} \mu \qquad (\text{дори } \overline{X}_n \to \mu \text{ п.с.}),$$

следователно $\widehat{\mu}_n = \overline{X}_n$ е състоятелна оценка на μ.

Ако $\theta_k = \mathbb{E}\left[X_1^k\right]$, $\mathbb{E}\left[|X_1|^k\right] < \infty$, то за всяко фиксирано $k \geq 1$

$$\widehat{\theta}_{k,n} = \frac{1}{n}\sum_{j=1}^{n} X_j^k \xrightarrow{\mathbb{P}} \mathbb{E}\left[X_1^k\right] = \theta_k.$$

Затова емпиричните моменти са състоятелни оценки на съответните теоретични моменти.

Пример. За равномерното разпределение $U(0,\theta)$ оценката $Y_n = \max(X_1, \ldots, X_n)$ също е състоятелна, макар да е изместена. Наистина, за $0 < \varepsilon < \theta$,

$$\mathbb{P}\left(|Y_n - \theta| > \varepsilon\right) = \mathbb{P}\left(Y_n < \theta - \varepsilon\right) = \left(1 - \frac{\varepsilon}{\theta}\right)^n \longrightarrow 0.$$

Бел.: Въпрос: ако знаем само крайно много моменти $\mathbb{E}\left[X\right], \mathbb{E}\left[X^2\right], \ldots, \mathbb{E}\left[X^k\right]$, можем ли еднозначно да определим разпределението F_X?

Максимално правдоподобие и ентропия

Допълнителна бележка към Лекция 12

Постановка на задачата

Нека $\mathcal{H}$ е множество от хипотези за разпределението на случайната величина X. На всяка хипотеза $h \in \mathcal{H}$ съответства плътност f_h. Нека $h_* \in \mathcal{H}$ е *истинската*, но неизвестна хипотеза, т.е. наблюденията $X_1, \ldots, X_n$ са независими и еднакво разпределени с плътност f_{h_*}.

За всяка кандидат-хипотеза $h \in \mathcal{H}$ дефинираме функцията на правдоподобие

$$L_n(h) = L(\vec{X} \mid h) = \prod_{j=1}^{n} f_h(X_j).$$

Търсим хипотеза $\widehat{h}_n$, която максимизира $L_n(h)$. Ако $f_h(X_j) > 0$, можем да разглеждаме логаритмичното правдоподобие

$$\ell_n(h) = \log L_n(h) = \sum_{j=1}^{n} \log f_h(X_j), \qquad M_n(h) = \frac{\ell_n(h)}{n}.$$

Тъй като логаритъмът е строго растящ, максимизаторите на L_n, ℓ_n и M_n съвпадат. Полагаме

$$Y_j(h) = \log f_h(X_j), \qquad M_n(h) = \frac{1}{n}\sum_{j=1}^{n} Y_j(h).$$

Гранично логаритмично правдоподобие

За фиксирана хипотеза h предполагаме, че $\mathbb{E}_{h_*}[|\log f_h(X_1)|] < \infty$. Тогава законът за големите числа дава

$$M_n(h) \xrightarrow[n\to\infty]{\text{п.с.}} \mathbb{E}_{h_*}[\log f_h(X_1)] = \int \log f_h(x)\, f_{h_*}(x)\, dx =: J(h).$$

Следователно границата на нормализираното логаритмично правдоподобие е детерминистичната функция $J : \mathcal{H} \mapsto \mathbb{R}$.

Връзка с относителната ентропия

Да приемем, че плътностите са положителни върху общата си област и всички интеграли по-долу са определени. Тогава

$$\begin{aligned} J(h_*) - J(h) &= \int \log \frac{f_{h_*}(x)}{f_h(x)}\, f_{h_*}(x)\, dx \\ &= -\mathbb{E}_{h_*}\left[\log \frac{f_h(X_1)}{f_{h_*}(X_1)}\right] \\ &\geq -\log \mathbb{E}_{h_*}\left[\frac{f_h(X_1)}{f_{h_*}(X_1)}\right] = -\log \int f_h(x)\, dx = 0. \end{aligned}$$

Използвахме неравенството на Йенсен за вдлъбнатата функция $\log$. Лявата страна е *относителната ентропия* (дивергенцията на Кулбак–Лайблер)

$$D_{\mathrm{KL}}(f_{h_*} \| f_h) = \int f_{h_*}(x) \log \frac{f_{h_*}(x)}{f_h(x)}\, dx \geq 0.$$

Значи истинската плътност максимизира J:

$$J(h_*) = \max_{h\in\mathcal{H}} J(h).$$

Равенство $J(h) = J(h_*)$ е възможно точно когато $f_h = f_{h_*}$ почти навсякъде. Ако моделът е *идентифицируем*, т.е. различните h задават различни разпределения, максимумът на J е единствен и се достига при h_*.

Бел.: С обичайната конвенция за диференциална ентропия $H(f) = -\int f \log f$ имаме $J(h_*) = -H(f_{h_*})$. Съществото за оценяването е разликата $J(h_*) - J(h) = D_{\mathrm{KL}}(f_{h_*} \| f_h)$.

За състоятелността на оценката

Ако h_0 е *фиксирана* невярна хипотеза и $J(h_0) < J(h_*)$, то от закона за големите числа следва

$$M_n(h_*) - M_n(h_0) \xrightarrow[n\to\infty]{\text{п.с.}} J(h_*) - J(h_0) > 0.$$

Следователно с вероятност 1 за всички достатъчно големи n е изпълнено $L_n(h_*) > L_n(h_0)$. Това обяснява защо максималното правдоподобие предпочита истинския модел пред всяка *отделно фиксирана* грешна хипотеза.

Бел.: Тази аргументация сама по себе си не доказва $\widehat{h}_n \to h_*$: максимизиращата хипотеза $\widehat{h}_n$ може да се променя с n. При безкраен клас от хипотези обикновено е необходима и равномерна сходимост. Достатъчно условие е например $\mathcal{H}$ да е компактно метрично пространство, J да е непрекъсната с единствен максимум при h_* и да е изпълнено

$$\sup_{h\in\mathcal{H}} |M_n(h) - J(h)| \xrightarrow[n\to\infty]{n.c.} 0.$$

Тогава всеки избран максимизатор $\widehat{h}_n$ на M_n клони почти сигурно към h_*. Наистина, върху компактното множество $\{h : d(h, h_*) \geq \varepsilon\}$ функцията J е отделена с положителна разлика от максимума си, а равномерната сходимост пренася това свойство върху M_n за големи n.

Пример: експоненциално разпределение

Нека $X_1, \dots, X_n$ са независими с плътност

$$f_h(x) = he^{-hx}\, 1_{\{x>0\}}, \qquad h > 0.$$

Тогава за положителни наблюдения

$$\ell_n(h) = n \log h - h \sum_{j=1}^{n} X_j, \qquad M_n(h) = \log h - h\overline{X}_n.$$

От

$$\frac{d}{dh} M_n(h) = \frac{1}{h} - \overline{X}_n, \qquad \frac{d^2}{dh^2} M_n(h) = -\frac{1}{h^2} < 0$$

получаваме единствената МП-оценка

$$\widehat{h}_n = \frac{1}{\overline{X}_n}.$$

При истински параметър h_* имаме $\mathbb{E}[X_1] = 1/h_*$ и законът за големите числа дава $\overline{X}_n \to 1/h_*$ почти сигурно. Следователно

$$\widehat{h}_n = \frac{1}{\overline{X}_n} \xrightarrow[n\to\infty]{\text{п.с.}} h_*.$$

В този пример $J(h) = \log h - h/h_*$ и

$$J(h_*) - J(h) = \log \frac{h_*}{h} + \frac{h}{h_*} - 1 \geq 0,$$

което илюстрира ентропийното неравенство.

Лекция 13

Доверителни интервали

В предходната лекция разглеждахме точкови оценки $\hat{\theta} = \hat{\theta}(\vec{X})$ на неизвестния параметър θ въз основа на извадката $\vec{X} = (X_1, \ldots, X_n)$. Сега ще построяваме интервални оценки. За простота нека $\theta \in \Theta \subseteq \mathbb{R}$ и законът на наблюденията се задава чрез $F_X(x;\theta)$.

Дефиниция. Случайният интервал

$$I(\vec{X}) = [T_1(\vec{X}), T_2(\vec{X})]$$

се нарича *доверителен интервал* за θ с *доверителна вероятност* (ниво на доверие) γ, ако

$$\mathbb{P}_\theta\big(T_1(\vec{X}) \le \theta \le T_2(\vec{X})\big) \ge \gamma, \qquad \theta \in \Theta.$$

Често γ се избира между 0.9 и 0.999. При равенство за всички θ интервалът има точно ниво γ.

Краищата T_1, T_2 са статистики, т.е. случайни величини. След наблюдаване на извадката получаваме конкретен интервал.

Централна статистика

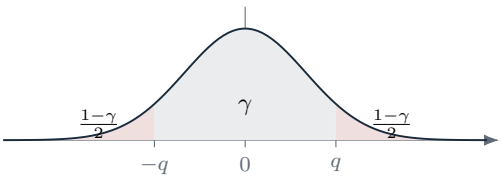
Дефиниция. Величината $T = T(\vec{X}, \theta)$ се нарича *централна статистика* , ако има непрекъснато разпределение, което не зависи от неизвестния параметър θ.

Ако изберем $q_1 < q_2$ така, че

$$\mathbb{P}_\theta\big(q_1 \le T(\vec{X}, \theta) \le q_2\big) = \gamma,$$

и успеем да решим тези неравенства относно θ, получаваме доверителен интервал. Например при симетрично разпределение на T можем да вземем $q_1 = -q$, $q_2 = q$, като

$$\mathbb{P}_\theta(T < -q) = \mathbb{P}_\theta(T > q) = \frac{1-\gamma}{2}.$$



Интервали за математическото очакване на нормална извадка

Пример. *Известна дисперсия.* Нека $X_1, \ldots, X_n$ са независими с разпределение $N(\mu, \sigma^2)$, където $\sigma^2 > 0$ е известно, а μ е неизвестно. Тогава

$$\overline{X}_n = \frac{1}{n}\sum_{j=1}^{n} X_j \sim N\left(\mu, \frac{\sigma^2}{n}\right), \qquad T = \frac{\overline{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0,1).$$

Тъй като законът на T не зависи от μ, величината е централна статистика. Нека $Z \sim N(0,1)$ и изберем $q > 0$ с

$$\gamma = \mathbb{P}\left(-q \le Z \le q\right) = 2\Phi(q) - 1, \qquad q = \Phi^{-1}\left(\frac{1+\gamma}{2}\right).$$

От $-q \le (\overline{X}_n - \mu)/(\sigma/\sqrt{n}) \le q$ следва

$$I_\mu = \left[\overline{X}_n - q\frac{\sigma}{\sqrt{n}}, \overline{X}_n + q\frac{\sigma}{\sqrt{n}}\right].$$

Например за $\gamma = 0.95$ имаме $q \approx 1.96$. Дължината на интервала намалява пропорционално на $n^{-1/2}$.

Пример. *Неизвестна дисперсия.* Нека сега и σ^2 е неизвестно. Полагаме

$$S^2 = \frac{1}{n-1}\sum_{j=1}^{n}(X_j - \overline{X}_n)^2, \qquad n \geq 2.$$

За нормална извадка е изпълнен важният факт

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1), \qquad \overline{X}_n \perp\!\!\!\perp S^2.$$

Той се получава от ортогоналното разлагане

$$\sum_{j=1}^{n}\frac{(X_j-\mu)^2}{\sigma^2} = \frac{(n-1)S^2}{\sigma^2} + \left(\frac{\overline{X}_n - \mu}{\sigma/\sqrt{n}}\right)^2$$

и независимостта на съответните компоненти на нормалния вектор. Следователно

$$T_n = \frac{\overline{X}_n - \mu}{S/\sqrt{n}} = \frac{Z}{\sqrt{V_n/(n-1)}} \sim t(n-1), \qquad Z \sim N(0,1), \quad V_n = \frac{S^2}{\sigma^2}(n-1) \sim \chi^2(n-1), \quad Z \perp\!\!\!\perp V_n.$$

Разпределението на Стюдент $t(n-1)$ е симетрично. Ако $q > 0$ се избере така, че $\mathbb{P}(|T_n| \leq q) = \gamma$, то

$$I_\mu = \left[\overline{X}_n - q\frac{S}{\sqrt{n}}, \overline{X}_n + q\frac{S}{\sqrt{n}}\right].$$

При големи n разпределението $t(n-1)$ е близко до $N(0,1)$, понеже $V_n/(n-1) \xrightarrow{\mathbb{P}} 1$.

Доверителни интервали за дисперсията

Нека отново $X_1, \ldots, X_n$ са независими с разпределение $N(\mu, \sigma^2)$. Избираме $0 < q_1 < q_2$ така, че

$$\mathbb{P}(q_1 \leq V_n \leq q_2) = \gamma$$

за съответното χ^2-разпределение V_n.

а) Ако μ е известно, тогава

$$V_n = \frac{1}{\sigma^2}\sum_{j=1}^{n}(X_j-\mu)^2 \sim \chi^2(n),$$

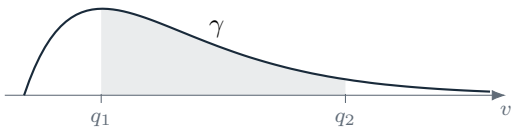
и доверителен интервал за σ^2 е

$$I_{\sigma^2} = \left[\frac{\sum_{j=1}^{n}(X_j-\mu)^2}{q_2}, \frac{\sum_{j=1}^{n}(X_j-\mu)^2}{q_1}\right].$$

б) Ако μ е неизвестно, използваме $V_n = (n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ и получаваме

$$I_{\sigma^2} = \left[\frac{(n-1)S^2}{q_2}, \frac{(n-1)S^2}{q_1}\right].$$

В двата случая квантилите q_1, q_2 са на съответното χ^2-разпределение (с n или $n-1$ степени на свобода).



Проверка на статистически хипотези

При точковото и интервалното оценяване търсим стойността на неизвестния параметър. Сега искаме да проверим твърдение за него въз основа на извадката $\vec{X}$.

Разглеждаме *нулева хипотеза* H_0 и *алтернативна хипотеза* H_1. При *прости хипотези* например

$$H_0 : \ \theta = \theta_0, \qquad H_1 : \ \theta = \theta_1,$$

а при *сложни хипотези* можем да имаме $H_1 : \theta > \theta_0$ (или $\theta < \theta_0$). **Пример.** Можем да проверяваме твърдение за честотата на странични реакции при ваксина. Ако p е тази честота, пример за две прости хипотези са $H_0 : p = 0.99$ и $H_1 : p = 0.95$.

Дефиниция. *Критична област* (област на отхвърляне) на критерия е множество $W \subseteq \mathbb{R}^n$. Отхвърляме H_0, ако $\vec{X} \in W$; в противен случай не я отхвърляме.

При две прости хипотези H_0 и H_1 разглеждаме

$$\begin{aligned} \alpha &= \mathbb{P}\left(\vec{X} \in W \middle| H_0\right) && \text{— вероятност за грешка от първи род,} \\ \beta &= \mathbb{P}\left(\vec{X} \notin W \middle| H_1\right) && \text{— вероятност за грешка от втори род,} \\ 1-\beta &= \mathbb{P}\left(\vec{X} \notin W \middle| H_1\right) && \text{— мощност на критерия.} \end{aligned}$$

Често предварително избираме ниво на значимост α (например 0.05 или 0.01). Ако $W_1 \subseteq W_2$, то

$$\alpha(W_1) \le \alpha(W_2), \qquad \beta(W_1) \ge \beta(W_2).$$

Следователно по-голямата критична област повишава мощността, но увеличава и вероятността за грешка от първи род.

Дефиниция. Критерий с критична област W^* се нарича *най-мощен на ниво* α срещу фиксирана алтернатива H_1, ако $\mathbb{P}\left(\vec{X} \in W^* \middle| H_0\right) \le \alpha$ и за всяка друга област W с $\mathbb{P}\left(\vec{X} \in W \middle| H_0\right) \le \alpha$ имаме

$$\mathbb{P}(\vec{X} \notin W \big| H_1) \ge \mathbb{P}(\vec{X} \notin W^* \big| H_1).$$

Лема на Нейман–Пирсън

Нека

$$H_0 : \ \theta = \theta_0, \qquad H_1 : \ \theta = \theta_1$$

са прости хипотези и при H_i съвместната плътност на извадката е

$$L_i(\vec{x}) = \prod_{j=1}^{n} f_X(x_j; \theta_i), \qquad i = 0, 1.$$

Лема (Нейман–Пирсън). Да допуснем, че за някое $k \ge 0$ критичната област

$$W^* = \{\vec{x} : L_1(\vec{x}) > k L_0(\vec{x})\}$$

има $\mathbb{P}(\vec{X} \in W^* \big| H_0) = \alpha$. Тогава W^* е най-мощна област на ниво α.

Доказателство. Нека W е друга критична област с $\mathbb{P}(\vec{X} \in W \big| H_0) = \alpha$. От дефиницията на W^* (с произволно разпределение на граничните точки, при които има равенство) следва

$$\begin{aligned} &\mathbb{P}_{H_1}(\vec{X} \in W^*) - \mathbb{P}_{H_1}(\vec{X} \in W) \\ &\quad = \int_{W^* \setminus W} L_1(\vec{x})\, d\vec{x} - \int_{W \setminus W^*} L_1(\vec{x})\, d\vec{x} \\ &\quad \ge k \left(\int_{W^* \setminus W} L_0(\vec{x})\, d\vec{x} - \int_{W \setminus W^*} L_0(\vec{x})\, d\vec{x} \right) \\ &\quad = k\big(\mathbb{P}_{H_0}(\vec{X} \in W^*) - \mathbb{P}_{H_0}(\vec{X} \in W)\big) \ge 0. \end{aligned}$$

Следователно W^* има максимална мощност. □

Пример: нормално разпределение с известна дисперсия

Нека $X_1, \ldots, X_n$ са независими с разпределение $N(\mu, \sigma^2)$, където σ^2 е известно. Проверяваме простите хипотези

$$H_0 : \ \mu = \mu_0, \qquad H_1 : \ \mu = \mu_1 > \mu_0.$$

Функциите на правдоподобие са

$$L_i(\vec{x}) = (\sigma\sqrt{2\pi})^{-n} \exp\left(-\frac{1}{2\sigma^2} \sum_{j=1}^{n} (x_j - \mu_i)^2 \right), \qquad i = 0, 1.$$

Тогава

$$\log \frac{L_1(\vec{x})}{L_0(\vec{x})} = \frac{\mu_1 - \mu_0}{\sigma^2} \sum_{j=1}^{n} x_j - \frac{n(\mu_1^2 - \mu_0^2)}{2\sigma^2}.$$

Понеже $\mu_1 > \mu_0$, отношението L_1/L_0 нараства с $\overline{x}_n$. Лемата на Нейман–Пирсън дава критична област

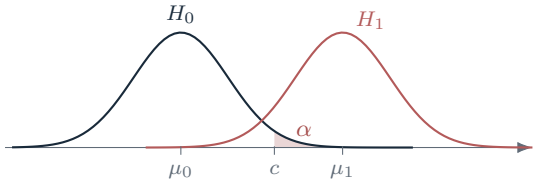
$$W^* = \{\vec{x} : \overline{x}_n \geq c\} = \{\vec{x} : L_1(\vec{x}) \geq K L_0(\vec{x})\}.$$

Намираме c, K (дайте израз), така че вероятността за отхвърляне при H_0 да е точно α. Тъй като

$$Z = \frac{\overline{X}_n - \mu_0}{\sigma/\sqrt{n}} \sim N(0,1) \quad \text{при } H_0,$$

и ако $q_{1-\alpha}$ е квантилът на стандартното нормално разпределение с $\mathbb{P}(Z \geq q_{1-\alpha}) = \alpha$, получаваме

$$W^* = \left\{ \vec{x} : \overline{x}_n \geq \mu_0 + q_{1-\alpha} \frac{\sigma}{\sqrt{n}} \right\} = \left\{ \vec{x} : \frac{\overline{x}_n - \mu_0}{\sigma/\sqrt{n}} \geq q_{1-\alpha} \right\}.$$



При наблюдавана извадка отхвърляме H_0 тогава и само тогава, когато

$$\overline{X}_n \geq \mu_0 + q_{1-\alpha} \frac{\sigma}{\sqrt{n}}.$$

Лекция 14

Линейна регресия

Едно от първите статистически изследвания на линейната регресия е проведено от Франсис Галтон. Той изследва зависимостта между ръста на бащите и техните синове. Ако X е отклонението на ръста на бащата от средния ръст, то средният ръст на сина се приближава с израз от вида

$$\text{среден ръст} + \beta X, \qquad \beta \approx 0.6.$$

Така отклоненията на синовете от средния ръст обикновено са по-малки от отклоненията на бащите — явление, известно като *регрес към средното*.

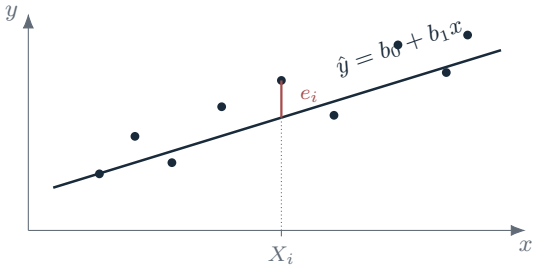
Дефиниция. При *проста линейна регресия* наблюденията се описват с модела

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \qquad i = 1, \dots, n,$$

където Y_i е зависимата променлива, X_i е регресорът, β_0, β_1 са неизвестни параметри, а ε_i е случайната грешка.

Търсим оценки b_0, b_1 на β_0, β_1. Регресионната права е $\hat{y} = b_0 + b_1 x$. За наблюдението (X_i, Y_i) предсказаната стойност и остатъкът са съответно

$$\widehat{Y}_i = b_0 + b_1 X_i, \qquad e_i = Y_i - \widehat{Y}_i.$$



Метод на най-малките квадрати

Избираме b_0, b_1 така, че сумата от квадратите на остатъците да бъде минимална:

$$Q(b_0, b_1) = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (Y_i - b_0 - b_1 X_i)^2 \longrightarrow \min.$$

Необходимите условия за минимум дават *нормалните уравнения*

$$\frac{\partial Q}{\partial b_0} = -2 \sum_{i=1}^{n} (Y_i - b_0 - b_1 X_i) = 0,$$

$$\frac{\partial Q}{\partial b_1} = -2 \sum_{i=1}^{n} X_i (Y_i - b_0 - b_1 X_i) = 0.$$

Означаваме

$$\overline{X} = \frac{1}{n} \sum_{i=1}^{n} X_i, \qquad \overline{Y} = \frac{1}{n} \sum_{i=1}^{n} Y_i, \qquad S_{xx} = \sum_{i=1}^{n} (X_i - \overline{X})^2.$$

Първото уравнение е еквивалентно на $\overline{Y} = b_0 + b_1 \overline{X}$, тоест

$$b_0 = \overline{Y} - b_1 \overline{X}.$$

Замествайки във второто, получаваме

$$\begin{aligned} 0 &= \sum_{i=1}^{n} X_i\big(\overline{Y} - b_1\overline{X} + b_1 X_i - Y_i\big) \\ &= n\overline{X}\,\overline{Y} - b_1 n\overline{X}^2 + b_1\sum_{i=1}^{n} X_i^2 - \sum_{i=1}^{n} X_i Y_i. \end{aligned}$$

Следователно, ако $S_{xx} > 0$ (наблюдаваните X_i не са всички равни), то оценките съществуват и са единствени:

$$b_1 = \frac{\sum_{i=1}^n X_i Y_i - n\overline{X}\,\overline{Y}}{\sum_{i=1}^n X_i^2 - n\overline{X}^2} = \frac{\sum_{i=1}^n (X_i - \overline{X})(Y_i - \overline{Y})}{\sum_{i=1}^n (X_i - \overline{X})^2}, \qquad b_0 = \overline{Y} - b_1\overline{X}.$$

Свойства на оценките

Получените оценки съществуват алгебрично, но доколко са добри? За изследването им разглеждаме модела

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \qquad i = 1, \ldots, n,$$

като $X_1, \ldots, X_n$ се смятат за фиксирани (контролирани) стойности. Предполагаме, че грешките са независими и

$$\mathbb{E}\,[\varepsilon_i] = 0, \qquad \mathrm{D}(\varepsilon_i) = \sigma^2 > 0 \quad \text{за всяко } i.$$

Равенството на дисперсиите се нарича *хомоскедастичност*. Понякога се добавя по-силното предположение $\varepsilon_i \sim N(0, \sigma^2)$, което ни позволява да получим точните разпределения на оценките.
Понеже $\sum_i (X_i - \overline{X}) = 0$, формулата за наклона се записва като

$$b_1 = \frac{\sum_{i=1}^n (X_i - \overline{X}) Y_i}{S_{xx}} = \beta_1 + \frac{\sum_{i=1}^n (X_i - \overline{X})\varepsilon_i}{S_{xx}}.$$

Следователно

$$\mathbb{E}\,[b_1] = \beta_1, \qquad \mathrm{D}(b_1) = \frac{\sigma^2}{S_{xx}}.$$

Действително, при пресмятане на дисперсията използваме независимостта на грешките:

$$\mathrm{D}(b_1) = \frac{1}{S_{xx}^2}\sum_{i=1}^{n} (X_i - \overline{X})^2 \sigma^2 = \frac{\sigma^2}{S_{xx}}.$$

Оценката b_1 е *неизместена*. Ако грешките са нормални, тогава като линейна комбинация от тях

$$b_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right).$$

За свободния член имаме

$$b_0 = \overline{Y} - b_1\overline{X} = \beta_0 + \overline{\varepsilon} - \frac{\overline{X}}{S_{xx}}\sum_{i=1}^{n} (X_i - \overline{X})\varepsilon_i, \qquad \overline{\varepsilon} = \frac{1}{n}\sum_{i=1}^{n} \varepsilon_i.$$

Тогава $\mathbb{E}\,[b_0] = \beta_0$, т.е. и b_0 е неизместена оценка. Освен това

$$\mathrm{Cov}\left(\overline{\varepsilon}, \sum_{i=1}^{n} (X_i - \overline{X})\varepsilon_i\right) = \frac{\sigma^2}{n}\sum_{i=1}^{n} (X_i - \overline{X}) = 0,$$

откъдето

$$\mathrm{D}(b_0) = \mathrm{D}(\bar{\varepsilon}) + \frac{\overline{X}^2}{S_{xx}^2}\mathrm{D}\left(\sum_{i=1}^{n}(X_i - \overline{X})\varepsilon_i\right)$$
$$= \sigma^2\left(\frac{1}{n} + \frac{\overline{X}^2}{S_{xx}}\right).$$

При нормални грешки получаваме също

$$b_0 \sim N\left(\beta_0, \sigma^2\left(\frac{1}{n} + \frac{\overline{X}^2}{S_{xx}}\right)\right).$$

Бел.: Неизместеността и формулите за дисперсиите не изискват нормалност, а само посочените условия върху грешките.

Оценка на σ^2

Ако $\varepsilon_i \sim N(0, \sigma^2)$ са независими, то

$$\frac{1}{\sigma^2}\sum_{i=1}^{n}(Y_i - \beta_0 - \beta_1 X_i)^2 \sim \chi^2(n).$$

След оценяване на двата параметъра β_0, β_1 сумата от квадратите на остатъците има разпределение

$$\frac{1}{\sigma^2}\sum_{i=1}^{n}(Y_i - b_0 - b_1 X_i)^2 \sim \chi^2(n-2), \qquad n \geq 3.$$

Тъй като математическото очакване на $\chi^2(k)$ е k, следва

$$\mathbb{E}\left[\sum_{\mathrm{i}=1}^{\mathrm{n}}(\mathrm{Y_i} - \mathrm{b_0} - \mathrm{b_1 X_i})^2\right] = (n-2)\sigma^2.$$

Ето защо *неизместената оценка на дисперсията* е

$$\hat{\sigma}^2 = \frac{1}{n-2}\sum_{i=1}^{n}(Y_i - b_0 - b_1 X_i)^2.$$

Проверка на хипотези

Често искаме да проверим дали има линейна зависимост в модела. Това съответства на $H_0 : \beta_1 = 0$. По-общо разглеждаме двустранните хипотези

$$H_0 : \ \beta_1 = b, \qquad H_1 : \ \beta_1 \neq b,$$

при предварително зададено ниво на значимост α.

Известна дисперсия. Ако σ^2 е известно и грешките са нормални, то при H_0

$$Z = \frac{b_1 - b}{\sigma/\sqrt{S_{xx}}} \sim N(0,1).$$

Нека $q_{\alpha/2} > 0$ е определено чрез $\mathbb{P}\left(Z_0 \geq q_{\alpha/2}\right) = \alpha/2$ за $Z_0 \sim N(0,1)$. Критичната област е

$$W = \left\{|Z| \geq q_{\alpha/2}\right\}.$$

Съответният доверителен интервал за β_1 с доверителна вероятност $1-\alpha$ е

$$I_{\beta_1} = \left[b_1 - q_{\alpha/2}\frac{\sigma}{\sqrt{S_{xx}}}, \quad b_1 + q_{\alpha/2}\frac{\sigma}{\sqrt{S_{xx}}}\right].$$

Неизвестна дисперсия. Заместваме σ^2 с $\hat{\sigma}^2$. При H_0 статистиката

$$T = \frac{b_1 - b}{\hat{\sigma}/\sqrt{S_{xx}}} \sim t(n-2).$$

Ако $q^{(t)}_{\alpha/2}$ е горният $\alpha/2$-квантил на разпределението $t(n-2)$, отхвърляме H_0 при $|T| \geq q^{(t)}_{\alpha/2}$. Доверителният интервал за β_1 се получава от горния, като заменим σ с $\hat{\sigma}$ и нормалния квантил с $q^{(t)}_{\alpha/2}$.

Проверка на хипотеза за свободния член. От формулата за дисперсията на b_0 означаваме

$$h_0^2 = \frac{1}{n} + \frac{\overline{X}^2}{S_{xx}}, \qquad b_0 \sim N(\beta_0, \sigma^2 h_0^2).$$

При проверка на $H_0 : \beta_0 = b$ и известна σ^2 използваме

$$Z_0 = \frac{b_0 - b}{\sigma h_0} \sim N(0,1) \qquad \text{при } H_0.$$

Ако σ^2 е неизвестна, тогава

$$T_0 = \frac{b_0 - b}{\hat{\sigma} h_0} \sim t(n-2) \qquad \text{при } H_0.$$

Критичните области за двустранните проверки се задават от съответните нормални и Стюдентови квантили, както при β_1.